
TRADING INTELLIGENT

Économétrie financière, Machine Learning, Deep Learning
et Reinforcement Learning pour la décision de marché

CHAPITRE 1

Comprendre le marché et ses données

Question directrice : Avant de prédire un marché, que mesure-t-on réellement, et quelle information un algorithme peut-il légitimement utiliser au temps t ?

Tawfik Masrour

Version 2.1 – septembre 2026

Comment utiliser ce chapitre

Ce chapitre pose les fondations conceptuelles et pratiques de l'ouvrage. Il peut être lu de manière autonome, puis prolongé par deux laboratoires numériques complémentaires : l'un consacré aux données de marché, aux bougies OHLCV et à la microstructure élémentaire ; l'autre aux rendements, aux ajustements et à la qualité des données. L'objectif n'est pas d'accumuler du vocabulaire financier, mais de construire des conventions suffisamment précises pour que les modèles étudiés ensuite aient un sens statistique, économique et opérationnel.

À RETENIR – Principe de travail

Le prix, le rendement, la volatilité, le signal, la position et le PnL (*Profit and Loss*, résultat financier) sont six objets différents. Les confondre est l'une des sources les plus fréquentes d'erreur dans un projet de trading algorithmique.

Table des matières

1	Comprendre le marché et ses données	1
1.1	Pourquoi commencer par la donnée plutôt que par l'intelligence artificielle ?	1
1.2	Du marché réel à une série temporelle	2
1.3	Le temps est une variable structurelle	8
1.4	Prix brut, prix ajusté et opérations sur titres	9
1.5	Pourquoi passer du prix au rendement ?	11
1.6	Volatilité : mesurer l'amplitude plutôt que la direction	14
1.7	Premiers faits stylisés des rendements financiers	15
1.8	De la variation au capital : composer correctement les rendements	16
1.9	Qualité des données : le premier "modèle" est un contrôle	17
1.10	Premier pont vers le Machine Learning	19
1.11	Premier pont vers le Reinforcement Learning	19
1.12	Laboratoires numériques du chapitre	20
1.13	Point de vue ingénieur : le contrat de donnée	20
1.14	Ce que ce chapitre ne permet pas encore de conclure	21
1.15	Exercices	21
1.16	Mini-activité pratique : diagnostic d'une source de marché	23
1.17	Synthèse	23
1.18	Lexique local FR-EN	24
1.19	Transition vers le chapitre 2	25

Comprendre le marché et ses données

QUESTION DIRECTRICE – Que voit vraiment un algorithme de trading ?

Une stratégie intelligente ne voit ni “la Bourse”, ni “le futur”, ni même un prix unique. Elle reçoit une suite de mesures, prises à certaines dates, selon certaines conventions, avec des coûts, des délais et des imperfections. Avant tout modèle statistique ou réseau de neurones, il faut donc construire correctement l’objet que l’on veut apprendre.

1.1 Pourquoi commencer par la donnée plutôt que par l’intelligence artificielle ?

L’intitulé *Trading Intelligent* peut donner envie de commencer immédiatement par les modèles les plus sophistiqués : réseaux neuronaux séquentiels, Transformers ou agents d’apprentissage par renforcement. Ce serait pourtant une mauvaise entrée, à la fois pédagogique et scientifique. Un modèle peut être extrêmement sophistiqué et produire une conclusion totalement fausse si l’on a mal défini le prix, le temps, le rendement ou l’information disponible au moment de la décision.

La première compétence d’un ingénieur quantitatif n’est donc pas de connaître le plus grand nombre d’algorithmes. Elle consiste à savoir transformer un flux de marché en une représentation explicite, correctement horodatée et exploitable sans ambiguïté. Ce chapitre installe cette grammaire de base.

INTUITION – Le marché n’est pas un fichier CSV

Un fichier CSV (*Comma-Separated Values*, ou fichier de valeurs séparées) est une représentation tabulaire construite *après* les événements. Le marché, lui, est un processus continu d’ordres, de transactions, d’annulations et de mises à jour de cotations. Une ligne quotidienne décrite par les variables OHLCV (*Open, High, Low, Close, Volume*) est déjà une compression de cette activité. Comprendre ce qui a été compressé est indispensable avant d’appliquer un modèle.

Les questions qui vont guider le chapitre sont les suivantes :

- qu’est-ce qu’un prix de marché et pourquoi existe-t-il plusieurs prix au même instant ?
- que représentent exactement les variables Open, High, Low, Close et Volume ?
- pourquoi les rendements sont-ils souvent plus utiles que les niveaux de prix ?
- que signifie une volatilité calculée sur une fenêtre glissante ?
- comment distinguer une absence normale de cotation d’un trou de données ?
- quelles informations deviendront plus tard des variables explicatives (*features*), des cibles ou des variables de décision ?

Objectifs d'apprentissage

À l'issue du chapitre, le lecteur doit pouvoir :

1. décrire les principaux objets d'un flux de marché : transaction, cotation (quote), bid, ask, spread et OHLCV ;
2. distinguer niveau de prix, rendement simple et rendement logarithmique ;
3. calculer et interpréter une volatilité glissante élémentaire ;
4. identifier les principales difficultés de calendrier, ajustement et qualité des données ;
5. construire un premier pipeline Python reproductible de chargement, contrôle et transformation ;
6. expliquer pourquoi une donnée observable *après* la décision ne peut pas devenir une variable explicative (feature) au temps de la décision.

1.2 Du marché réel à une série temporelle

1.2.1 Quelques familles d'actifs

Tout au long de l'ouvrage, nous rencontrerons plusieurs familles d'instruments, car aucune ne doit être confondue avec “le marché” au sens général. Les actions représentent des titres de propriété d'entreprises cotées ; les indices synthétisent un panier d'actifs ; les devises sont cotées par paires ; les cryptomonnaies se négocient sur des plateformes souvent ouvertes en continu. Les mécanismes de cotation, les horaires et les coûts peuvent donc différer fortement.

TABLE 1.1 – Quelques objets financiers rencontrés dans l'ouvrage.

Famille	Exemple	Particularité utile	Attention
Action	AAPL, MSFT	prix, volume, opérations sur titres	splits, dividendes, horaires de bourse
Indice	S&P 500, MASI	mesure agrégée d'un marché	l'indice n'est pas toujours directement négociable
Devise	EUR/USD	cotation par paire, marché quasi continu en semaine	unités de cotation et fuseaux horaires
Crypto-actif	BTC/USDT	marché 24h/24, interface de programmation (API) souvent accessible	fragmentation des plateformes, forte volatilité

EXEMPLE – Comment lire quelques symboles de marché ?

AAPL et MSFT sont des *tickers*, c'est-à-dire des codes courts utilisés pour identifier des titres cotés. La paire EUR/USD exprime le nombre de dollars correspondant à un euro. De même, BTC/USDT cote le bitcoin dans une unité de compte indexée sur le dollar. Ces écritures sont compactes, mais elles portent déjà une convention : dans une paire X/Y , le prix indique combien d'unités de Y valent une unité de X .

Le but n'est pas ici de faire un cours de produits financiers. Nous retiendrons surtout qu'un même

algorithmes ne doit jamais être appliqué sans comprendre la nature de l'instrument et la convention des données.

1.2.2 Transaction, cotation et carnet d'ordres

Une **transaction** est un échange effectivement réalisé. Une **cotation** ou *quote* exprime au contraire des prix proposés par le marché. Dans un carnet d'ordres, le *best bid* est le **plus haut prix acheteur actuellement disponible**, tandis que le *best ask* est le **plus bas prix vendeur actuellement disponible**. Ces deux cotations encadrent la meilleure fourchette immédiatement visible ; elles ne décrivent pas à elles seules toute la profondeur du carnet.

DÉFINITION – Bid, Ask et Spread

Au temps t , notons B_t le meilleur prix acheteur et A_t le meilleur prix vendeur. Le *spread* est

$$S_t = A_t - B_t.$$

Le prix milieu de fourchette, ou *mid-price*, est souvent défini par

$$M_t = \frac{A_t + B_t}{2}.$$

Best bid, best ask et spread : les meilleures cotations visibles




FIGURE 1.1 – Représentation simplifiée des meilleures cotations bid/ask et du spread.

Cette distinction paraît élémentaire, mais elle deviendra cruciale lors d'une simulation rétrospective (backtesting). Une stratégie qui achète ne peut pas supposer qu'elle achète exactement au dernier prix affiché si l'ask est supérieur. De même, une stratégie qui vend traverse souvent le spread dans l'autre sens. Le spread est ainsi une première forme de coût de transaction.

EXEMPLE – Un coût invisible si l'on ne regarde que le Close

Supposons $B_t = 99,95$ et $A_t = 100,05$. Le mid-price vaut 100, mais un achat immédiat s'effectue approximativement à 100,05. Si l'on revend immédiatement au bid, le prix accessible est 99,95. Sans mouvement du marché, l'aller-retour perd déjà 0,10 par unité. Un backtest basé

uniquement sur un prix unique ignorerait ce coût.

1.2.3 Du flux continu aux barres OHLCV

Les données de marché peuvent être observées transaction par transaction, à la seconde, à la minute, à l'heure ou à la journée. Une barre OHLCV est une **agrégation** de ce flux. Elle conserve quelques caractéristiques de la période, mais elle ne conserve pas toute l'histoire des transactions.

Une barre OHLCV rassemble cinq informations. L'acronyme vient de l'anglais *Open, High, Low, Close, Volume* :

- **Open** : premier prix observé selon la convention de la barre ;
- **High** : plus haut prix observé pendant la période ;
- **Low** : plus bas prix observé pendant la période ;
- **Close** : dernier prix observé selon la convention de la barre ;
- **Volume** : quantité d'activité échangée selon la convention du marché et de la source.

DÉFINITION – Corps et mèches d'une bougie

Le **corps** relie Open et Close. La **mèche supérieure** relie le sommet du corps au High ; la **mèche inférieure** relie le bas du corps au Low. Une bougie est dite haussière lorsque $Close > Open$ et baissière lorsque $Close < Open$. Cette convention visuelle décrit le signe de la variation entre l'ouverture et la clôture ; elle ne révèle pas l'ordre complet des événements intrapériodes.




FIGURE 1.2 – Anatomie d'une bougie OHLC : corps, mèches, ouverture, clôture, plus haut et plus bas.




FIGURE 1.3 – Bougies journalières et volume : la bougie mise en évidence montre où lire Open, High, Low et Close sur un graphique réel. Chaque bougie résume une journée de négociation.

EXEMPLE – Lire une barre OHLCV en quelques secondes

Supposons qu'une période soit résumée par $Open = 100$, $High = 104$, $Low = 98$, $Close = 102$ et $Volume = 1,2$ million d'unités. Le corps va de 100 à 102, la mèche supérieure atteint 104 et la mèche inférieure 98. La bougie est haussière car $102 > 100$. En revanche, rien dans ces quatre prix ne dit si 104 a été touché avant 98.

Même OHLC, histoire différente

Considérons deux trajectoires :

$$100 \rightarrow 98 \rightarrow 104 \rightarrow 102 \quad \text{et} \quad 100 \rightarrow 104 \rightarrow 98 \rightarrow 102.$$

Elles ont exactement les mêmes valeurs $O = 100$, $H = 104$, $L = 98$ et $C = 102$, mais l'ordre des événements est inversé.




FIGURE 1.4 – Deux trajectoires intrapériodes différentes peuvent produire exactement la même barre OHLC.

ATTENTION – Une barre OHLC ne donne pas l'ordre des événements

Cette perte d'information n'est pas purement théorique. Si une stratégie possède simultanément un stop-loss et un take-profit à l'intérieur de la même barre, l'OHLC seul peut ne pas suffire à déterminer lequel aurait été touché en premier. Une simulation précise peut alors exiger une fréquence plus fine ou une hypothèse explicite d'exécution.

Pourquoi le Close d'une bougie n'est-il pas toujours l'Open de la suivante ?

Dans une série parfaitement continue et construite sur des transactions adjacentes, les deux valeurs peuvent être très proches. Mais l'égalité n'est pas une identité mathématique. Entre deux barres peuvent intervenir :

- une fermeture overnight ou un week-end ;
- une nouvelle information arrivée lorsque le marché était fermé ;
- une enchère ou un fixing d'ouverture ;
- une faible liquidité, de sorte qu'aucune transaction n'a lieu à certains niveaux ;
- un saut entre deux transactions successives ;
- une différence de convention de construction des barres.

Le rendement entre la clôture précédente et l'ouverture suivante est un **rendement close-to-open**. Lorsqu'une discontinuité significative apparaît entre les zones de prix de deux périodes successives, on parle couramment de **gap**, notamment de gap d'ouverture. Ainsi, une différence microscopique entre $Close_t$ et $Open_{t+1}$ n'est pas nécessairement un gap au sens visuel ou pratique ; et un gap significatif n'est pas, à lui seul, une erreur de donnée.

Que signifie réellement le volume ?

Le volume mesure une quantité d'activité échangée pendant la période, mais son unité dépend de l'instrument et de la source : nombre d'actions, contrats, unités de crypto-actif, volume notionnel, voire parfois une convention propre au fournisseur. Il faut donc documenter son unité avant toute comparaison. Dans la figure 1.3, le panneau supérieur décrit les niveaux de prix tandis que le panneau inférieur décrit la quantité échangée : ce sont deux informations complémentaires, mais de nature différente.

ATTENTION – Volume élevé ne signifie pas automatiquement “tendance validée”

Un volume élevé indique une activité d'échange importante relativement à une référence choisie. Il ne détermine pas, à lui seul, la direction future du prix et ne constitue pas une preuve de persistance d'une tendance. Son interprétation demande un contexte supplémentaire.

1.2.4 Fréquence, fenêtre, horizon et rebalancement : quatre horloges distinctes

Une donnée peut être enregistrée toutes les minutes alors que la décision vise un horizon de plusieurs heures. Une feature peut, elle, résumer plusieurs jours de passé, tandis que la position est révisée toutes les trente minutes. Quatre temporalités doivent donc être distinguées :

- la **fréquence d'observation** : intervalle entre deux enregistrements ;
- la **fenêtre de calcul des features** : profondeur de passé utilisée pour construire une information ;
- l'**horizon de prédiction** : distance entre l'instant de décision et la variable future visée ;
- la **fréquence de rebalancement** : rythme auquel la stratégie peut modifier sa position.

Quatre horloges indépendantes peuvent coexister dans une même stratégie



Capteurs = observation • rétroviseur = passé • phares = horizon • volant = action

FIGURE 1.5 – Observation, fenêtre de features, horizon de prédiction et rebalancement sont quatre temporalités différentes.

EXEMPLE – Quatre temporalités dans le même système

On peut observer des prix chaque minute, calculer certaines features à partir des 20 derniers jours, prédire une quantité à 3 heures et réviser la position toutes les 30 minutes. Aucun de ces nombres n'impose les trois autres.

INTUITION – Capteurs, mémoire, phares et volant

Une analogie utile consiste à voir la fréquence d'observation comme les *capteurs*, la fenêtre de features comme la *mémoire* utilisée pour interpréter le passé, l'horizon comme la portée des *phares* et le rebalancement comme le rythme auquel on peut agir sur le *volant*. L'analogie aide à séparer les rôles ; les définitions temporelles ci-dessus restent la référence scientifique.

Cette distinction deviendra fondamentale en Machine Learning et en Reinforcement Learning. Une feature calculée sur 20 jours n'implique ni une prédiction à 20 jours, ni une décision tous les 20 jours.

1.3 Le temps est une variable structurelle

Dans un problème tabulaire classique, permuter les lignes d'un fichier peut ne rien changer à la signification statistique. Pour une série temporelle, cette opération détruit la structure essentielle : l'ordre.

1.3.1 Horodatage, fuseau horaire et calendrier de marché

Une date n'est pas uniquement un label. Elle peut encoder un fuseau horaire, une heure d'ouverture, une heure de clôture et un calendrier particulier. Les marchés d'actions ferment les week-ends et jours fériés, alors que de nombreuses plateformes crypto fonctionnent en continu. Une fusion naïve de plusieurs sources peut ainsi aligner des observations qui ne représentent pas la même période économique.

POINT DE VUE INGÉNIEUR – Question de provenance

Avant de joindre deux fichiers, demander : “À quelle heure exacte cette valeur était-elle connue ?” Une date sans heure peut cacher une convention de clôture. Une valeur macroéconomique publiée le jour t ne doit pas être utilisée comme si elle était disponible dès le début de la journée t .

Nous rencontrerons plus tard une notion centrale : le **biais d'anticipation** (*look-ahead bias*). Le chapitre 6 l'étudiera en profondeur, mais sa prévention commence ici, par une horodatation propre.

1.3.2 Absence de ligne : trou ou marché fermé ?

Si une date manque dans une série quotidienne, plusieurs situations sont possibles :

- le marché était fermé ;
- la source n'a pas publié la donnée ;
- une erreur d'acquisition a eu lieu ;

- le titre a été suspendu ;
- la convention de calendrier est différente d'un autre actif.




FIGURE 1.6 – Un trou de données doit être diagnostiqué avant toute imputation.

Remplir automatiquement une valeur manquante par la dernière observation peut parfois être raisonnable, mais parfois catastrophique. En particulier, attribuer un rendement nul à une période non observée revient à introduire une information qui n'a jamais été mesurée.

1.4 Prix brut, prix ajusté et opérations sur titres

Pour une action, une variation du prix coté ne correspond pas toujours à une création ou à une destruction équivalente de richesse. Les **opérations sur titres** (*corporate actions*, OST) – notamment les splits ou fractionnements, les dividendes et les regroupements – peuvent introduire des ruptures mécaniques dans une série brute. D'autres événements peuvent aussi entrer dans cette famille selon le marché et la convention du fournisseur.

Split : davantage d'actions, prix unitaire différent

Lors d'un split 2-pour-1, le nombre d'actions est approximativement multiplié par deux tandis que le prix unitaire est approximativement divisé par deux, toutes choses égales par ailleurs :

$$1 \times 100 = 100 \quad \longrightarrow \quad 2 \times 50 = 100.$$

La richesse instantanée n'a donc pas été divisée par deux simplement parce que le prix unitaire passe d'environ 100 à 50.




FIGURE 1.7 – Autour d'un split, la série brute peut faire apparaître une chute mécanique que l'ajustement neutralise pour certaines analyses historiques.

ATTENTION – Expérience volontairement incorrecte

Si l'on calcule naïvement le rendement du jour du split à partir du prix brut, on peut obtenir un faux rendement proche de -50% . Le calcul est syntaxiquement correct, mais l'objet économique est mal défini : il ignore que le nombre d'actions détenues a changé.

Dividende : une partie de la valeur peut être versée en cash

Supposons, dans un raisonnement volontairement simplifié, qu'une action cote 100 euros juste avant le détachement d'un dividende de 5 euros. Toutes choses égales par ailleurs, le prix ex-dividende peut s'ajuster autour de 95 euros. L'investisseur possède alors approximativement :

95 euros d'action + 5 euros de cash.

Ce schéma isole le mécanisme du dividende ; dans le marché réel, les mouvements de prix simultanés, la fiscalité, la microstructure et les anticipations empêchent d'en faire une égalité exacte universelle.

DÉFINITION – Price return et total return

Le **price return** mesure la variation liée au prix seul. Le **total return** tient aussi compte des distributions reçues, par exemple les dividendes. Ainsi, un rendement calculé uniquement à partir du prix coté ne décrit pas nécessairement toute l'évolution de la richesse de l'investisseur. Cette distinction sera approfondie plus tard lorsque le besoin l'exigera.

Pourquoi existe-t-il des prix ajustés ?

Une série ajustée cherche à rendre comparables dans le temps des observations affectées par certaines opérations sur titres. Elle est souvent utile pour l'analyse de rendements historiques ou de richesse totale. Elle n'est cependant pas un substitut universel au prix réellement coté.

ATTENTION – Ne jamais transformer “Adjusted Close” en règle absolue

Le choix dépend de l’objectif. Une analyse de rendement total, une estimation statistique, une simulation d’exécution, une étude de microstructure ou la reconstitution d’ordres réels peuvent exiger des représentations différentes. Les fournisseurs peuvent en outre appliquer des conventions d’ajustement différentes. Il faut documenter ce qui a été ajusté, comment et pourquoi.

1.5 Pourquoi passer du prix au rendement ?

La figure 1.8 montre une trajectoire de prix synthétique. Elle semble posséder une tendance et des niveaux successifs. Pourtant, les modèles de séries temporelles s’intéressent souvent davantage aux variations qu’au niveau lui-même.



FIGURE 1.8 – Trajectoire de prix synthétique utilisée dans le notebook du chapitre.




FIGURE 1.9 – Rendements logarithmiques de la même série.

Le changement de représentation est profond. Le prix P_t est un niveau ; le rendement mesure une variation relative entre deux instants.

1.5.1 Rendement simple

Pour un actif sans flux intermédiaire, le rendement simple entre $t - 1$ et t est

$$R_t = \frac{P_t - P_{t-1}}{P_{t-1}} = \frac{P_t}{P_{t-1}} - 1.$$

Si $P_{t-1} = 100$ et $P_t = 103$, alors $R_t = 3\%$.

La propriété importante est la composition multiplicative :

$$1 + R_{0 \rightarrow 2} = (1 + R_1)(1 + R_2).$$

Une hausse de 10% suivie d'une baisse de 10% ne ramène donc pas au point de départ :

$$1.10 \times 0.90 = 0.99.$$

Le capital final est inférieur de 1% au capital initial.

1.5.2 Rendement logarithmique

Le rendement logarithmique est défini par

$$r_t = \ln \left(\frac{P_t}{P_{t-1}} \right) = \ln(P_t) - \ln(P_{t-1}).$$

Cette définition suppose des prix strictement positifs :

$$P_t > 0, \quad P_{t-1} > 0.$$

Son avantage principal est l'additivité temporelle :

$$r_{0 \rightarrow T} = \sum_{t=1}^T r_t.$$

Les deux définitions sont reliées par

$$r_t = \ln(1 + R_t), \quad R_t = e^{r_t} - 1.$$

Pour de petites variations, l'approximation $\ln(1 + x) \approx x$ donne $r_t \approx R_t$.




FIGURE 1.10 – Comparaison entre rendement simple et rendement logarithmique.

EXEMPLE – Calcul manuel sur trois jours

Soit $P_0 = 100$, $P_1 = 102$ et $P_2 = 99$. Alors

$$R_1 = \frac{102}{100} - 1 = 0.02, \quad R_2 = \frac{99}{102} - 1 \approx -0.02941.$$

La composition donne

$$(1 + R_1)(1 + R_2) - 1 = \frac{99}{100} - 1 = -0.01.$$

Avec les rendements logarithmiques,

$$r_1 = \ln(1.02), \quad r_2 = \ln(99/102),$$

et

$$r_1 + r_2 = \ln(99/100).$$

Les deux représentations décrivent la même évolution, mais avec des propriétés algébriques différentes.

1.5.3 Prix, rendement, signal, position, PnL : ne jamais les confondre

Cette distinction mérite d'être fixée dès maintenant :


prix	P_t ,
rendement	R_t ou r_t ,
signal	s_t ,
position	w_t ,
PnL	gain/perte monétaire ou relatif.

Le **PnL** (*Profit and Loss*) désigne le résultat financier, c'est-à-dire le gain ou la perte produit par une position. Il peut être exprimé en unité monétaire ou de manière relative.

EXEMPLE – Du rendement au PnL

Un capital de 10 000 MAD est entièrement exposé à un actif qui gagne 2% pendant la période. En négligeant les frais, le gain est $10\,000 \times 0,02 = 200$ MAD. Le rendement est 2% ; le PnL est ici +200 MAD. Ces deux quantités décrivent le même mouvement sous deux unités différentes.

Un modèle peut produire un signal positif sans que la stratégie prenne une position maximale. La taille de position dépendra du risque, de la confiance, des coûts et des contraintes. Nous reviendrons à cette chaîne dans les chapitres 8 et 9.

À RETENIR – La chaîne qui guidera tout l'ouvrage

Le modèle n'est qu'une brique du système.

1.6 Volatilité : mesurer l'amplitude plutôt que la direction

Un rendement moyen indique une tendance centrale, mais ne dit pas combien les observations fluctuent. La volatilité vise précisément cette dispersion.

Pour une fenêtre de w rendements, une estimation simple est l'écart-type empirique :

$$\hat{\sigma}_t = \sqrt{\frac{1}{w-1} \sum_{i=0}^{w-1} (r_{t-i} - \bar{r}_t)^2}.$$

Pour des données journalières, on annualise souvent par

$$\hat{\sigma}_{t,\text{ann}} = \sqrt{252} \hat{\sigma}_{t,\text{daily}}.$$

Le facteur 252 représente approximativement le nombre de jours de bourse par an. Cette annualisation repose sur une hypothèse de mise à l'échelle de la variance ; elle sera donc utilisée comme convention, non comme loi universelle.




FIGURE 1.11 – Volatilité glissante annualisée sur une fenêtre de 20 jours.

La volatilité mesure la **dispersion des rendements autour de leur niveau moyen**. Elle est souvent utilisée comme *proxy* de risque, mais elle ne constitue pas à elle seule une mesure exhaustive du risque. Elle traite symétriquement les fortes hausses et les fortes baisses et ne mesure pas directement, par exemple, le risque de liquidité ou le risque de perte extrême. Une journée peut être très volatile et finir presque au même niveau qu'elle a commencé ; inversement, une tendance régulière peut être directionnelle mais relativement peu volatile.

1.7 Premiers faits stylisés des rendements financiers

Les marchés réels ne se comportent pas exactement comme une suite de tirages gaussiens indépendants. Une littérature importante documente des propriétés récurrentes, souvent appelées *stylized facts* [2]. Nous n'en démontrerons pas encore la validité statistique ; nous les utiliserons comme observations qui motiveront les chapitres suivants.

1.7.1 Les rendements sont plus proches d'une série centrée que les prix

Le niveau de prix peut dériver fortement au cours du temps, tandis que les rendements oscillent souvent autour d'une moyenne beaucoup plus stable. Cette différence explique pourquoi la stationnarité sera la première question formelle du chapitre 2.

1.7.2 Les distributions peuvent avoir des queues épaisses

La figure 1.12 compare la distribution des rendements du jeu de données pédagogique à une loi normale ajustée. Le jeu de données est synthétique et a été construit avec des chocs à queues plus épaisses ; la figure sert donc à illustrer ce que l'on cherchera ensuite dans des données réelles.




FIGURE 1.12 – Distribution des rendements du jeu de données pédagogique et comparaison à une normale ajustée.

Une queue épaisse signifie qu'un événement extrême peut être plus fréquent que ne le suggère une approximation gaussienne simple. En gestion du risque, cette différence est loin d'être cosmétique : elle affecte les probabilités attribuées aux pertes importantes.

1.7.3 La volatilité peut se regrouper dans le temps

Il est courant d'observer des périodes calmes alterner avec des périodes agitées. Ce regroupement est visible lorsque l'on trace $|r_t|$ ou r_t^2 .




FIGURE 1.13 – Amplitude des rendements : illustration d'un regroupement temporel de la volatilité.

Cette observation donnera plus tard naissance à une question précise : si la variance change au cours du temps, peut-on la modéliser ? Le chapitre 3 introduira la famille ARCH/GARCH, c'est-à-dire des modèles autorégressifs d'hétéroscédasticité conditionnelle et leur généralisation, précisément conçus pour représenter une variance qui évolue dans le temps.

INTUITION – La moyenne et la variance ne racontent pas la même histoire

Il est possible que la direction moyenne d'un actif soit très difficile à prédire tout en ayant une volatilité partiellement prévisible. En finance, savoir *combien le marché risque de bouger* peut être aussi important que savoir *dans quel sens* il bougera.

1.8 De la variation au capital : composer correctement les rendements

Si une unité monétaire est investie et réinvestie, sa valeur après T périodes est

$$W_T = W_0 \prod_{t=1}^T (1 + R_t).$$

Pour $W_0 = 1$, la courbe W_T est souvent appelée *wealth curve* ou courbe de richesse. Elle ne constitue pas encore une simulation rétrospective complète de stratégie (backtest), mais elle apprend déjà à respecter la composition multiplicative des gains et pertes.




FIGURE 1.14 – Courbe de richesse obtenue en composant les rendements simples.

ATTENTION – Additionner des rendements simples sur de longues périodes

La somme $\sum_t R_t$ peut fournir une approximation pour de petites variations, mais elle ne représente pas exactement la croissance composée. Pour reconstituer un capital, utiliser le produit des facteurs $(1 + R_t)$ ou l'exponentielle de la somme des rendements logarithmiques.

1.9 Qualité des données : le premier “modèle” est un contrôle

Une chaîne de traitement (pipeline) de trading ne devrait jamais commencer par `model.fit`. Elle devrait commencer par des contrôles de cohérence. Les erreurs les plus dangereuses sont précisément celles qui ne provoquent aucune exception Python mais changent silencieusement le sens économique des données.

1.9.1 Contrôles minimaux

Pour une table de marché, on vérifiera au minimum :

1. ordre temporel et type des timestamps ;
2. fuseau horaire explicite lorsque l'heure importe ;
3. absence de doublons non expliqués ;
4. prix strictement positifs lorsque la convention l'exige ;
5. $High \geq \max(Open, Close)$ et $Low \leq \min(Open, Close)$;
6. $High \geq Low$;
7. $Ask \geq Bid$ lorsque des quotes sont présentes ;
8. volumes compatibles avec l'unité attendue et non négatifs lorsque cette convention s'applique ;
9. taux et localisation des valeurs manquantes ;

10. calendrier attendu, fermetures normales et trous anormaux ;
11. provenance, version et convention d'ajustement de la source.

```
assert df["date"].is_monotonic_increasing
assert not df["date"].duplicated().any()
assert (df["high"] >= df[["open", "close"]].max(axis=1)).all()
assert (df["low"] <= df[["open", "close"]].min(axis=1)).all()
assert (df["high"] >= df["low"]).all()
assert (df["ask"] >= df["bid"]).all()
```

Un `assert` ne remplace pas un audit de données. Il sert à transformer une hypothèse silencieuse en condition explicite et reproductible.

1.9.2 Trois erreurs qui produisent pourtant du code “qui marche”

- **Un trou remplacé par zéro** : le programme continue, mais on invente un rendement nul qui n’a pas été observé.
- **Des timestamps mal alignés** : deux colonnes sont présentes sur la même ligne alors qu’elles ne décrivent pas le même instant économique.
- **Un split traité comme un crash** : la formule de rendement est correcte, mais le prix brut n’est pas la bonne représentation pour la question posée.

Ces exemples montrent une distinction essentielle : **validité informatique** et **validité économique** ne sont pas synonymes.

1.9.3 Valeur aberrante ou événement réel ?

En analyse de données classique, une valeur très extrême, souvent qualifiée de valeur aberrante (*outlier*), est parfois traitée comme une anomalie à supprimer. En finance, cette réaction automatique est dangereuse : un crash, un gap ou une annonce importante est précisément un événement économique que le système doit parfois apprendre à gérer.

Avant de supprimer un point extrême, il faut demander :

- s’agit-il d’une erreur de collecte ou d’un mouvement réel ?
- une source secondaire indépendante confirme-t-elle l’observation ?
- une opération sur titres explique-t-elle la rupture ?
- le timestamp et le fuseau ont-ils été correctement interprétés ?
- l’événement s’est-il produit dans une phase de marché particulière ?

POINT DE VUE INGÉNIEUR – Tracer toute décision de nettoyage

Dans un projet sérieux, toute suppression, imputation ou correction doit être reproductible. Conserver la donnée brute en lecture seule, produire la donnée transformée par script et journaliser les décisions importantes. Un nettoyage non traçable devient rapidement une source de biais impossible à auditer.

1.10 Premier pont vers le Machine Learning

Le Machine Learning (ML, apprentissage automatique) sera réactivé progressivement lorsque ses notions deviendront utiles. À ce stade, trois idées suffisent : une observation, des variables explicatives et une cible à prédire.

RAPPEL JUSTE À TEMPS – Feature, Target, Prédiction

En apprentissage supervisé, une observation au temps t est représentée par un vecteur de variables $\mathbf{x}_t$. Le modèle apprend une fonction

$$\hat{y}_t = f_{\theta}(\mathbf{x}_t).$$

Les composantes de $\mathbf{x}_t$ sont les variables explicatives, ou *features*. La variable y_t est la cible, ou *target*. En trading, l'ordre temporel impose une contrainte supplémentaire : chaque feature doit être disponible au moment de la décision.

Supposons par exemple que l'on veuille prédire le signe du rendement de demain :

$$y_t = \mathbf{1}(r_{t+1} > 0).$$

La cible utilise le futur par définition ; c'est normal, car elle sert à apprendre. Mais aucune feature de $\mathbf{x}_t$ ne doit dépendre de r_{t+1} .

On pourrait construire :

$$\mathbf{x}_t = [r_t, r_{t-1}, \hat{\sigma}_{t,20}, \text{volume}_t, \text{spread}_t].$$

Toutes ces quantités sont observables au temps t , sous réserve d'une convention claire sur l'heure exacte de calcul.

ATTENTION – Le futur peut se cacher dans une transformation apparemment innocente

Une moyenne glissante centrée, une mise à l'échelle (*scaling*) calculée sur tout le jeu de données ou une colonne “next return” mal décalée peuvent faire entrer de l'information future dans les features. Le modèle semble alors excellent parce qu'il a accès à une information qui n'aurait pas été disponible au moment réel de la décision. Nous consacrerons un chapitre entier à ce problème.

1.11 Premier pont vers le Reinforcement Learning

Le trading ne sera pas seulement traité comme un problème de prédiction. Une stratégie doit également choisir une action et gérer les conséquences de cette action.

Plus tard, nous définirons un état s_t contenant les informations disponibles, une action a_t et une récompense. Pour l'instant, retenons simplement la chaîne :

$$\text{observer} \rightarrow \text{décider} \rightarrow \text{agir} \rightarrow \text{mesurer la conséquence}.$$

Un état de marché pourrait inclure les derniers rendements, la volatilité et la position courante. Une action pourrait être “vendre”, “neutre” ou “acheter”. Mais si les données de départ sont mal horodatées ou si le spread est ignoré, l'environnement RL lui-même sera faux. La qualité de cette représentation sera donc également déterminante lorsque nous aborderons le Deep Reinforcement Learning (DRL, apprentissage profond par renforcement).

1.12 Laboratoires numériques du chapitre

Le chapitre est prolongé par deux laboratoires numériques complémentaires. Ils utilisent le jeu de données pédagogique **TI_CH01_MARKET_V1**, entièrement synthétique et régénérable de manière déterministe. L'objectif n'est pas de recopier le texte du livre, mais de transformer les distinctions conceptuelles en expériences observables.

ATTENTION – Nature du jeu de données fourni

Le jeu **TI_CH01_MARKET_V1** ne représente aucune action, devise ou cryptomonnaie réelle. Il est construit pour permettre des expériences reproductibles hors ligne, notamment sur OHLCV, bid/ask, rendements, volatilité et contrôles de qualité.

Laboratoire 1 – Market Data, OHLCV & Microstructure

Le premier laboratoire part de la question : *que contient réellement une donnée de marché, et qu'a-t-on déjà perdu lorsque l'on observe une bougie ?* Il fait manipuler transactions et quotes simplifiées, bid/ask/mid, spread, anatomie d'une bougie, agrégation tick vers barres, perte d'information intra-période, gaps, volume et temporalités d'observation/décision.

Laboratoire 2 – Returns, Adjustments & Data Quality

Le second part de la question : *comment transformer une donnée brute en information statistiquement et économiquement légitime ?* Il met en scène un split traité d'abord volontairement de manière incorrecte, puis corrigé ; compare rendements simple et logarithmique ; construit volatilité et richesse ; injecte des défauts de données ; puis relie proprement données, features, target et premier vocabulaire de décision séquentielle.

À RETENIR – Une formule doit être comprise avant d'être automatisée

Dans les deux laboratoires, le code vient après la question et avant l'interprétation. Une cellule Python n'a de valeur pédagogique que si le lecteur sait quel objet elle calcule, pourquoi elle le calcule et ce qu'il ne faut pas conclure de sa sortie.

1.13 Point de vue ingénieur : le contrat de donnée

Avant même le contrat d'un modèle, un projet professionnel doit posséder un contrat de donnée. Il décrit ce que chaque champ signifie et quelles propriétés sont garanties.

TABLE 1.2 – Exemple minimal de contrat pour une table de marché.

Champ	Sémantique	Contrôle
timestamp	instant de référence en fuseau explicite	ordre croissant, unicité selon la clé
open/high/low/close	prix de la barre	cohérence OHLC, unité et devise
volume	volume de la période	type, unité, valeurs négatives interdites
bid/ask	meilleure cotation disponible	$\text{ask} \geq \text{bid}$
source	provenance du flux	version, API et documentation archivées

Dans un projet complet, ce type de contrat doit accompagner le pipeline de données afin de rendre explicites les hypothèses de qualité, de provenance et de disponibilité.

1.14 Ce que ce chapitre ne permet pas encore de conclure

Nous avons volontairement résisté à la tentation de prédire. Plusieurs questions restent ouvertes :

- le niveau de prix est-il stationnaire ?
- les rendements sont-ils autocorrélés ?
- le passé contient-il une information linéaire exploitable ?
- comment distinguer bruit blanc et structure temporelle ?
- la variance peut-elle être considérée constante ?

Ces questions seront traitées progressivement. Le chapitre 2 introduira la stationnarité, les fonctions d'autocorrélation (ACF) et d'autocorrélation partielle (PACF), le bruit blanc ainsi que les processus autorégressifs (AR) et de moyenne mobile (MA). Le chapitre 3 séparera ensuite la dynamique de la moyenne et celle de la volatilité.

1.15 Exercices

Niveau A – Comprendre

1. Expliquer pourquoi le dernier prix traité, le bid, l'ask et le mid-price peuvent différer au même instant.
2. Pour $O = 100$, $H = 104$, $L = 98$, $C = 102$, identifier le corps et les deux mèches. Proposer deux trajectoires intrapériodes différentes compatibles avec cette même barre.
3. Expliquer pourquoi $Close_t$ peut différer de $Open_{t+1}$ sans qu'il y ait nécessairement erreur de donnée.
4. Distinguer fréquence d'observation, fenêtre de features, horizon de prédiction et fréquence de

rebalancement.

5. Une action monte de 20% puis baisse de 20%. Revient-elle à son prix initial? Justifier par un calcul.
6. Pourquoi une barre quotidienne ne suffit-elle pas toujours pour simuler un ordre stop intra-journalier?
7. Donner deux raisons pour lesquelles une date absente d'une série n'est pas nécessairement une erreur.
8. Expliquer en une phrase la différence entre volatilité et direction.

Niveau B – Calcul

1. Pour $P_0 = 80$, $P_1 = 82$, $P_2 = 79$ et $P_3 = 83$, calculer les rendements simples et logarithmiques. Vérifier la composition sur toute la période.
2. Avec $Bid = 49,97$ et $Ask = 50,03$, calculer le spread absolu, le mid-price et le spread en points de base.
3. Une série de cinq rendements journaliers est $(1\%, -2\%, 0.5\%, 1.5\%, -1\%)$. Calculer la valeur finale d'un capital initial de 10 000 MAD sans frais.

Niveau C – Raisonnement

1. Un jeu de données contient une colonne de moyenne mobile calculée avec une fenêtre centrée de 21 jours. Peut-elle être utilisée pour une décision au jour t ? Argumenter.
2. Deux fournisseurs donnent des rendements différents pour la même action le jour d'un split. Proposer un protocole pour comprendre la divergence avant de choisir une source.
3. Pourquoi un "outlier" financier ne doit-il pas être supprimé uniquement parce qu'il dépasse trois écarts-types?

Niveau D – Programmation

1. Écrire une fonction `validate_ohlcv(df)` qui retourne un rapport de contrôle plutôt que d'interrompre immédiatement le programme.
2. Construire des rendements à 1, 5 et 20 jours. Comparer visuellement leurs distributions.
3. Calculer une volatilité glissante pour plusieurs fenêtres et commenter le compromis entre réactivité et stabilité.

Niveau E – Problème d'ingénieur

On vous remet deux fichiers : un actif coté uniquement les jours ouvrables et une cryptomonnaie cotée 7 jours sur 7. Vous souhaitez construire plus tard un modèle utilisant les deux. Concevoir, sans coder, une politique d'alignement temporel. Préciser ce que vous feriez des week-ends, des valeurs

manquantes et des fuseaux horaires. Indiquer les décisions qui doivent être documentées pour rendre l'expérience reproductible.

1.16 Mini-activité pratique : diagnostic d'une source de marché

Par groupes de deux, choisir une source de données publique documentée et licitement réutilisable et produire une fiche d'une page :


1. instrument et marché ;
2. période et fréquence ;
3. fuseau horaire ;
4. variables disponibles ;
5. politique d'ajustement des prix ;
6. trous ou valeurs manquantes ;
7. coût d'accès et limites de l'interface de programmation (API) ;
8. conditions de réutilisation ;
9. une figure de prix et une figure de rendements ;
10. trois risques de mauvaise interprétation.

Le but n'est pas de trouver "la meilleure interface de programmation (API)", mais d'apprendre à décrire un flux avant de l'utiliser.

1.17 Synthèse

Nous avons construit les objets qui serviront de base à tout l'ouvrage. Un marché produit des transactions et des cotations. Une barre OHLCV est une agrégation de cette activité. Le prix mesure un niveau, le rendement mesure une variation relative, et la volatilité mesure la dispersion des rendements autour de leur niveau moyen. Le spread rappelle qu'une exécution a un coût. Le temps, le calendrier et les ajustements ne sont pas des détails informatiques : ils déterminent le sens économique de la donnée.

Le message central du chapitre peut être résumé par la chaîne suivante :



À RETENIR – Sept idées à retenir

1. Le marché n'a pas un prix unique : bid, ask, transaction et mid-price sont des objets différents.
2. OHLCV est une compression d'information, pas le flux original.
3. Le temps et le calendrier sont constitutifs du problème.
4. Prix et rendement ne répondent pas à la même question.
5. Les rendements simples se composent multiplicativement ; les rendements log s'additionnent.
6. La volatilité peut changer dans le temps et deviendra un objet de modélisation.
7. Aucune sophistication en Machine Learning, Deep Learning ou Reinforcement Learning ne compense une donnée mal définie ou contenant le futur.

1.18 Lexique local FR–EN

Français	Anglais	Sens dans l'ouvrage
prix acheteur	bid price	meilleur prix auquel un acheteur est prêt à acheter
prix vendeur	ask price	meilleur prix auquel un vendeur est prêt à vendre
fourchette / écart bid-ask	bid-ask spread	$Ask - Bid$
prix milieu	mid-price	moyenne de bid et ask
prix d'ouverture	open	premier prix d'une barre
plus haut / plus bas	high / low	extrêmes d'une barre
prix de clôture	close	dernier prix d'une barre
volume	volume	quantité échangée selon convention du marché
rendement simple	simple return	variation relative $P_t/P_{t-1} - 1$
rendement logarithmique	log return	$\ln(P_t/P_{t-1})$
volatilité	volatility	dispersion des rendements
fenêtre glissante	rolling window	sous-échantillon mobile dans le temps
valeur manquante	missing value	observation absente
fuite d'information	data leakage	information non légitime dans les variables explicatives
biais d'anticipation	look-ahead bias	utilisation du futur pour simuler le passé
courbe de richesse	wealth curve	évolution composée d'un capital

1.19 Transition vers le chapitre 2

Nous savons maintenant construire une série de rendements et vérifier son intégrité. Mais nous ne savons pas encore si le passé contient une structure exploitable.

Supposons que l'on observe un rendement positif aujourd'hui. Cela augmente-t-il la probabilité d'un rendement positif demain ? Une grande variation est-elle suivie d'une autre grande variation ? Une série qui semble monter est-elle réellement stable autour d'une tendance, ou possède-t-elle une racine unitaire ?

Pour répondre proprement, nous devons abandonner l'impression visuelle et introduire des concepts statistiques précis : **stationnarité, bruit blanc, autocorrélation et autocorrélation partielle**. Nous verrons alors comment ces notions conduisent naturellement aux premiers modèles autorégressifs et de moyenne mobile. Ce sera l'objet du chapitre 2.

Bibliographie

- [1] R. S. Tsay, *Analysis of Financial Time Series*, 3rd ed., Wiley, 2010.
- [2] R. Cont, “Empirical properties of asset returns : stylized facts and statistical issues”, *Quantitative Finance*, vol. 1, no. 2, pp. 223–236, 2001.
- [3] L. Harris, *Trading and Exchanges : Market Microstructure for Practitioners*, Oxford University Press, 2003.
- [4] J. Hasbrouck, *Empirical Market Microstructure : The Institutions, Economics, and Econometrics of Securities Trading*, Oxford University Press, 2007.
- [5] E. P. Chan, *Algorithmic Trading : Winning Strategies and Their Rationale*, Wiley, 2013.
- [6] Plotly, *Sample Datasets*, dépôt GitHub `plotly/datasets`, jeu `finance-charts-apple.csv`, consulté en septembre 2026. Dépôt distribué sous licence MIT.