

TRADING INTELLIGENT

CH02 – Fiche de référence

Formules, définitions et diagnostics essentiels

Dépendance temporelle – Stationnarité – AR – MA – ARIMA – Prédiction

Pr. Tawfik Masrour – complément du CH02 v2.2

Comment utiliser cette fiche

Ce document est un **formulaire de référence**, pas un substitut au cours. Pour chaque objet, distinguer : **définition mathématique**, **hypothèses**, **interprétation** et **limites**. Une formule correcte hors de ses hypothèses peut conduire à une conclusion incorrecte.

1. Rappels probabilistes et statistiques

Espérance : moyenne théorique pondérée par les probabilités

Soit une variable aléatoire réelle X . Son espérance existe au sens usuel si $\mathbb{E}[|X|] < \infty$. C'est la **moyenne théorique de ses valeurs, pondérées par leur probabilité**.

Définition générale :

$$\mathbb{E}[X] = \int x \, dP_X(x),$$

où P_X est la loi de X .

Cas discret. Si X prend les valeurs x_i avec $p_i = P(X = x_i)$, $p_i \geq 0$ et $\sum_i p_i = 1$:

$$\mathbb{E}[X] = \sum_i x_i p_i$$

Cas continu. Si X admet une densité f_X :

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x f_X(x) \, dx$$

Interprétation

L'espérance est un **centre de gravité probabiliste**. Une valeur deux fois plus probable reçoit deux fois plus de poids. Elle n'est ni nécessairement une valeur effectivement observée, ni la valeur la plus probable.

Exemple discret : si $P(X = -1) = 0.75$ et $P(X = 2) = 0.25$, alors

$$\mathbb{E}[X] = (-1)(0.75) + (2)(0.25) = -0.25.$$

Moyenne empirique. Pour des observations $x_1, \dots, x_n$:

$$\bar{x} = \frac{1}{n} \sum_{t=1}^n x_t$$

$\bar{x}$ est calculée sur les **données observées**; $\mu = \mathbb{E}[X]$ est un paramètre de la **loi**. Sous des conditions appropriées (par exemple i.i.d., ou dépendance temporelle suffisamment régulière/ergodique), $\bar{x}$ estime μ .

Ne pas confondre

$\mathbb{E}[X]$ est une moyenne **probabiliste théorique**; $\bar{x}$ est une moyenne **empirique**. Dans une série temporelle dépendante, la stationnarité seule ne suffit pas à justifier toutes les propriétés d'estimation de $\bar{x}$.

Variance et écart-type

Si $\mathbb{E}[X^2] < \infty$, la variance mesure la dispersion quadratique autour de $\mu = \mathbb{E}[X]$:

$$\text{Var}(X) = \mathbb{E}[(X - \mu)^2] = \mathbb{E}[X^2] - \mu^2.$$

Cas discret :

$$\text{Var}(X) = \sum_i (x_i - \mu)^2 p_i.$$

Cas continu :

$$\text{Var}(X) = \int (x - \mu)^2 f_X(x) \, dx.$$

Écart-type :

$$\sigma = \sqrt{\text{Var}(X)}$$

La variance est dans l'unité au carré; l'écart-type revient dans l'unité de X .

Sur un échantillon. Deux quantités sont courantes :

$$s_n^2 = \frac{1}{n} \sum_{t=1}^n (x_t - \bar{x})^2$$

(variance descriptive des valeurs observées), et

$$s^2 = \frac{1}{n-1} \sum_{t=1}^n (x_t - \bar{x})^2$$

(estimation sans biais de σ^2 dans le cadre i.i.d. classique). Le facteur $n-1$ ne « corrige » pas une dépendance temporelle; l'inférence sous dépendance demande des hypothèses supplémentaires.

Covariance et corrélation

Si les seconds moments existent :

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mu_X)(Y - \mu_Y)].$$

Si $\sigma_X > 0$ et $\sigma_Y > 0$:

$$\text{Corr}(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}$$

avec $-1 \leq \text{Corr}(X, Y) \leq 1$.

Sens

Covariance > 0 : variations linéaires dans le même sens.
Covariance < 0 : sens opposés.
Corrélation : covariance standardisée, sans unité.
Corrélation nulle n'implique pas indépendance en général.

2. Processus, série temporelle, lag, information

Un **processus stochastique** est une famille de variables aléatoires $\{X_t\}_{t \in \mathcal{T}}$. Une **série temporelle observée** $x_1, \dots, x_n$ est une réalisation de ce processus.

Lag k : pour $k \geq 0$, X_{t-k} est la variable située k périodes avant t .

$$\text{lag } k : X_{t-k}$$

Opérateur retard L :

$$LX_t = X_{t-1}, \quad L^k X_t = X_{t-k}.$$

Information passée : $\mathcal{F}_{t-1}$ représente l'information disponible avant d'observer X_t .

Innovation ε_t : composante nouvelle de X_t qui n'était pas prévisible à partir de $\mathcal{F}_{t-1}$ dans le modèle considéré ; typiquement

$$\mathbb{E}[\varepsilon_t | \mathcal{F}_{t-1}] = 0.$$

Schéma mental

$$X_t = \underbrace{\mathbb{E}[X_t | \mathcal{F}_{t-1}]}_{\text{partie prévisible}} + \underbrace{\varepsilon_t}_{\text{innovation}}.$$

3. Stationnarité : quantificateurs à connaître

Stationnarité stricte

Le processus $\{X_t\}$ est strictement stationnaire si, pour **tout** entier $m \geq 1$, pour **toutes** dates $t_1, \dots, t_m$ et pour **tout** décalage h admissible :

$$(X_{t_1}, \dots, X_{t_m}) \stackrel{d}{=} (X_{t_1+h}, \dots, X_{t_m+h})$$

Autrement dit, **toutes les lois jointes** sont invariantes par translation du temps.

Stationnarité faible (d'ordre 2)

On suppose d'abord $\mathbb{E}[X_t^2] < \infty$ pour tout t . Le processus est faiblement stationnaire si les trois propriétés suivantes valent **pour tout** t et **pour tout lag entier** k admissible :

$$\mathbb{E}[X_t] = \mu \quad (\text{indépendant de } t)$$

$$\text{Var}(X_t) = \sigma^2 < \infty \quad (\text{indépendante de } t)$$

$$\text{Cov}(X_t, X_{t-k}) = \gamma(k)$$

La troisième condition signifie que la covariance dépend **uniquement de l'écart temporel** k , jamais de la date absolue t .

Forme équivalente, pour toutes dates s, t :

$$\text{Cov}(X_s, X_t) = \gamma(t - s).$$

Pour un processus réel, $\gamma(-k) = \gamma(k)$.

Quantificateur essentiel

Il ne suffit pas qu'il *existe* un lag k pour lequel la covariance est stable. La propriété doit tenir **pour tous les lags** considérés et pour toutes les dates où ces lags sont définis.

À retenir

Stationnaire ne signifie pas « plat ». Une série peut fluctuer fortement tout en gardant, au sens probabiliste, une moyenne, une variance et une structure d'autocovariance invariantes dans le temps.

4. Bruit blanc et marche aléatoire

Bruit blanc faible

Un processus $\{\varepsilon_t\}$ est un bruit blanc faible de variance σ_ε^2 si, **pour tout** t :

$$\mathbb{E}[\varepsilon_t] = 0, \quad \text{Var}(\varepsilon_t) = \sigma_\varepsilon^2 < \infty,$$

et, **pour tout** $k \neq 0$:

$$\text{Cov}(\varepsilon_t, \varepsilon_{t-k}) = 0$$

Bruit blanc i.i.d. : hypothèse plus forte, les ε_t sont indépendantes et de même loi.

Bruit blanc gaussien : cas où les innovations sont en plus gaussiennes.

Deux implications fausses en général

non autocorrélé $\nRightarrow$ indépendant

bruit blanc faible $\nRightarrow$ gaussien

Marche aléatoire

Sans dérive :

$$X_t = X_{t-1} + \varepsilon_t$$

Donc, par itération :

$$X_t = X_0 + \sum_{j=1}^t \varepsilon_j.$$

Si X_0 est constant et les innovations sont non corrélées de variance σ_ε^2 :

$$\text{Var}(X_t) = t\sigma_\varepsilon^2$$

Si X_0 est aléatoire et indépendant des innovations :

$$\text{Var}(X_t) = \text{Var}(X_0) + t\sigma_\varepsilon^2.$$

La variance croît avec t : le niveau n'est pas faiblement stationnaire. Un choc est accumulé et modifie durablement le niveau futur.

5. Autocovariance, ACF et PACF

Pour un processus faiblement stationnaire : **Autocovariance au lag** k :

$$\gamma(k) = \text{Cov}(X_t, X_{t-k})$$

Elle est bien définie indépendamment de t grâce à la stationnarité faible ; $\gamma(0) = \text{Var}(X_t) = \sigma^2$.

ACF théorique :

$$\rho(k) = \frac{\gamma(k)}{\gamma(0)}$$

avec $\rho(0) = 1$, $|\rho(k)| \leq 1$, et $\rho(-k) = \rho(k)$ pour un processus réel.

ACF empirique :

$$\hat{\rho}(k) = \frac{\sum_{t=k+1}^n (x_t - \bar{x})(x_{t-k} - \bar{x})}{\sum_{t=1}^n (x_t - \bar{x})^2}.$$

Sous des hypothèses de bruit blanc et pour une première lecture :

$$\pm \frac{1.96}{\sqrt{n}}$$

Bandes approximatives. Elles ne constituent ni une preuve d'indépendance ni une règle automatique de choix d'ordre.

PACF au lag k . C'est la corrélation linéaire « directe » entre X_t et X_{t-k} après élimination de l'effet linéaire de $X_{t-1}, \dots, X_{t-k+1}$. Équivalamment, dans une projection linéaire de X_t sur ses k derniers lags, la PACF au lag k est liée au coefficient du lag le plus éloigné.

ACF vs PACF

ACF : dépendance linéaire totale au lag k (directe + transmise).

PACF : dépendance linéaire restant au lag k après contrôle des lags intermédiaires.

6. Modèles AR : mémoire des valeurs

AR(1)

Sous la convention

$$X_t = c + \phi X_{t-1} + \varepsilon_t$$

où $\{\varepsilon_t\}$ est un bruit blanc de variance σ_ε^2 .

Si $|\phi| < 1$, il existe une solution causale faiblement stationnaire. Sa moyenne est :

$$\mu = \frac{c}{1 - \phi}$$

Écriture centrée :

$$X_t - \mu = \phi(X_{t-1} - \mu) + \varepsilon_t.$$

Variance :

$$\text{Var}(X_t) = \frac{\sigma_\varepsilon^2}{1 - \phi^2}$$

ACF :

$$\rho(k) = \phi^{|k|}$$

Effet de ϕ

$\phi \approx 0$: mémoire faible.
 $0 < \phi < 1$: persistance positive.
 $-1 < \phi < 0$: alternance/oscillation.
 $|\phi| \approx 1$: très forte persistance ; la frontière $|\phi| = 1$ est non stationnaire.

AR(p)

$$X_t = c + \sum_{i=1}^p \phi_i X_{t-i} + \varepsilon_t$$

Le nombre p est le **plus grand lag autorégressif inclus**.

Polynôme AR :

$$\phi(z) = 1 - \phi_1 z - \dots - \phi_p z^p.$$

Condition standard de causalité/stationnarité :

$$\phi(z) = 0 \Rightarrow |z| > 1$$

Si la solution est stationnaire et $1 - \sum_{i=1}^p \phi_i \neq 0$:

$$\mu = \frac{c}{1 - \sum_{i=1}^p \phi_i}.$$

Signature théorique idéale : PACF coupée après p , ACF décroissante. Sur données finies, ce n'est qu'un diagnostic.

7. Modèles MA et ARMA : mémoire des chocs

MA(1)

$$X_t = \mu + \varepsilon_t + \theta \varepsilon_{t-1}$$

Avec un bruit blanc de variance finie, un MA(1) est **stationnaire pour toute valeur finie de θ** . La condition

$$|\theta| < 1$$

concerne l'**invertibilité** sous cette convention de signe : elle assure une représentation unique et stable des innovations à partir des observations.

MA(q)

$$X_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}.$$

La mémoire des innovations est finie : l'ACF théorique est nulle au-delà du lag q . L'invertibilité exige que les racines du polynôme MA soient à l'extérieur du cercle unité.

ARMA(p,q)

$$X_t = c + \sum_{i=1}^p \phi_i X_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}.$$

Stationnarité/causalité : condition sur les racines AR.

Invertibilité : condition sur les racines MA.

Mémo conceptuel

AR = mémoire des valeurs observées

MA = mémoire des innovations/chocs

Signatures idéales ACF/PACF

Modèle	ACF	PACF
AR(p)	décroît	coupure après p
MA(q)	coupure après q	décroît
ARMA	décroît	décroît

« Coupure » et « décroissance » sont des signatures théoriques. Bruit d'échantillonnage, saisonnalité, ruptures, paramètres proches des frontières ou non-stationnarité peuvent les brouiller.

8. Différenciation, intégration et racine unitaire

Première différence :

$$\Delta X_t = X_t - X_{t-1} = (1 - L)X_t$$

Pour une marche aléatoire :

$$X_t = X_{t-1} + \varepsilon_t \Rightarrow \Delta X_t = \varepsilon_t.$$

Série intégrée $I(d)$. Le nombre $d \geq 0$ est le **plus petit entier** tel que

$$\Delta^d X_t = (1 - L)^d X_t \text{ soit stationnaire}$$

Ainsi $I(0)$ signifie stationnaire en niveau ; $I(1)$ signifie qu'une première différence suffit, mais pas zéro différence.

Sur-différenciation

Différencier une série déjà stationnaire peut introduire une structure MA artificielle et amplifier le bruit. La différenciation transforme la dynamique ; ce n'est pas un nettoyage neutre.

9. Tendance déterministe vs racine unitaire

Stationnaire autour d'une tendance :

$$X_t = a + bt + u_t, \quad u_t \text{ stationnaire}$$

Après retrait de $a + bt$, on retrouve un processus stationnaire ; les chocs autour de la tendance sont transitoires.

Marche aléatoire avec dérive :

$$X_t = X_{t-1} + \delta + \varepsilon_t$$

La tendance moyenne provient ici de l'accumulation d'une dérive et des innovations ; les chocs sur le niveau sont permanents.

10. ARIMA(p,d,q)

ARIMA = *Autoregressive Integrated Moving Average*. Le principe : différencier d fois, puis modéliser la série différenciée par un ARMA(p, q).

- p : ordre AR de la série différenciée ;
- d : nombre de différenciations ;
- q : ordre MA de la série différenciée.

Avec

$$\phi(L) = 1 - \phi_1 L - \dots - \phi_p L^p, \quad \theta(L) = 1 + \theta_1 L + \dots + \theta_q L^q,$$

on écrit schématiquement :

$$\phi(L)(1-L)^d X_t = c + \theta(L)\varepsilon_t$$

Selon les logiciels et la valeur de d , l'interprétation du terme constant/tendance dépend de la paramétrisation. Toujours lire la convention utilisée.

Déchiffrage

ARIMA(1,0,0)=AR(1).
 ARIMA(0,0,1)=MA(1).
 ARIMA(1,0,1)=ARMA(1,1).
 ARIMA(0,1,0)=marche aléatoire sans dérive dans cette écriture simple.
 ARIMA(1,1,1)=ARMA(1,1) appliqué à la première différencence.

11. Tests ADF, PP et KPSS

ADF – Augmented Dickey–Fuller

Forme pédagogique :

$$\Delta X_t = \alpha + \beta t + \gamma X_{t-1} + \sum_{i=1}^r \delta_i \Delta X_{t-i} + u_t.$$

Dans cette écriture :

$$H_0 : \gamma = 0 \iff \text{racine unitaire}$$

L'alternative dépend des termes déterministes inclus : stationnarité autour de zéro, d'une constante, ou d'une tendance selon la spécification.

Petite p -value $\Rightarrow$ rejet de H_0 .

Grande p -value $\Rightarrow$ **on ne rejette pas** H_0 ; cela ne prouve pas que H_0 est vraie.

PP – Phillips–Perron

$$H_0 : \text{racine unitaire}$$

Même hypothèse nulle générale que l'ADF, mais correction non paramétrique de certaines formes de dépendance sérielle et d'hétéroscédasticité des erreurs.

KPSS

La logique est inversée :

$$H_0 : \text{stationnarité}$$

Selon la spécification : stationnarité autour d'un niveau (c) ou d'une tendance déterministe (ct).

Test	H_0	Petite p -value
ADF	racine unitaire	rejet de la racine unitaire
PP	racine unitaire	rejet de la racine unitaire
KPSS	stationnarité	rejet de la stationnarité

Spécification = partie du test

Tester avec constante seule et tester avec constante + tendance ne répondent pas exactement à la même question. Une série stationnaire autour d'une tendance déterministe n'est pas une série à racine unitaire.

Bornes de p-values

Si une implémentation KPSS renvoie une borne issue de sa table, écrire honnêtement

$$p \geq 0.10 \quad \text{ou} \quad p \leq 0.01,$$

et non une fausse valeur exacte. Une très petite p -value ADF doit être écrite en notation scientifique ou sous forme d'inégalité, jamais comme une probabilité « exactement nulle ».

12. Résidus et Ljung–Box

Résidu d'une observation ajustée/prévue :

$$\hat{\varepsilon}_t = X_t - \hat{X}_t$$

Après ajustement d'un modèle de moyenne, on cherche notamment à vérifier qu'il ne reste pas de dépendance linéaire globale exploitable dans les résidus.

Le statisticien de Ljung–Box au lag maximal m utilise les autocorrélations résiduelles :

$$Q(m) = n(n+2) \sum_{k=1}^m \frac{\hat{\rho}_k^2}{n-k}.$$

Hypothèse nulle :

$$H_0 : \rho_1 = \rho_2 = \dots = \rho_m = 0$$

Pour un ARIMA(p, d, q), certains logiciels permettent une correction du nombre de degrés de liberté via

$$\text{model_df} = p + q$$

Interprétation correcte

Une grande p -value signifie seulement que le test ne détecte pas d'autocorrélation globale significative jusqu'au lag m compte tenu de sa puissance et de sa spécification. Elle ne prouve ni indépendance, ni gaussianité, ni bon modèle à tous égards.

13. AIC et BIC

Pour une vraisemblance maximisée L , un modèle ayant k paramètres estimés et n observations :

$$\text{AIC} = -2 \log L + 2k$$

$$\text{BIC} = -2 \log L + k \log n$$

Comment comparer

À données, variable expliquée et convention de vraisemblance comparables, **plus petit est meilleur parmi les modèles candidats**. Ce sont des critères relatifs, pas des mesures absolues de qualité.

Règle centrale

$$\text{AIC/BIC} \neq \text{performance hors échantillon}$$

Un meilleur critère in-sample ne garantit pas un meilleur forecast futur.

14. Prévision temporelle

Prévision ponctuelle

Sous une perte quadratique, la prévision optimale conditionnelle est la moyenne conditionnelle :

$$\hat{X}_{t+h|t} = \mathbb{E}[X_{t+h} | \mathcal{F}_t]$$

Origine fixe, multi-pas

À la date T , le modèle est estimé une seule fois puis on calcule

$$\hat{y}_{T+1|T}, \hat{y}_{T+2|T}, \dots, \hat{y}_{T+h|T}.$$

À distinguer du *walk-forward*, où l'origine de prévision avance à mesure que de nouvelles observations deviennent disponibles et où le modèle peut être mis à jour/réestimé.

Intervalle de prévision

Un intervalle annoncé à 95% est conditionnel au modèle, à ses paramètres estimés et à ses hypothèses probabilistes. Il vise une **couverture répétée** de 95% sous ces conditions ; ce n'est pas une garantie universelle sur une réalisation particulière.

15. Baselines de prévision

Persistance

$$\hat{y}_{T+h}^{\text{pers}} = y_T$$

Elle suppose que le meilleur niveau futur reste le dernier niveau observé.

Drift

Dérive moyenne estimée sur le train :

$$\hat{\delta} = \frac{y_T - y_1}{T - 1}$$

Puis

$$\hat{y}_{T+h}^{\text{drift}} = y_T + h\hat{\delta}$$

Principe expérimental

Toute méthode sophistiquée doit être comparée à **plusieurs baselines raisonnables**, calculées sans fuite future et évaluées sur exactement les mêmes dates de test.

16. Erreurs de prévision

Pour h observations de test, avec erreurs $e_j = y_{T+j} - \hat{y}_{T+j}$:

MAE :

$$\text{MAE} = \frac{1}{h} \sum_{j=1}^h |e_j|$$

Interprétable dans l'unité de la série ; chaque erreur compte linéairement.

RMSE :

$$\text{RMSE} = \sqrt{\frac{1}{h} \sum_{j=1}^h e_j^2}$$

Même unité que la série, mais les grandes erreurs reçoivent un poids quadratique plus important.

Comparer correctement

MAE/RMSE de deux modèles ne sont directement comparables que s'ils portent sur la même variable, la même transformation, le même horizon/protocole et les mêmes observations de test.

17. Moyenne et variance conditionnelles

Avec $\mathcal{F}_{t-1}$ l'information disponible avant t :

$$m_t = \mathbb{E}[X_t | \mathcal{F}_{t-1}]$$

mesure la composante prévisible de la **moyenne** conditionnelle.

La variance conditionnelle est :

$$h_t = \text{Var}(X_t | \mathcal{F}_{t-1})$$

Elle mesure l'incertitude restante sachant le passé.

Pont vers CH03

ARMA/ARIMA structurent surtout m_t . En finance, h_t peut varier fortement même lorsque les résidus sont peu autocorrélés ; des autocorrélations des carrés $\hat{\varepsilon}_t^2$ suggèrent alors une dynamique de volatilité de type ARCH/GARCH.

18. Tableau de lecture rapide

Si je vois...	Je pense à...
$\mathbb{E}[X]$	moyenne théorique pondérée par la loi
$\bar{x}$	moyenne empirique des observations
X_{t-k}	lag k
$\gamma(k)$	autocovariance au lag k
$\rho(k)$	autocorrélation au lag k
$\text{AR}(p)$	p lags de valeurs
$\text{MA}(q)$	q lags d'innovations
$I(d)$	ordre minimal de différenciation
ADF / PP	H_0 : racine unitaire
KPSS	H_0 : stationnarité
Ljung-Box	autocorrélations résiduelles conjointes
AIC / BIC	compromis ajustement-complexité
MAE / RMSE	erreur de prévision hors échantillon

19. Formules à retrouver instantanément

- $\mathbb{E}[X] = \sum_i x_i p_i$ (discret) ou $\int x f_X(x) dx$ (continu).
- $\text{Var}(X) = \mathbb{E}[(X - \mu)^2] = \mathbb{E}[X^2] - \mu^2$.
- $\gamma(k) = \text{Cov}(X_t, X_{t-k})$ pour tout lag k sous stationnarité faible.
- $\rho(k) = \gamma(k)/\gamma(0)$.
- $X_t = c + \phi X_{t-1} + \varepsilon_t$ et $|\phi| < 1$ pour AR(1) stationnaire.
- $\text{Var}(X_t) = \sigma_\varepsilon^2 / (1 - \phi^2)$ pour AR(1) stationnaire.
- $X_t = \mu + \varepsilon_t + \theta \varepsilon_{t-1}$ pour MA(1).
- $\Delta X_t = (1 - L)X_t$.
- $\phi(L)(1 - L)^d X_t = c + \theta(L)\varepsilon_t$ pour ARIMA.
- $\text{AIC} = -2 \log L + 2k$, $\text{BIC} = -2 \log L + k \log n$.
- $\hat{y}_{T+h}^{\text{pers}} = y_T$ et $\hat{y}_{T+h}^{\text{drift}} = y_T + h\hat{\delta}$.
- MAE et RMSE doivent être évaluées sur le même protocole de test.

20. Pièges conceptuels à éviter

1. Espérance $\neq$ moyenne empirique

L'une appartient à la loi ; l'autre est calculée sur un échantillon.

2. Stationnarité faible : « pour tout lag »

La covariance doit dépendre uniquement du lag pour tous les couples de dates admissibles, pas seulement pour quelques lags observés.

3. MA stationnaire $\neq$ MA invertible

Un $\text{MA}(q)$ fini avec bruit blanc est stationnaire ; l'invertibilité est une condition distincte d'identification/représentation.

4. ACF/PACF $\neq$ empreintes magiques

Elles suggèrent des structures plausibles ; elles ne remplacent ni estimation, ni diagnostic, ni validation hors échantillon.

5. Grande p-value $\neq$ preuve de H_0

On dit « on ne rejette pas H_0 », jamais « H_0 est prouvée ».

6. Différencier $\neq$ nettoyer

La transformation modifie la dynamique et peut surdifférencier.

7. AIC/BIC $\neq$ forecast futur

Les critères in-sample ne remplacent jamais l'évaluation hors échantillon et les baselines.

8. Bon ARIMA $\neq$ bonne stratégie de trading

Une prévision statistiquement correcte peut être trop faible après coûts, latence, contraintes de risque ou inadéquation à l'objectif économique.

21. Les quatre phrases à mémoriser**Mémoire**

AR = mémoire des valeurs.

MA = mémoire des chocs.

ARIMA = différenciation + ARMA.

Diagnostic in-sample $\neq$ performance future.

22. Mini-checklist de maîtrise

- Je sais distinguer espérance théorique, moyenne empirique et moyenne conditionnelle.
- Je peux énoncer la stationnarité faible avec les mots « pour tout t » et « pour tout lag k ».
- Je distingue bruit blanc faible, bruit blanc i.i.d. et bruit blanc gaussien.
- Je distingue ACF et PACF et connais leurs limites d'identification.
- Je sais distinguer stationnarité d'un MA(q) et invertibilité.
- Je sais lire p, d, q dans ARIMA(p, d, q).
- Je n'inverse pas les hypothèses nulles ADF/PP et KPSS.
- Je sais ce qu'une grande p -value Ljung–Box permet – et ne permet pas – de conclure.
- Je distingue prévision à origine fixe et walk-forward.
- Je compare toujours un modèle à plusieurs baselines raisonnables sur les mêmes données de test.

Principe final

Une formule n'est maîtrisée que si l'on sait **ce qu'elle définit ou mesure, pour quels objets et sous quelles hypothèses elle est valide, comment l'interpréter et ce qu'elle ne permet pas de conclure.**