
TRADING INTELLIGENT

Économétrie financière, Machine Learning, Time Series, Deep Learning
et Reinforcement Learning pour la décision de marché

CHAPITRE 2

Comprendre la dépendance temporelle

Stationnarité, AR, MA et ARIMA

Question directrice : comment distinguer une mémoire statistique exploitable d'une simple dérive du niveau, puis transformer ce diagnostic en une prévision réellement vérifiable hors échantillon ?

Tawfik Masrour

Version 2.2 – octobre 2026

Comment utiliser ce chapitre

Le chapitre précédent a établi une distinction essentielle entre prix, rendement, volatilité, signal, position et résultat financier. Nous pouvons maintenant poser une question plus fine : lorsque deux observations successives se ressemblent, cette ressemblance traduit-elle une véritable dépendance temporelle, une tendance, une racine unitaire, ou seulement le hasard ?

Ce chapitre suit une progression volontairement causale : **voir la dépendance, stabiliser la série, identifier un mécanisme, estimer, diagnostiquer**, puis seulement **prévoir**. ARIMA apparaît ainsi comme l'aboutissement d'une chaîne de raisonnement, et non comme une commande logicielle à appliquer mécaniquement.

À RETENIR – Objectifs de maîtrise

À la fin du chapitre, vous devez être capable de :

- distinguer bruit blanc, processus stationnaire, tendance déterministe et racine unitaire ;
- interpréter correctement ACF et PACF sans les transformer en règles de reconnaissance automatiques ;
- relier AR, MA, ARMA et ARIMA à des mécanismes de mémoire différents ;
- lire conjointement ADF, PP et KPSS, en tenant compte de leur spécification ;
- choisir des modèles candidats avec parcimonie, puis contrôler leurs résidus avec notamment Ljung–Box ;
- évaluer une prévision à origine fixe sur des données futures, face à plusieurs baselines raisonnables, sans fuite temporelle.

ATTENTION – Règle de méthode

Une bonne prévision temporelle n'est jamais prouvée par la qualité d'ajustement sur les données utilisées pour estimer le modèle. Toute conclusion de performance doit être obtenue sur des observations chronologiquement postérieures à l'entraînement et interprétée face à des baselines adaptées au problème.

Table des matières

2	Comprendre la dépendance temporelle	1
2.1	Pourquoi le temps change la nature du problème	1
2.2	Stationnarité : chercher une structure qui ne se déplace pas sous nos pieds	3
2.3	Bruit blanc et marche aléatoire : deux références à ne pas confondre	4
2.4	Autocovariance et autocorrélation : mesurer la mémoire	6
2.5	Le modèle AR(1) : quand la valeur actuelle hérite du passé	6
2.6	Le modèle MA : quand les chocs récents laissent une trace finie	8
2.7	ACF et PACF : deux vues complémentaires de la dépendance	9
2.8	ARMA : combiner persistance et mémoire des chocs	11
2.9	Différenciation et racine unitaire : rendre le niveau modélisable	11
2.10	Tests de stationnarité : ADF, PP et KPSS	13
2.11	ARIMA : ARMA appliqué à une série rendue stationnaire	15
2.12	La démarche Box–Jenkins : un cycle de diagnostic	16
2.13	Choisir entre plusieurs modèles : AIC et BIC	17
2.14	Résidus : le modèle a-t-il réellement extrait la mémoire ?	18
2.15	Prévision : une valeur centrale et une incertitude	19
2.16	Évaluer une prévision sans regarder le futur	20
2.17	Pourquoi ARIMA est important en trading même lorsqu’il ne gagne pas	22
2.18	Première limite : la variance peut elle-même évoluer	22
2.19	Laboratoires numériques associés	23
2.20	Exemple guidé : diagnostiquer une série inconnue	23
2.21	Exercices	23
2.22	Checklist de maîtrise	25
2.23	Synthèse	25

Comprendre la dépendance temporelle

Stationnarité, AR, MA et ARIMA

QUESTION DIRECTRICE – Le passé contient-il réellement de l'information sur le futur ?

Deux valeurs proches dans le temps peuvent se ressembler pour plusieurs raisons : mémoire du processus, inertie économique, tendance, saisonnalité, changement lent de niveau ou simple hasard. La modélisation temporelle consiste d'abord à séparer ces mécanismes. Un modèle ARIMA n'est pas une formule magique de prévision : c'est une manière rigoureuse de représenter certaines formes de dépendance après avoir traité la non-stationnarité.

RAPPEL JUSTE À TEMPS – Pont avec le chapitre 1

Dans CH01, nous avons appris qu'un prix, un rendement et une volatilité ne racontent pas la même chose. Ici, cette distinction devient opérationnelle : les **niveaux de prix** sont souvent très persistants et potentiellement non stationnaires, alors que les **rendements** sont généralement plus proches d'une série stationnaire en moyenne mais peuvent garder une dépendance dans leur variance. Choisir la variable à modéliser fait donc partie du diagnostic, avant même de choisir ARIMA.

2.1 Pourquoi le temps change la nature du problème

Dans un problème statistique tabulaire, une observation est souvent traitée comme une ligne indépendante des autres. Dans une série temporelle, l'ordre est constitutif de l'information : la valeur observée hier peut influencer celle d'aujourd'hui, et la valeur de demain n'était évidemment pas disponible lorsque la décision d'aujourd'hui a été prise.

Considérons une suite d'observations

$$X_1, X_2, \dots, X_t, \dots$$

prises à intervalles réguliers. La première question n'est pas encore « quel modèle utiliser ? », mais plutôt :

comment la distribution de X_t dépend-elle de son propre passé ?

Cette question conduit à trois objets fondamentaux : le **retard temporel**, la **stationnarité** et la **corrélation sérielle**.

DÉFINITION – Retard ou lag

Le *lag* k d'une série est sa valeur décalée de k périodes. Au temps t , le premier retard est X_{t-1} , le deuxième X_{t-2} , etc. Le mot anglais *lag* est extrêmement courant en économétrie et en apprentissage automatique sur séries temporelles.




FIGURE 2.1 – Une série et son premier retard : le décalage rend visible la notion de mémoire temporelle.

EXEMPLE – Construire une variable retardée

Si les rendements journaliers sont $r_1 = 1\%$, $r_2 = -0,5\%$, $r_3 = 0,8\%$ et $r_4 = 0,2\%$, alors pour prédire r_4 , la variable retardée d'ordre 1 vaut $r_3 = 0,8\%$ et celle d'ordre 2 vaut $r_2 = -0,5\%$. Cette construction paraît élémentaire, mais elle réapparaîtra plus tard sous le nom de *feature engineering temporel* en Machine Learning.

2.1.1 Processus stochastique, réalisation et innovation

Un **processus stochastique** est une famille de variables aléatoires indexées par le temps :

$$\{X_t\}_{t \in \mathcal{T}}.$$

Une série effectivement observée est une **réalisation** ou trajectoire de ce processus. Nous ne voyons donc qu'un chemin parmi tous ceux qui auraient pu être produits.

Un terme que nous utiliserons constamment est celui d'**innovation**. Une innovation ε_t représente l'information nouvelle arrivant au temps t et qui n'était pas prévisible à partir du passé dans le modèle considéré. Dans le cas le plus simple, on la modélise comme un bruit blanc.

INTUITION – Le modèle sépare mémoire et nouveauté

Une représentation temporelle cherche souvent à écrire

$$\text{valeur actuelle} = \text{partie expliquée par le passé} + \text{innovation nouvelle}.$$

L'enjeu n'est pas d'éliminer le hasard, mais de distinguer ce qui possède une structure répétable de ce qui reste imprévisible.

2.2 Stationnarité : chercher une structure qui ne se déplace pas sous nos pieds

La stationnarité joue un rôle central parce qu'elle rend possible l'apprentissage à partir du passé. Si la relation statistique change complètement au fil du temps, une moyenne ou une autocorrélation estimée hier peut ne plus décrire demain.

2.2.1 Stationnarité stricte et stationnarité faible

La **stationnarité stricte** exige que la loi jointe de tout ensemble d'observations soit inchangée par translation dans le temps. Pour tout k , tous instants $t_1, \dots, t_k$ et tout décalage h ,

$$(X_{t_1}, \dots, X_{t_k}) \stackrel{d}{=} (X_{t_1+h}, \dots, X_{t_k+h}).$$

Cette définition est élégante mais souvent trop exigeante pour la pratique.

On utilise donc très fréquemment la **stationnarité faible**, également appelée stationnarité de second ordre ou stationnarité en covariance. Elle demande trois propriétés :

1. une moyenne constante : $\mathbb{E}[X_t] = \mu$;
2. une variance finie et constante : $\text{Var}(X_t) = \sigma^2$;
3. une covariance qui dépend du retard k , et non de la date absolue :

$$\text{Cov}(X_t, X_{t-k}) = \gamma(k).$$




FIGURE 2.2 – Une trajectoire stationnaire et une marche aléatoire : deux comportements très différents malgré des mouvements locaux parfois similaires.

EXEMPLE – Ce que signifie « moyenne stable »

Une série stationnaire peut connaître des excursions importantes au-dessus ou au-dessous de sa moyenne. La stationnarité ne signifie donc pas que la série est plate. Elle signifie que ses propriétés probabilistes ne dérivent pas systématiquement avec le calendrier. Un AR(1) stationnaire peut passer de -3 à $+3$ et rester stationnaire si ce type de fluctuation appartient au même mécanisme tout au long de la période.

ATTENTION – Stationnaire ne signifie pas « sans crise »

Une série financière peut paraître approximativement stationnaire sur une période tout en changeant de régime pendant une crise. La stationnarité est un modèle de travail, non une vérité métaphysique sur le marché. Nous apprendrons plus tard à rechercher des ruptures et à réévaluer les modèles hors échantillon.

2.3 Bruit blanc et marche aléatoire : deux références à ne pas confondre

2.3.1 Le bruit blanc

Un **bruit blanc** est une suite $\{\varepsilon_t\}$ telle que, dans sa forme faible,

$$\mathbb{E}[\varepsilon_t] = 0, \quad \text{Var}(\varepsilon_t) = \sigma^2, \quad \text{Cov}(\varepsilon_t, \varepsilon_{t-k}) = 0 \quad (k \neq 0).$$

ATTENTION – Non autocorrélé ne signifie pas indépendant

Le bruit blanc faible impose l'absence d'autocovariance hors lag zéro, mais cela ne suffit pas, en général, à garantir l'indépendance. De même, « bruit blanc » ne signifie pas automatiquement « gaussien ». Un **bruit blanc gaussien** ajoute l'hypothèse de normalité ; dans ce cas particulier, la non-corrélation conjointe et la gaussianité permettent une interprétation plus forte.

$$\text{non autocorrélé} \not\Rightarrow \text{indépendant}, \quad \text{bruit blanc} \not\Rightarrow \text{gaussien}.$$

Le terme « blanc » vient par analogie avec un signal contenant toutes les fréquences sans structure privilégiée. Dans un modèle bien spécifié, les résidus doivent souvent ressembler à un bruit blanc : s'ils conservent une autocorrélation importante, le modèle a probablement laissé de l'information temporelle inexploitée.




FIGURE 2.3 – Une réalisation de bruit blanc et son autocorrélation empirique.

2.3.2 La marche aléatoire

Une **marche aléatoire** simple s'écrit

$$X_t = X_{t-1} + \varepsilon_t.$$

Par récurrence,

$$X_t = X_0 + \sum_{j=1}^t \varepsilon_j.$$

La variance devient

$$\text{Var}(X_t) = t\sigma^2$$

si les innovations sont indépendantes et de variance σ^2 . Elle augmente donc avec le temps : le niveau n'est pas stationnaire.

EXEMPLE – Pourquoi une marche aléatoire « se souvient » de tous les chocs

Supposons $X_0 = 100$. Un choc de +5 au premier jour porte la série à 105. Même si toutes les innovations suivantes sont nulles, le niveau reste 105. Le choc n'est jamais oublié. C'est très différent d'un AR(1) stationnaire, dans lequel l'effet d'un choc s'atténue progressivement.

Cette distinction est cruciale en finance. Les niveaux de prix sont souvent beaucoup plus proches d'un comportement intégré ou quasi intégré que les rendements. Cela ne veut pas dire qu'un prix est exactement une marche aléatoire ; cela signifie qu'il faut être très prudent avant de traiter son niveau comme une série stationnaire.

2.4 Autocovariance et autocorrélation : mesurer la mémoire

Pour une série stationnaire, l'autocovariance au retard k est

$$\gamma(k) = \text{Cov}(X_t, X_{t-k}).$$

La **fonction d'autocorrélation**, notée ACF pour *Autocorrelation Function*, normalise cette quantité :

$$\rho(k) = \frac{\gamma(k)}{\gamma(0)}.$$

Par construction, $\rho(0) = 1$ et $-1 \leq \rho(k) \leq 1$.

EXEMPLE – Interpréter une autocorrélation de lag 1

Si $\rho(1) = 0,70$, les valeurs consécutives ont tendance à évoluer dans le même sens relativement à leur moyenne : une valeur élevée est souvent suivie d'une valeur élevée. Si $\rho(1) = -0,60$, l'alternance est plus fréquente : une valeur élevée tend à être suivie d'une valeur basse. Une corrélation proche de zéro indique qu'une dépendance linéaire de ce retard n'est pas clairement visible.

2.4.1 Autocorrélation empirique

Avec des données finies $x_1, \dots, x_n$, on estime l'autocorrélation. Une forme courante est

$$\hat{\rho}(k) = \frac{\sum_{t=k+1}^n (x_t - \bar{x})(x_{t-k} - \bar{x})}{\sum_{t=1}^n (x_t - \bar{x})^2}.$$

Les graphiques ACF représentent $\hat{\rho}(k)$ pour plusieurs retards. Les bandes affichées autour de zéro servent de repère statistique approximatif ; elles ne doivent pas être interprétées comme une règle absolue indépendante du contexte et du nombre de retards inspectés.

ATTENTION – Un pic isolé n'est pas automatiquement une mémoire exploitable

Sous des hypothèses simplifiées de bruit blanc, une règle approximative place des bandes autour de $\pm 1,96/\sqrt{n}$. Mais si l'on inspecte vingt ou trente retards, quelques dépassements peuvent apparaître par hasard. La taille de l'échantillon, la multiplicité des retards, la non-normalité, l'hétéroscédasticité et le choix préalable de la transformation doivent donc entrer dans l'interprétation. L'ACF est un outil de diagnostic, pas un détecteur automatique d'alpha.

2.5 Le modèle AR(1) : quand la valeur actuelle hérite du passé

Un modèle **autorégressif** d'ordre 1, noté AR(1), s'écrit

$$X_t = c + \phi X_{t-1} + \varepsilon_t,$$

où ϕ mesure la persistance du passé et ε_t est une innovation.

Si $|\phi| < 1$, le processus possède une version stationnaire. Sa moyenne vaut

$$\mu = \frac{c}{1 - \phi}.$$

En soustrayant cette moyenne, on obtient

$$X_t - \mu = \phi(X_{t-1} - \mu) + \varepsilon_t.$$

Cette écriture révèle la logique de retour vers la moyenne : un écart présent est multiplié par ϕ à la période suivante, puis par ϕ^2 , etc.




FIGURE 2.4 – Trois niveaux de persistance dans un AR(1). Les trajectoires utilisent exactement la même réalisation des innovations afin d'isoler visuellement l'effet de ϕ .

2.5.1 L'effet de ϕ

- Si $\phi = 0$, il ne reste aucune mémoire autorégressive : $X_t = c + \varepsilon_t$.
- Si $0 < \phi < 1$, les écarts ont tendance à persister puis à s'atténuer.
- Si $-1 < \phi < 0$, les écarts changent fréquemment de signe : le retour vers la moyenne est oscillant.
- Si ϕ est très proche de 1, la mémoire est longue et la série peut visuellement ressembler à une marche aléatoire sur un échantillon court.

Lorsque $c = 0$ et que l'innovation a une variance σ_ε^2 , la variance stationnaire vaut

$$\text{Var}(X_t) = \frac{\sigma_\varepsilon^2}{1 - \phi^2}.$$

L'ACF théorique prend une forme particulièrement simple :

$$\rho(k) = \phi^k.$$




FIGURE 2.5 – Dans un AR(1), l'autocorrélation décroît géométriquement ; un coefficient négatif produit une alternance de signes.

EXEMPLE – Combien reste-t-il d'un choc ?

Avec $\phi = 0,8$, un choc d'amplitude 1 laisse une contribution de 0,8 une période plus tard, 0,64 deux périodes plus tard, puis 0,512, etc. Avec $\phi = 0,2$, il ne reste déjà que 0,04 après deux périodes. Le paramètre ϕ est donc une mesure directe de mémoire.

2.5.2 Du AR(1) au AR(p)

Un modèle AR(p) généralise cette idée :

$$X_t = c + \phi_1 X_{t-1} + \phi_2 X_{t-2} + \dots + \phi_p X_{t-p} + \varepsilon_t.$$

Le nombre p est l'**ordre autorégressif**. L'analyse de stationnarité s'exprime alors à l'aide du polynôme

$$\phi(z) = 1 - \phi_1 z - \dots - \phi_p z^p.$$

Une condition standard de stationnarité est que les racines de ce polynôme soient situées à l'extérieur du cercle unité.

INTUITION – Pourquoi ne pas apprendre cette condition par coeur ?

Pour un AR(1), elle se réduit simplement à $|\phi| < 1$. Pour des ordres supérieurs, les racines évitent d'avoir à raisonner séparément sur de nombreuses combinaisons de coefficients. Ce critère est important pour comprendre le modèle ; dans la pratique logicielle, les bibliothèques peuvent aussi vérifier ou imposer la stationnarité lors de l'estimation.

2.6 Le modèle MA : quand les chocs récents laissent une trace finie

Un modèle **moyenne mobile** d'ordre 1, noté MA(1) pour *Moving Average*, s'écrit

$$X_t = \mu + \varepsilon_t + \theta \varepsilon_{t-1}.$$

Le nom « moyenne mobile » peut être trompeur : il ne s'agit pas de la moyenne glissante descriptive calculée sur des observations. Ici, la valeur dépend d'innovations présentes et passées.




FIGURE 2.6 – Mémoire finie d'un MA(1) après un choc unitaire.

EXEMPLE – Un choc qui disparaît après une période

Dans un MA(1) avec $\theta = 0,7$, une innovation de valeur 1 contribue de 1 à X_t puis de 0,7 à X_{t+1} . À partir de X_{t+2} , ce choc particulier ne contribue plus directement. La mémoire est donc finie, contrairement à celle d'un AR stationnaire dont l'effet décroît progressivement sans disparaître immédiatement.

Un MA(q) général est

$$X_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}.$$

Le nombre q est l'**ordre moyenne mobile**.

2.6.1 Invertibilité : retrouver une représentation unique

Pour obtenir une représentation suffisamment stable et identifiable, on impose généralement une condition d'**invertibilité** au polynôme MA. Pour un MA(1), une condition courante est $|\theta| < 1$. Cette notion joue, du côté MA, un rôle analogue à celui de la stationnarité du côté AR. Elle permet d'exprimer les innovations à partir des observations passées sans créer une dynamique explosive.

2.7 ACF et PACF : deux vues complémentaires de la dépendance

L'ACF mesure la corrélation totale entre X_t et X_{t-k} . Une partie de cette corrélation peut cependant être transmise par les retards intermédiaires. La **fonction d'autocorrélation partielle**, PACF pour *Partial Autocorrelation Function*, cherche au contraire à mesurer la relation directe entre X_t et X_{t-k} après avoir retiré l'effet linéaire des retards $1, \dots, k-1$.

EXEMPLE – Corrélation directe ou transmise ?

Dans un $AR(1)$, X_t dépend directement de X_{t-1} . Comme X_{t-1} dépend lui-même de X_{t-2} , X_t et X_{t-2} sont corrélés. Mais cette corrélation de lag 2 est essentiellement transmise par X_{t-1} . La PACF retire cette médiation : pour un $AR(1)$ idéal, elle présente surtout un pic au lag 1.




FIGURE 2.7 – Signatures empiriques classiques d'un $AR(1)$ et d'un $MA(1)$ dans l'ACF et la PACF ; les bandes pointillées sont des repères approximatifs $\pm 1,96/\sqrt{N}$.

Dans les cas idéaux :

- un $AR(p)$ présente une PACF qui se coupe après le retard p , tandis que son ACF décroît progressivement ;
- un $MA(q)$ présente une ACF qui se coupe après le retard q , tandis que sa PACF décroît progressivement ;
- un $ARMA(p, q)$ produit souvent des décroissances plus progressives des deux côtés.

ATTENTION – Les « signatures » ne sont pas des règles de reconnaissance d'images

Sur un échantillon réel, l'ACF et la PACF sont bruitées. Une série financière peut aussi comporter saisonnalité, ruptures, hétéroscédasticité ou paramètres proches de la frontière de stationnarité. On utilise donc ces graphiques pour proposer des ordres plausibles, pas pour décréter mécaniquement un modèle.

2.8 ARMA : combiner persistance et mémoire des chocs

Un modèle ARMA(p, q), pour *Autoregressive Moving Average*, combine les deux mécanismes :

$$X_t = c + \sum_{i=1}^p \phi_i X_{t-i} + \varepsilon_t + \sum_{j=1}^q \theta_j \varepsilon_{t-j}.$$

L'idée est simple : une partie de la valeur courante dépend des observations passées, et une autre partie dépend de chocs récents non anticipés.

EXEMPLE – Pourquoi combiner AR et MA ?

Une série peut présenter une persistance générale, bien décrite par un terme AR, tout en réagissant de façon spécifique à des chocs récents, ce qu'un terme MA capture efficacement. Un ARMA(1,1) peut ainsi être plus parcimonieux qu'un AR d'ordre élevé qui essaierait d'imiter simultanément ces deux mécanismes.

Pour une série déjà stationnaire, ARMA fournit donc une famille naturelle de modèles linéaires. Mais que faire si le niveau ne l'est pas ?

2.9 Différenciation et racine unitaire : rendre le niveau modélisable

La **première différence** est

$$\Delta X_t = X_t - X_{t-1}.$$

Pour une marche aléatoire,

$$X_t = X_{t-1} + \varepsilon_t,$$

on obtient immédiatement

$$\Delta X_t = \varepsilon_t.$$

Une série non stationnaire en niveau peut donc devenir stationnaire après différenciation.




FIGURE 2.8 – Une marche aléatoire et sa première différence.

Une série est dite **intégrée d'ordre 1**, notée $I(1)$, si elle devient stationnaire après une différenciation. Plus généralement, $I(d)$ signifie qu'il faut appliquer d différenciations pour obtenir une représentation stationnaire, sous les hypothèses du modèle considéré.

ATTENTION – Ne pas différencier « parce que le graphique monte »

Une tendance déterministe et une racine unitaire ne sont pas exactement le même phénomène. Une série autour d'une tendance linéaire peut être stationnaire autour de cette tendance après détrendage, tandis qu'une marche aléatoire accumule des chocs permanents. Les tests de racine unitaire aident à distinguer ces cas, sans les résoudre automatiquement.

2.9.1 Tendance déterministe, racine unitaire et sur-différenciation

Deux séries peuvent toutes deux « monter » et pourtant demander des traitements très différents. Dans un modèle à tendance déterministe,

$$X_t = a + bt + u_t,$$

où u_t est stationnaire, un choc sur u_t est transitoire autour d'une trajectoire déterministe. Dans une marche aléatoire avec dérive,

$$X_t = X_{t-1} + \delta + \varepsilon_t,$$

un choc ε_t modifie durablement le niveau futur. Detrender la première série peut être pertinent ; différencier la seconde l'est souvent davantage.




FIGURE 2.9 – Deux trajectoires croissantes mais deux mécanismes : tendance déterministe autour d'un niveau prévisible et racine unitaire avec chocs permanents.

ATTENTION – Sur-différencier crée aussi des problèmes

Différencier une série déjà stationnaire peut augmenter le bruit, produire une autocorrélation négative artificielle au premier retard et dégrader la prévision. Le bon ordre d est donc généralement le **plus petit** ordre de différenciation qui rend la représentation suffisamment stationnaire pour le modèle visé.

Même dans le cas le plus simple, si X_t est déjà stationnaire, la transformation

$$\Delta X_t = X_t - X_{t-1}$$

ne constitue pas un « nettoyage » neutre : elle mélange deux valeurs successives et peut créer une structure de type MA dans la série transformée. **Différencier transforme la dynamique.**

2.10 Tests de stationnarité : ADF, PP et KPSS

Les graphiques sont indispensables, mais ils ne suffisent pas. Plusieurs tests statistiques complètent le diagnostic.

2.10.1 ADF : Augmented Dickey–Fuller

Le test ADF, pour *Augmented Dickey–Fuller*, teste comme hypothèse nulle la présence d'une racine unitaire [6]. Dans une forme simplifiée,

$$\Delta X_t = \alpha + \beta t + \gamma X_{t-1} + \sum_{i=1}^p \delta_i \Delta X_{t-i} + u_t.$$

L'hypothèse nulle correspond à une dynamique compatible avec une racine unitaire. Une petite p -value conduit à rejeter cette hypothèse, sous la spécification choisie.

EXEMPLE – Lire un résultat ADF

Si le test ADF produit une p -value de 0,004, on dispose d'éléments pour rejeter l'hypothèse nulle de racine unitaire au seuil de 5%. Si la p -value vaut 0,45, on ne rejette pas cette hypothèse. « Ne pas rejeter » ne signifie cependant pas « prouver qu'il existe une racine unitaire » : le test peut manquer de puissance, notamment avec peu de données ou une dynamique proche de 1.

2.10.2 PP : Phillips–Perron

Le test PP, pour *Phillips–Perron*, possède également une hypothèse nulle de racine unitaire [7], mais traite la dépendance et l'hétéroscédasticité des erreurs par une correction non paramétrique différente de l'augmentation explicite en retards de l'ADF. Dans cet ouvrage, il sert surtout de test complémentaire lorsque l'on souhaite vérifier la robustesse d'un diagnostic.

2.10.3 KPSS : Kwiatkowski–Phillips–Schmidt–Shin

Le test KPSS inverse la logique : son hypothèse nulle est la stationnarité autour d'un niveau ou, selon la spécification, autour d'une tendance déterministe [8].

Cette différence d'hypothèse est précieuse : ADF et KPSS ne posent pas la même question. On peut les lire conjointement.

POINT DE VUE INGÉNIEUR – La spécification du test fait partie du résultat

Tester une série « avec constante » ou « avec constante et tendance » n'est pas un détail logiciel. Le nombre de retards dans ADF, le choix niveau/tendance dans KPSS et la taille de l'échantillon peuvent changer la conclusion. Un rapport sérieux note donc au minimum la transformation testée, la composante déterministe retenue, le nombre de retards ou la règle de sélection, la statistique et la p -value.

EXEMPLE – Une tendance déterministe peut changer entièrement la lecture du test

Sur une série simulée de la forme $Y_t = a + bt + u_t$, avec u_t stationnaire, une expérience reproductible du Notebook 1 donne typiquement : ADF avec constante seule, $p \approx 0,95$; ADF avec constante et tendance, $p \approx 2,2 \times 10^{-14}$. Pour KPSS, la même série conduit à $p \leq 0,01$ avec stationnarité autour d'un niveau, mais $p \geq 0,10$ avec stationnarité autour d'une tendance. La série n'a pas changé : **c'est la question statistique posée qui a changé**. Une p -value numériquement minuscule n'est d'ailleurs jamais « mathématiquement égale à zéro ».

Lire conjointement ADF et KPSS : une boussole, pas un verdict automatique

	KPSS : ne rejette pas la stationnarité	KPSS : rejette la stationnarité
ADF : rejette la racine unitaire	Concordance : stationnarité plausible	Zone ambiguë : vérifier tendance, ruptures, lags
ADF : ne rejette pas la racine unitaire	Zone ambiguë : puissance limitée / cas frontière	Concordance : non-stationnarité plausible

FIGURE 2.10 – Lecture conjointe d'ADF et KPSS : les zones de concordance sont informatives, les zones ambiguës demandent davantage de diagnostic.

TABLE 2.1 – Logique des trois tests de stationnarité abordés dans le chapitre.

Test	Hypothèse nulle	Si la p -value est petite	Usage principal
ADF	racine unitaire	on rejette la racine unitaire	diagnostic paramétrique avec retards
PP	racine unitaire	on rejette la racine unitaire	contrôle robuste complémentaire
KPSS	stationnarité	on rejette la stationnarité	contrepoint à ADF/PP

POINT DE VUE INGÉNIEUR – Toujours tester une spécification, jamais « la stationnarité » en général

Le résultat dépend de la présence ou non d'une constante, d'une tendance, du nombre de retards et de la longueur de l'échantillon. Un bon diagnostic combine graphique, connaissance du mécanisme, tests et vérification de robustesse.

2.11 ARIMA : ARMA appliqué à une série rendue stationnaire

ARIMA signifie *Autoregressive Integrated Moving Average*. En français, on parle souvent de modèle autorégressif intégré moyenne mobile. La notation $ARIMA(p, d, q)$ rassemble :

- p : ordre autorégressif AR ;
- d : nombre de différenciations ;
- q : ordre moyenne mobile MA.

Une écriture compacte utilise l'opérateur retard L , défini par $LX_t = X_{t-1}$. Si

$$\phi(L) = 1 - \phi_1 L - \dots - \phi_p L^p, \quad \theta(L) = 1 + \theta_1 L + \dots + \theta_q L^q,$$

alors un ARIMA peut être représenté conceptuellement par

$$\phi(L)(1 - L)^d X_t = c + \theta(L)\varepsilon_t.$$

EXEMPLE – Déchiffrer quelques notations

- ARIMA(1,0,0) est un AR(1) ;
- ARIMA(0,0,1) est un MA(1) ;
- ARIMA(1,0,1) est un ARMA(1,1) ;
- ARIMA(0,1,0) est une marche aléatoire sans dérive dans sa forme la plus simple ;
- ARIMA(1,1,1) modélise la première différence par une structure ARMA(1,1).

2.12 La démarche Box–Jenkins : un cycle de diagnostic

La modélisation ARIMA est souvent associée à la démarche Box–Jenkins [1]. Elle ne consiste pas à choisir automatiquement trois nombres, mais à itérer entre préparation, identification, estimation et contrôle.

Cycle de modélisation ARIMA : itératif plutôt que mécanique




FIGURE 2.11 – La démarche ARIMA est un cycle : un diagnostic insuffisant ramène à l'identification.

2.12.1 Étape 1 : préparer la série

On clarifie la fréquence, le calendrier, les valeurs manquantes, les transformations éventuelles et surtout le niveau de différenciation d . Une différenciation excessive peut introduire artificiellement une structure moyenne mobile et augmenter le bruit.

2.12.2 Étape 2 : proposer des ordres p et q

On examine l'ACF, la PACF, la parcimonie attendue et plusieurs modèles candidats. Le but n'est pas de maximiser le nombre de paramètres, mais d'obtenir une représentation suffisamment riche avec peu de paramètres.

2.12.3 Étape 3 : estimer

Les paramètres sont généralement estimés par maximum de vraisemblance ou par méthodes appariées. Les bibliothèques modernes utilisent des formulations d'espace d'état et le filtre de Kalman pour de nombreuses variantes ARIMA [13].

2.12.4 Étape 4 : diagnostiquer les résidus

Un bon ajustement ne suffit pas. Les résidus doivent être inspectés :

- moyenne proche de zéro ;
- absence de structure temporelle résiduelle importante ;
- variance suffisamment stable pour l'usage visé ;
- absence de motifs évidents oubliés par le modèle.

Le test de Ljung-Box [9] examine conjointement si les autocorrélations résiduelles jusqu'à un certain retard m sont compatibles avec zéro. Son hypothèse nulle s'écrit schématiquement

$$H_0 : \rho_1 = \rho_2 = \dots = \rho_m = 0.$$

Lorsqu'il est appliqué aux résidus d'un ARIMA(p, d, q), le nombre de degrés de liberté consommés par les composantes AR/MA doit être pris en compte lorsque l'implémentation le permet ; dans Statsmodels, l'argument `model_df=p+q` fournit ce correctif. Une grande p -value **ne prouve pas l'indépendance** : elle signifie seulement que le test ne détecte pas d'autocorrélation globale significative aux retards considérés.

2.12.5 Étape 5 : prévoir et évaluer

Le modèle est finalement évalué sur des observations futures non utilisées pour l'ajustement. Nous approfondirons la validation temporelle au chapitre 6 ; ici, nous introduisons simplement le principe d'une séparation chronologique entre entraînement et évaluation.

2.13 Choisir entre plusieurs modèles : AIC et BIC

Deux critères d'information très utilisés sont l'AIC, *Akaike Information Criterion* [10], et le BIC, *Bayesian Information Criterion* [11]. Ils mettent en balance qualité d'ajustement et complexité.

Une forme classique de l'AIC est

$$\text{AIC} = -2 \log L + 2k,$$

et celle du BIC

$$\text{BIC} = -2 \log L + k \log n,$$

où L est la vraisemblance maximisée, k le nombre de paramètres et n la taille de l'échantillon.

INTUITION – Pourquoi pénaliser la complexité ?

Un modèle plus complexe peut presque toujours mieux épouser les données d'entraînement. La pénalité rappelle qu'un paramètre supplémentaire doit apporter suffisamment d'information pour justifier son coût statistique. Le BIC pénalise généralement davantage les modèles complexes lorsque n est grand.

ATTENTION – Le plus petit AIC n'est pas « le meilleur modèle » au sens universel

AIC et BIC comparent des modèles sur un même jeu de données et sous des hypothèses précises. Un modèle peut avoir un AIC plus faible mais prévoir moins bien hors échantillon, laisser des résidus autocorrélés ou être économiquement peu utile. Ces critères servent à orienter la sélection, non à remplacer l'analyse.

TABLE 2.2 – Exemple reproductible du Notebook 2 : classement in-sample et erreur future ne coïncident pas nécessairement.

Modèle	AIC train	BIC train	MAE test
ARIMA(1,1,0)	1140,72	1153,11	8,07
ARIMA(1,1,1)	1110,79	1127,31	8,43
ARIMA(2,1,1)	1112,17	1132,82	8,38

Dans cette expérience, ARIMA(1,1,1) est choisi par les critères AIC et BIC sur l'entraînement. Pourtant, ARIMA(1,1,0) obtient la plus petite MAE sur cette période de test particulière. Cette observation ne justifie pas de re-sélectionner après coup sur le test ; elle montre précisément que les critères d'information et la performance future répondent à des questions différentes.

2.14 Résidus : le modèle a-t-il réellement extrait la mémoire ?

Après estimation, on définit schématiquement le résidu

$$\hat{\varepsilon}_t = X_t - \hat{X}_t.$$

Si le modèle a correctement capturé la dépendance linéaire visée, l'ACF résiduelle doit être beaucoup plus faible que celle de la série initiale.




FIGURE 2.12 – Diagnostic résiduel : la série des erreurs et leur autocorrélation doivent être examinées conjointement.

EXEMPLE – Un pic résiduel au lag 2

Supposons qu'après ajustement d'un $AR(1)$, l'ACF des résidus conserve un fort pic au lag 2. Cela suggère qu'une information à deux périodes n'a pas été correctement absorbée. Une possibilité est d'examiner un $AR(2)$, un terme MA ou une autre structure. Ce diagnostic ne dit pas automatiquement lequel choisir ; il indique que le modèle actuel n'a pas terminé le travail.

2.15 Prévision : une valeur centrale et une incertitude

Une prévision ARIMA ne produit pas seulement une trajectoire moyenne. Elle doit idéalement être accompagnée d'un intervalle de prévision qui reflète l'incertitude croissante avec l'horizon.

ATTENTION – Un intervalle à 95% n'est pas une garantie universelle

L'intervalle de prévision est **conditionnel au modèle estimé et à ses hypothèses**. Sa couverture dépend notamment de la spécification du modèle, de l'estimation, de la distribution supposée des innovations et de la structure de variance. Si la variance conditionnelle évolue fortement, une modélisation ARIMA de la moyenne peut être insuffisante ; ce constat prépare directement CH03 et les modèles ARCH/GARCH.




FIGURE 2.13 – Exemple de prévision ARIMA avec observations réalisées et intervalle de prévision.

Pour un horizon $h = 1$, la prévision bénéficie de toute l'information disponible jusqu'au temps t . À plusieurs pas, certaines valeurs futures nécessaires sont elles-mêmes remplacées par des prévisions, ce qui augmente l'incertitude.

EXEMPLE – Prévision à 1 jour et à 20 jours

Prévoir demain peut exploiter directement toutes dernières observations. Prévoir vingt jours plus loin nécessite propager le modèle sur une longue chaîne d'étapes inconnues. Même si la prévision centrale reste raisonnable, l'intervalle doit généralement s'élargir. Une stratégie qui utilise uniquement le point central sans tenir compte de cette incertitude peut être excessivement confiante.

2.16 Évaluer une prévision sans regarder le futur

Une prévision temporelle doit être évaluée dans l'ordre du temps. Si les observations futures influencent directement ou indirectement le choix du modèle, des hyperparamètres, des transformations ou de la normalisation, l'évaluation souffre de **fuite temporelle** (*look-ahead bias*).

Validation temporelle : la frontière train/test est une frontière d'information




FIGURE 2.14 – Séparation chronologique : le modèle est construit sur le passé et évalué sur une période future restée intacte.

Pour une première évaluation, on peut conserver les h dernières observations comme jeu de test. Le protocole du Notebook 2 est une **prévision multi-pas à origine fixe** : à la date T , le modèle est ajusté une seule fois puis produit

$$\hat{y}_{T+1|T}, \hat{y}_{T+2|T}, \dots, \hat{y}_{T+h|T}.$$

Il faut la distinguer d'un protocole *walk-forward* : une nouvelle observation devient disponible, le modèle peut être mis à jour, puis une nouvelle prévision de court horizon est produite. Le walk-forward sera traité en profondeur dans CH06 ; il n'est pas développé ici.

Deux erreurs simples sont utiles pour commencer :

$$\text{MAE} = \frac{1}{h} \sum_{j=1}^h |y_{T+j} - \hat{y}_{T+j}|, \quad \text{RMSE} = \sqrt{\frac{1}{h} \sum_{j=1}^h (y_{T+j} - \hat{y}_{T+j})^2}.$$

Le RMSE pénalise davantage les grandes erreurs ; le MAE est plus directement interprétable dans l'unité de la série. Aucune métrique n'a de sens sans une **baseline**. Toute méthode sophistiquée doit être comparée à **plusieurs baselines raisonnables**.

Pour un niveau très persistant, une première référence est la persistance :

$$\hat{y}_{T+h}^{\text{pers}} = y_T.$$

Si la série possède une dérive, une seconde baseline simple consiste à estimer sur l'entraînement

$$\hat{\delta} = \frac{y_T - y_1}{T - 1}, \quad \hat{y}_{T+h}^{\text{drift}} = y_T + h\hat{\delta}.$$

Sur le dataset pédagogique et la même fenêtre test de 60 observations, le Notebook 2 obtient :

Méthode	MAE	RMSE
Persistance	12,74	14,87
Drift	8,43	9,90
ARIMA(1,1,1)	8,43	9,90

Les valeurs non arrondies montrent même une nuance intéressante : la baseline drift obtient une MAE très légèrement meilleure, tandis qu'ARIMA obtient un RMSE très légèrement meilleur. Le

message scientifique est essentiel : **un modèle peut sembler extrêmement performant face à une baseline trop faible, puis perdre presque tout avantage face à une baseline simple mais mieux adaptée.**

À RETENIR – Trois niveaux de preuve

Un modèle temporel crédible doit franchir trois contrôles distincts : **(1) cohérence statistique** du mécanisme et des paramètres, **(2) résidus** sans mémoire linéaire importante oubliée, **(3) performance future** comparée à une baseline sur des données réellement hors échantillon.

2.17 Pourquoi ARIMA est important en trading même lorsqu'il ne gagne pas

Dans un cours de Trading Intelligent, ARIMA a une valeur particulière. Il fournit un **benchmark explicable et rigoureux**. Avant d'accepter qu'un modèle de Machine Learning ou un réseau LSTM apporte quelque chose, il est sain de vérifier s'il bat une référence économétrique simple construite proprement.

Pour les prix financiers, le niveau peut être très persistant ou intégré alors que les rendements ont souvent une autocorrélation linéaire faible. Cela signifie qu'un ARIMA sur le prix peut produire des prévisions de niveau visuellement raisonnables sans nécessairement générer une stratégie profitable. De même, une petite prédictibilité statistique des rendements peut être absorbée par les coûts de transaction.

POINT DE VUE INGÉNIEUR – Baseline avant sophistication

Lorsque nous introduirons le Machine Learning, puis le Deep Learning, nous conserverons au moins trois références : une prévision naïve, une référence économétrique comme ARIMA lorsque pertinente, et une stratégie simple. Une méthode complexe devra justifier son existence par rapport à ces baselines, pas seulement produire un graphique plus impressionnant.

2.18 Première limite : la variance peut elle-même évoluer

Les modèles ARMA/ARIMA décrivent principalement la dynamique conditionnelle de la moyenne. Or les rendements financiers montrent souvent des périodes calmes suivies de périodes très agitées. Même si la moyenne devient difficile à prévoir, la variance peut présenter une structure temporelle forte. Des résidus peuvent donc être peu autocorrélés alors que leurs **carrés** restent nettement structurés : l'absence de mémoire linéaire dans la moyenne ne signifie pas absence de dynamique de volatilité.

C'est précisément la limite qui prépare le chapitre suivant. Nous passerons de

$$\mathbb{E}[X_t \mid \mathcal{F}_{t-1}]$$

à

$$\text{Var}(X_t \mid \mathcal{F}_{t-1}),$$

c'est-à-dire à la volatilité conditionnelle, avec ARCH et GARCH.

2.19 Laboratoires numériques associés

Deux notebooks prolongent le chapitre sans imposer de chemin informatique particulier.

1. **Notebook 1 – Stationnarité, ACF et PACF** : simulation de bruit blanc, AR(1), MA(1), marche aléatoire, différenciation et tests ADF/KPSS.
2. **Notebook 2 – ARIMA, diagnostics et prévision** : identification de modèles candidats, comparaison AIC/BIC, diagnostic des résidus, prévision multi-pas à origine fixe et comparaison avec les baselines persistance et drift.

Le jeu de données pédagogique porte l'identifiant stable **TI_CH02_TS_MODELS_V1** et le nom logique `TI_CH02_TS_Models_v1.csv`. Il contient plusieurs séries synthétiques dont les mécanismes sont connus, ce qui permet de vérifier si les outils retrouvent effectivement la structure génératrice.

2.20 Exemple guidé : diagnostiquer une série inconnue

Supposons qu'une série Y_t présente les caractéristiques suivantes :

- son niveau dérive lentement ;
- l'ADF en niveau ne rejette pas la racine unitaire ;
- le KPSS en niveau rejette la stationnarité ;
- après première différenciation, l'ADF rejette la racine unitaire et le KPSS ne rejette pas la stationnarité ;
- l'ACF de ΔY_t décroît rapidement ;
- la PACF montre un pic principal au lag 1.

Une démarche raisonnable serait :

1. proposer $d = 1$;
2. considérer un ARIMA(1,1,0) comme candidat simple ;
3. comparer avec ARIMA(0,1,1) et ARIMA(1,1,1) ;
4. utiliser AIC/BIC comme indices de parcimonie ;
5. inspecter l'ACF résiduelle et un test de Ljung–Box ;
6. évaluer les prévisions sur une période future conservée à part.

Aucune de ces étapes n'est suffisante isolément. C'est leur cohérence qui constitue l'argument scientifique.

2.21 Exercices

A – Compréhension

1. Expliquer avec ses propres mots la différence entre un bruit blanc et une marche aléatoire.
2. Une série stationnaire peut-elle avoir une valeur très élevée pendant quelques périodes ? Justifier.
3. Pourquoi l'ACF d'un AR(1) stationnaire ne s'annule-t-elle pas brutalement après le lag 1 ?
4. Pourquoi le terme « moyenne mobile » du modèle MA ne doit-il pas être confondu avec une moyenne glissante calculée sur les observations ?
5. Pourquoi la baseline de persistance n'est-elle pas toujours la meilleure baseline naïve lorsqu'une série présente une dérive ?

B – Calcul

5. Pour $X_t = 0,6X_{t-1} + \varepsilon_t$ avec $\text{Var}(\varepsilon_t) = 4$, calculer la variance stationnaire.
6. Pour un AR(1) avec $\phi = -0,5$, calculer $\rho(1)$, $\rho(2)$, $\rho(3)$ et interpréter l'alternance.
7. Pour $P_0 = 100$, $P_1 = 103$, $P_2 = 101$, $P_3 = 105$, calculer la série des premières différences et discuter si cette transformation suffit à conclure à la stationnarité.

C – Raisonnement

8. ADF ne rejette pas la racine unitaire, mais KPSS ne rejette pas non plus la stationnarité. Proposer au moins trois vérifications avant de décider de différencier.
9. Deux modèles donnent $\text{AIC} = 1320$ et 1314 . Le second possède deux paramètres supplémentaires. Peut-on conclure qu'il sera nécessairement meilleur en trading ? Construire une réponse argumentée.
10. Un ARIMA produit des résidus non autocorrélés mais dont la variance augmente fortement pendant certaines périodes. Quelle limitation apparaît et quel chapitre suivant devient pertinent ?
11. Une série présente une tendance déterministe. Pourquoi la spécification `c` versus `ct` peut-elle modifier la conclusion d'un test ADF ou KPSS ?
12. Que signifie réellement une p -value élevée du test de Ljung-Box ? Que ne permet-elle pas de conclure ?

D – Programmation et expérimentation

11. Simuler trois AR(1) avec $\phi = 0,2$, $0,8$ et $0,98$ en utilisant exactement les mêmes innovations. Comparer leurs trajectoires et ACF.
12. Simuler un MA(2), afficher ACF et PACF, puis vérifier expérimentalement quelle fonction présente la coupure la plus nette.
13. Ajuster ARIMA(0,1,0), ARIMA(1,1,0), ARIMA(0,1,1) et ARIMA(1,1,1) à la série pédagogique `arima_price`. Comparer AIC, BIC et erreurs de prévision sur les 40 dernières observations.

D2 – Validation temporelle

14. Comparer sur la série pédagogique persistance, drift et ARIMA avec MAE et RMSE. Les deux métriques conduisent-elles au même jugement ?
15. Expliquer précisément la différence entre une prévision multi-pas à origine fixe et un protocole walk-forward. Pourquoi le second est-il souvent plus proche d'une exploitation opérationnelle ?

E – Problème d'ingénieur

16. Une équipe annonce qu'un ARIMA(4,1,5) prédit mieux les prix d'un actif parce que son erreur d'entraînement est plus faible que celle d'un ARIMA(1,1,0). Concevoir un protocole minimal permettant de vérifier cette affirmation sans fuite temporelle.

2.22 Checklist de maîtrise

Avant de passer au chapitre suivant, vérifiez que vous pouvez répondre sans logiciel aux questions suivantes :

1. Pourquoi une forte autocorrélation d'un niveau de prix peut-elle être trompeuse ?
2. Quelle différence conceptuelle sépare mémoire AR et mémoire MA ?
3. Pourquoi ADF et KPSS peuvent-ils être utiles ensemble ?
4. Pourquoi choisir d trop grand peut-il dégrader un modèle ?
5. Que doit montrer l'ACF des résidus d'un modèle correctement spécifié pour la moyenne ?
6. Pourquoi un AIC plus faible ne prouve-t-il pas une meilleure prévision future ?
7. Pourquoi faut-il comparer plusieurs baselines raisonnables plutôt qu'une seule référence faible ?
8. Quelle différence existe entre une prévision multi-pas à origine fixe et une validation walk-forward ?
9. Que teste exactement Ljung-Box, et que signifie une grande p -value ?

Si une réponse reste hésitante, revenez au mécanisme correspondant avant de poursuivre vers ARCH/GARCH.

2.23 Synthèse

Nous avons construit une chaîne logique complète :

ordre temporel $\rightarrow$ stationnarité $\rightarrow$ ACF/PACF $\rightarrow$ AR/MA $\rightarrow$ ARMA
 $\rightarrow$ différenciation $\rightarrow$ ARIMA $\rightarrow$ diagnostic $\rightarrow$ prévision.

Les idées essentielles sont les suivantes :

- une série temporelle ne peut pas être traitée comme un tableau dont on mélange librement les lignes ;

- la stationnarité fournit un cadre dans lequel les propriétés estimées dans le passé peuvent rester utiles ;
- l'AR décrit une mémoire des valeurs passées, le MA une mémoire finie des innovations ;
- ACF et PACF aident à identifier cette mémoire mais ne remplacent pas la validation ;
- une racine unitaire rend le niveau non stationnaire et motive souvent la différenciation ;
- ADF/PP et KPSS posent des hypothèses nulles différentes et doivent être lus avec le graphique et le contexte ;
- $\text{ARIMA}(p, d, q)$ modélise la série après d différenciations par une structure $\text{ARMA}(p, q)$;
- un modèle n'est pas accepté sur l'ajustement seul : ses résidus et ses prévisions hors échantillon doivent être contrôlés ;
- une performance de prévision n'est interprétable qu'en regard de baselines raisonnables et d'un protocole temporel explicitement défini.

À RETENIR – Transition vers la volatilité

ARIMA peut extraire une structure dans la moyenne conditionnelle, mais il suppose implicitement une dynamique d'erreur qui reste souvent trop simple pour les marchés. Les rendements financiers présentent fréquemment des grappes de volatilité : la prochaine question sera donc non plus seulement « quelle valeur prévoir ? », mais « quelle incertitude prévoir ? ».

Lexique essentiel FR–EN

retard temporel — lag

processus stochastique — stochastic process

innovation — innovation (ε_t)

bruit blanc — white noise

stationnarité faible — weak / covariance stationarity

fonction d'autocorrélation — autocorrelation function (ACF)

fonction d'autocorrélation partielle — partial autocorrelation function (PACF)

autorégressif — autoregressive (AR)

moyenne mobile — moving average (MA)

autorégressif moyenne mobile — autoregressive moving average (ARMA)

différenciation — differencing (Δ)

racine unitaire — unit root

Augmented Dickey–Fuller — ADF test

Phillips–Perron — PP test

Kwiatkowski–Phillips–Schmidt–Shin — KPSS test

autorégressif intégré moyenne mobile — autoregressive integrated moving average (ARIMA)

critère d'information d'Akaike — Akaike information criterion (AIC)

critère d'information bayésien — Bayesian information criterion (BIC)

résidu — residual

test de Ljung–Box — Ljung–Box test

baseline de persistance — persistence baseline

baseline avec dérive — drift baseline

prévision à origine fixe — fixed-origin forecast

prévision hors échantillon — out-of-sample forecast (OOS)

Références essentielles

- [1] G. E. P. Box, G. M. Jenkins, G. C. Reinsel et G. M. Ljung, *Time Series Analysis : Forecasting and Control*, 5e éd., Wiley, 2015.
- [2] J. D. Hamilton, *Time Series Analysis*, Princeton University Press, 1994.
- [3] P. J. Brockwell et R. A. Davis, *Introduction to Time Series and Forecasting*, 3e éd., Springer, 2016.
- [4] R. S. Tsay, *Analysis of Financial Time Series*, 3e éd., Wiley, 2010.
- [5] R. J. Hyndman et G. Athanasopoulos, *Forecasting : Principles and Practice*, ressource en ligne, OTexts. Chapitres consacrés à la stationnarité, la différenciation et ARIMA. <https://otexts.com/fpp3/>
- [6] D. A. Dickey et W. A. Fuller, « Distribution of the Estimators for Autoregressive Time Series with a Unit Root », *Journal of the American Statistical Association*, vol. 74, no 366, p. 427–431, 1979.
- [7] P. C. B. Phillips et P. Perron, « Testing for a Unit Root in Time Series Regression », *Biometrika*, vol. 75, no 2, p. 335–346, 1988.
- [8] D. Kwiatkowski, P. C. B. Phillips, P. Schmidt et Y. Shin, « Testing the Null Hypothesis of Stationarity against the Alternative of a Unit Root », *Journal of Econometrics*, vol. 54, p. 159–178, 1992.
- [9] G. M. Ljung et G. E. P. Box, « On a Measure of Lack of Fit in Time Series Models », *Biometrika*, vol. 65, no 2, p. 297–303, 1978.
- [10] H. Akaike, « A New Look at the Statistical Model Identification », *IEEE Transactions on Automatic Control*, vol. 19, no 6, p. 716–723, 1974.
- [11] G. Schwarz, « Estimating the Dimension of a Model », *The Annals of Statistics*, vol. 6, no 2, p. 461–464, 1978.
- [12] Statsmodels Developers, *Time Series Analysis (tsa) – documentation officielle*. Fonctions ACF, PACF, ADF, KPSS, ARIMA et diagnostics de séries temporelles. <https://www.statsmodels.org/stable/tsa.html>
- [13] Statsmodels Developers, *statsmodels.tsa.arima.model.ARIMA – documentation officielle*. <https://www.statsmodels.org/stable/generated/statsmodels.tsa.arima.model.ARIMA.html>
- [14] Statsmodels Developers, *statsmodels.stats.diagnostic.acorr_ljungbox – documentation officielle*. https://www.statsmodels.org/stable/generated/statsmodels.stats.diagnostic.acorr_ljungbox.html