

TRADING INTELLIGENT

Économétrie financière, Machine Learning, Time Series, Deep Learning
et Reinforcement Learning pour la décision de marché

CHAPITRE 2

Comprendre la dépendance temporelle

Lire, diagnostiquer et modéliser une série temporelle — de zéro à SARIMA

Question directrice. Comment passer d'une suite de nombres observés dans le temps à une compréhension rigoureuse de sa mémoire, de sa stabilité et de sa prévisibilité — sans utiliser une formule, un graphique ou un test avant d'avoir expliqué ce qu'il signifie et pourquoi il existe ?

Comment utiliser ce chapitre

Ce chapitre est volontairement autonome. Il suppose que le lecteur sait manipuler l'algèbre élémentaire, les fonctions, les sommes et les logarithmes, mais **ne suppose aucune formation préalable en probabilités, en statistique, en économétrie ou en finance**. Lorsque nous aurons besoin d'une notion probabiliste, nous la construirons avant de l'utiliser. Lorsque nous aurons besoin d'une notion financière, nous la définirons localement.

À RETENIR – Contrat pédagogique « zéro boîte noire »

Aucune notion importante n'est introduite comme une recette. La progression est systématique :

problème → intuition → définition → dérivation
→ exemple numérique → figure → Python → limites.

Un symbole doit être défini avant sa première utilisation ; une figure doit illustrer une idée déjà expliquée ; un test doit être précédé de son hypothèse nulle ; une sortie logicielle doit être interprétable sans « faire confiance au logiciel ».

ATTENTION – Ce chapitre n'est pas un catalogue de commandes

Le but n'est pas d'apprendre `ARIMA(...).fit()` mais de comprendre ce que le logiciel cherche à estimer, sous quelles hypothèses, pourquoi certaines séries doivent être différenciées, pourquoi un résidu doit ressembler à un bruit blanc, et pourquoi une bonne performance in-sample ne prouve rien sur le futur.

Carte des dépendances conceptuelles

Le chapitre suit désormais une logique d'observation avant formalisation :

voir une série → tendance/saisonnalité/bruit → questions statistiques
→ $\mathbb{E}$, Var, Cov, Corr → stationnarité → lags → ACF/PACF
→ AR/MA/ARMA → L → racines → cercle unité → Δ → $I(d)$
→ ADF/PP/KPSS → saisonnalité profonde → Δ_s → SARIMA
→ estimation → résidus → prévision → validation temporelle.

Table des matières

2	Voir une série temporelle avant de la modéliser	1
2.1	Le premier geste : regarder ce qui évolue	1
2.2	Trois briques : tendance, saisonnalité et reste	1
2.3	Additif ou multiplicatif : pourquoi l'amplitude compte	3
2.4	Pourquoi ce chapitre ne commence pas directement par les probabilités	4
2.5	Un minimum de contexte financier, sans supposer de finance	4
2.6	La question suivante : qu'est-ce qui est stable ?	4

3	Les probabilités dont nous avons besoin — seulement quand elles deviennent utiles	5
3.1	Pourquoi introduire maintenant les probabilités ?	5
3.2	Variable aléatoire : transformer une issue en nombre	5
3.3	Espérance : le centre probabiliste, pas une promesse	6
3.4	Variance et écart-type : quantifier la dispersion	6
3.5	Covariance : deux variables bougent-elles ensemble ?	7
3.6	Corrélation : covariance sans unité	7
3.7	Indépendance : connaître l'une ne change pas la loi de l'autre	8
3.8	Fonction de répartition : accumuler les probabilités	8
3.9	Quantile : poser la question à l'envers	8
3.10	La loi normale : pourquoi la courbe en cloche apparaît partout	8
3.11	Standardisation : compter les écarts-types	9
3.12	D'où vient exactement le nombre 1,96 ?	9
3.13	Population, échantillon, estimateur : pourquoi les nombres calculés fluctuent	10
3.14	Erreur-type : la variabilité d'un estimateur	10
3.15	Le Théorème Central Limite : la normale émerge des moyennes	10
3.16	Intervalle de confiance et intervalle de prévision : ne pas les confondre	11
3.17	Probabilité, test, niveau α et p-value	11
4	Du hasard au temps : processus, retards et stationnarité	12
4.1	Une série temporelle n'est pas un tableau ordinaire	12
4.2	Processus stochastique et réalisation	12
4.3	Le retard ou lag	12
4.4	Information passée et innovation	13
4.5	Conditionnel et inconditionnel	13
4.6	Pourquoi la stationnarité est-elle importante ?	14
4.7	Stationnarité stricte	14
4.8	Stationnarité faible ou de second ordre	14
4.9	Quatre séries qui peuvent sembler proches à l'œil mais ne le sont pas	14
4.10	Tendance déterministe et stationnarité autour d'une tendance	15
4.11	Rupture de variance	15
4.12	Un minimum de vocabulaire financier pour les exemples	15
5	Bruit blanc, autocovariance et ACF : mesurer la mémoire sans magie	16
5.1	Le bruit blanc : une référence de « non-mémoire linéaire »	16
5.2	Pourquoi un bruit blanc n'a pas besoin d'être normal	17
5.3	La marche aléatoire : intégrer un bruit blanc	17
5.4	Autocovariance : appliquer la covariance à une série et son passé	17
5.5	Autocorrélation théorique : une mesure sans unité	18

5.6	ACF théorique et ACF empirique : propriété du modèle versus estimation	18
5.7	Calcul manuel d'une autocorrélation	18
5.8	Pourquoi l'ACF d'un bruit blanc n'est-elle jamais exactement zéro ?	19
5.9	Pourquoi l'erreur-type est approximativement $1/\sqrt{n}$ sous bruit blanc ?	19
5.10	Enfin, la bande $\pm 1,96/\sqrt{n}$	19
5.11	Expérience de Monte Carlo : voir la distribution d'échantillonnage de l'ACF	20
5.12	La formule de Bartlett : ce que l'on peut dire précisément	21
5.13	Multiplicité : pourquoi un pic sur vingt peut apparaître par hasard	21
5.14	Ce que l'ACF peut et ne peut pas dire	21
6	Le modèle autorégressif : comprendre la persistance de l'intérieur	22
6.1	Pourquoi introduire un modèle AR ?	22
6.2	Dérouler l'équation : la meilleure façon de voir la mémoire	22
6.3	La suite géométrique et l'oubli du passé lointain	23
6.4	Propagation d'un choc	23
6.5	Les régimes de ϕ	24
6.6	Espérance inconditionnelle d'un AR(1) stationnaire	25
6.7	Pourquoi $\phi = 1$ détruit l'espérance stationnaire	25
6.8	Variance inconditionnelle : dérivation complète	26
6.9	La mémoire amplifie le risque inconditionnel	26
6.10	Variance de la marche aléatoire et règle en racine du temps	27
6.11	ACF théorique de l'AR(1)	27
6.12	Demi-vie d'un choc	28
6.13	Du AR(1) au AR(p)	28
6.14	L'opérateur de retard : une notation qui compresse les décalages	28
6.15	Pourquoi introduire une variable complexe z ?	29
6.16	Nombre complexe et module : juste ce qu'il faut pour le cercle unité	29
6.17	AR(1) : coefficients à l'intérieur, racine à l'extérieur	29
6.18	AR(p) : la condition générale sur les racines	30
6.19	Ce qu'un AR ne garantit pas	31
7	MA, PACF et ARMA : mémoire des chocs, mémoire des valeurs	31
7.1	Pourquoi un modèle MA après l'AR ?	31
7.2	Lire un MA(1) terme par terme	32
7.3	Espérance et variance d'un MA(1)	32
7.4	ACF théorique du MA(1)	32
7.5	MA(q) : mémoire directe de longueur q	33
7.6	Pourquoi l'invertibilité existe-t-elle ?	33
7.7	Polynôme MA et racines	34

7.8	Pourquoi l'identifiabilité a besoin de l'invertibilité	34
7.9	Pourquoi l'ACF seule ne sépare pas toujours tout ?	35
7.10	Corrélation partielle : enlever les chemins intermédiaires	35
7.11	Construction par régression au lag 2	35
7.12	Signatures théoriques ACF/PACF	35
7.13	ARMA : combiner mémoire des valeurs et mémoire des chocs	36
7.14	Réponse impulsionnelle d'un ARMA	36
7.15	Pourquoi ne pas choisir un ARMA énorme ?	37
8	Racine unitaire, différenciation et tests de stationnarité	37
8.1	Pourquoi une racine unitaire est-elle un cas si particulier ?	37
8.2	Différencier : soustraire deux observations successives	37
8.3	Ordre d'intégration $I(d)$	38
8.4	Différence première, croissance et rendement	38
8.5	Sur-différenciation : trop transformer peut dégrader la série	39
8.6	Dickey–Fuller : dériver le test à partir de l'AR(1)	39
8.7	Pourquoi un test t ordinaire ne suffit pas ?	40
8.8	Constante, tendance ou rien : la spécification change la question	40
8.9	ADF : pourquoi ajouter des retards de différences ?	41
8.10	Choisir le nombre de retards de l'ADF	41
8.11	Lire une sortie ADF sans réciter une règle	41
8.12	Phillips–Perron : même nullité, correction différente	41
8.13	KPSS : inverser l'hypothèse nulle	41
8.14	Pourquoi combiner ADF/PP et KPSS ?	42
8.15	Près de la racine unitaire : le cas difficile	42
8.16	Ruptures structurelles : une autre source de confusion	42
8.17	De la différenciation à ARIMA	42
9	Saisonnalité et SARIMA : quand le temps possède un calendrier	43
9.1	Pourquoi la saisonnalité mérite une section entière	43
9.2	Période s : compter la distance entre positions comparables	43
9.3	Saisonnalité déterministe et saisonnalité stochastique	43
9.4	Ce que l'ACF doit montrer, et pourquoi	44
9.5	Pourquoi la différenciation ordinaire peut échouer	44
9.6	Différenciation saisonnière : comparer une position à elle-même un cycle plus tôt	44
9.7	Racines saisonnières : la géométrie revient	45
9.8	SARIMA : étendre ARIMA sans changer sa logique	45
9.9	Un exemple canonique : le modèle “airline”	46
9.10	Saisonnalité multiplicative et logarithme	46

9.11	Fourier : une autre façon de coder un calendrier régulier	46
9.12	Calendrier financier : saisonnalité réelle, mais prudence maximale	47
9.13	Sur-différenciation saisonnière	48
9.14	La séquence de diagnostic que nous retiendrons	48
10	ARIMA, estimation et sélection : de la structure au modèle ajusté	48
10.1	Déchiffrer $\text{ARIMA}(p, d, q)$	48
10.2	Lire quelques modèles sans jargon	49
10.3	Dérive dans un modèle intégré	49
10.4	Que signifie « estimer un modèle » ?	49
10.5	Vraisemblance : rendre les données observées plausibles	49
10.6	Exemple élémentaire : estimer une moyenne normale	50
10.7	Pourquoi ARMA est plus difficile à estimer qu'un AR simple ?	50
10.8	Erreur-type des paramètres	50
10.9	Box-Jenkins : une boucle plutôt qu'une recette	51
10.10	Identifier d avant p et q	51
10.11	Pourquoi la parcimonie est-elle une qualité ?	51
10.12	AIC : ajustement plus pénalité	52
10.13	BIC : une pénalité qui croît avec n	52
10.14	AIC/BIC ne sont pas des métriques de prévision future	52
10.15	Convergence numérique, optimum local et diagnostics d'estimation	53
10.16	Ce que l'on demande à un modèle estimé avant de prévoir	53
11	Résidus, prévision et validation temporelle : vérifier avant de croire	53
11.1	Résidu : ce que le modèle n'a pas expliqué	53
11.2	Que signifie « les résidus ressemblent à un bruit blanc » ?	54
11.3	Pourquoi une ACF résiduelle ne suffit pas à elle seule ?	54
11.4	La statistique de Ljung-Box, terme par terme	54
11.5	Prévoir, c'est calculer une distribution conditionnelle	55
11.6	Prévision $\text{AR}(1)$ à un pas	55
11.7	Erreur de prévision et variance à un horizon donné	56
11.8	Intervalle de prévision : le retour de 1,96	56
11.9	Prévision à origine fixe et walk-forward	57
11.10	Pourquoi un split aléatoire est généralement faux en séries temporelles	57
11.11	Fuite temporelle : les formes les plus fréquentes	57
11.12	Baselines : pourquoi une méthode sophistiquée doit battre quelque chose de simple	58
11.13	MAE : erreur absolue moyenne	58
11.14	RMSE : pénaliser davantage les grandes erreurs	59
11.15	Pourquoi la meilleure métrique dépend de la décision	59

11.16	Comparer sans réutiliser le test	59
11.17	Pourquoi une bonne moyenne ne suffit pas si la variance change	60
12	Exemple guidé intégral, exercices et synthèse	60
12.1	Un diagnostic complet sans sauter d'étape	60
12.2	Exemple numérique miniature : AR(1) de bout en bout	62
12.3	Exemple numérique miniature : bande ACF	62
12.4	Exemple numérique miniature : ADF	63
12.5	Laboratoires numériques associés	63
12.6	Exercices de compréhension conceptuelle	63
12.7	Exercices de calcul	64
12.8	Exercices d'analyse et de diagnostic	64
12.9	Checklist « zéro boîte noire » avant de quitter CH02	65
12.10	Synthèse : une seule histoire, pas trente notions séparées	65
12.11	Transition vers CH03	66

2 Voir une série temporelle avant de la modéliser

2.1 Le premier geste : regarder ce qui évolue

Une série temporelle est d'abord une succession d'observations ordonnées par le temps. Cette phrase semble banale, mais elle change toute la logique d'analyse : l'ordre n'est pas décoratif. Il porte de l'information. Permuter les observations d'une série détruit justement ce que nous voulons comprendre : continuité, mémoire, rythme, rupture et prévisibilité.

Prenons une suite très simple :

$$10, 12, 14, 16, 18, \dots$$

Sans aucun outil statistique, nous voyons déjà une organisation : la série croît régulièrement. Maintenant considérons

$$10, 15, 20, 15, 10, 15, 20, 15, \dots$$

Le niveau ne monte pas durablement, mais un motif se répète. Enfin, une suite telle que

$$10.2, 9.6, 10.7, 9.9, 10.1, \dots$$

semble fluctuer autour d'un niveau relativement stable.

INTUITION – Avant les modèles, apprendre à nommer les formes

Nous ne cherchons pas encore un ARIMA. Nous cherchons d'abord à répondre à quatre questions humaines :

1. le centre de la série change-t-il ?
2. certaines formes reviennent-elles à intervalles réguliers ?
3. l'amplitude des fluctuations reste-t-elle comparable ?
4. le passé semble-t-il contenir une information sur le futur ?

Les modèles viendront ensuite pour formaliser ces observations.

2.2 Trois briques : tendance, saisonnalité et reste

Une première représentation pédagogique consiste à écrire

$$Y_t = T_t + S_t + R_t,$$

où T_t désigne une tendance, S_t une composante saisonnière et R_t ce qui reste après avoir retiré les structures déterministes choisies.

DÉFINITION – Tendance

La **tendance** est une évolution persistante du niveau moyen sur une échelle de temps longue. Une tendance linéaire simple s'écrit

$$T_t = \beta_0 + \beta_1 t.$$

Le coefficient β_1 mesure alors le changement moyen du niveau lorsque le temps augmente d'une unité.

EXEMPLE – Calcul sans logiciel

Si $T_t = 20 + 0.5t$, alors $T_0 = 20$, $T_1 = 20.5$, $T_{10} = 25$. Le modèle ne dit pas que chaque observation vaut exactement cette quantité : il fournit une structure de niveau autour de laquelle les observations peuvent fluctuer.

DÉFINITION – Saisonnalité

La **saisonnalité** est une structure qui se répète approximativement selon une période s . Si des données mensuelles reproduisent une forme comparable chaque année, $s = 12$. Pour des données trimestrielles, une saisonnalité annuelle correspond à $s = 4$.

Un modèle périodique simple est

$$S_t = A \sin\left(\frac{2\pi t}{s} + \varphi\right),$$

où A est l'amplitude, s la période et φ la phase. Nous reviendrons profondément sur cette notion : pour l'instant, retenons seulement qu'une saisonnalité est une *structure liée à la position dans un cycle*, et non une simple tendance.

DÉFINITION – Bruit ou reste

Le terme R_t représente ce qui n'est pas expliqué par les composantes choisies. Dans un modèle probabiliste, ce reste est souvent traité comme aléatoire. Il ne faut toutefois pas appeler « bruit » tout ce que l'on n'a pas encore compris : un résidu peut encore contenir de la mémoire, une rupture, une saisonnalité oubliée ou une variance changeante.




FIGURE 1 – Une observation peut superposer tendance, saisonnalité et fluctuations. La figure vient après les définitions : elle illustre des objets déjà nommés.




FIGURE 2 – Décomposition pédagogique additive : les composantes sont montrées séparément avant leur somme.

2.3 Additif ou multiplicatif : pourquoi l'amplitude compte

Le schéma additif $Y_t = T_t + S_t + R_t$ suppose implicitement que l'amplitude saisonnière s'ajoute au niveau. Cela convient lorsque les oscillations saisonnières gardent une taille approximativement constante.

Mais certaines séries oscillent davantage lorsque leur niveau est élevé. On peut alors penser à une structure multiplicative :

$$Y_t = T_t \times S_t \times R_t.$$

Dans ce cas, un logarithme transforme les produits en sommes :

$$\log Y_t = \log T_t + \log S_t + \log R_t.$$




FIGURE 3 – Saisonnalité additive et multiplicative : même idée de répétition, mais géométrie différente de l’amplitude.

2.4 Pourquoi ce chapitre ne commence pas directement par les probabilités

Nous aurons besoin d’espérance, de variance, de covariance, de quantiles et de tests. Mais ces objets doivent répondre à des questions concrètes. Nous introduirons donc les probabilités comme un langage servant à quantifier ce que nous venons d’observer : centre, dispersion, co-mouvement et incertitude.

À RETENIR – Le fil directeur du chapitre

Nous partirons toujours d’un phénomène observable, puis seulement nous construirons l’outil mathématique nécessaire. Le lecteur doit pouvoir dire *pourquoi* une formule apparaît avant de devoir la mémoriser.

2.5 Un minimum de contexte financier, sans supposer de finance

Un **prix** P_t est simplement la valeur cotée d’un actif à la date t . Une variation absolue est $P_t - P_{t-1}$. Un rendement simple est

$$r_t = \frac{P_t - P_{t-1}}{P_{t-1}},$$

et un rendement logarithmique est

$$\ell_t = \log P_t - \log P_{t-1}.$$

Nous n’allons pas supposer que les prix ont une saisonnalité évidente comme la température. En finance, les structures périodiques sont souvent plus subtiles : jour de la semaine, ouverture/clôture, volumes intraday, volatilité intraday, calendrier de publications. Cette prudence sera essentielle lorsque nous traiterons la saisonnalité en profondeur.

2.6 La question suivante : qu’est-ce qui est stable ?

Nous savons maintenant décrire visuellement plusieurs formes. Mais pour comparer des observations éloignées dans le temps, estimer une moyenne, calculer une corrélation ou ajuster un modèle, il faut préciser ce qui reste suffisamment stable. C’est le rôle de la stationnarité. Avant de la définir rigoureusement, nous devons construire le petit langage probabiliste nécessaire.

3 Les probabilités dont nous avons besoin — seulement quand elles deviennent utiles

3.1 Pourquoi introduire maintenant les probabilités ?

Nous venons de voir qu'une courbe peut contenir tendance, saisonnalité et fluctuations. Pour dire rigoureusement qu'une série 'fluctue autour de 10', que deux variables 'bougent ensemble' ou qu'une autocorrélation observée peut être due au hasard, il nous faut maintenant un langage quantitatif de l'incertitude. C'est exactement le rôle des probabilités. Nous ne les introduisons donc pas comme un préalable abstrait, mais comme une boîte à outils appelée par des questions déjà rencontrées.

Nous allons donc construire uniquement les objets dont nous avons besoin. L'objectif n'est pas de faire un cours abstrait de théorie de la mesure, mais d'éviter qu'un terme comme « espérance », « quantile », « p-value » ou « loi normale » soit utilisé comme un mot magique.

FONDATION – Expérience aléatoire, issue et événement

Une **expérience aléatoire** est une expérience dont on ne connaît pas avec certitude l'issue avant de l'observer. L'ensemble des issues possibles est noté Ω . Un **événement** est un ensemble d'issues auquel on attribue une probabilité entre 0 et 1.

EXEMPLE – Un dé suffit

Pour un dé équilibré, $\Omega = \{1, 2, 3, 4, 5, 6\}$. L'événement « obtenir un nombre pair » est $A = \{2, 4, 6\}$ et $P(A) = 3/6 = 1/2$. Cette idée très simple reste la même lorsque l'issue devient un rendement, une erreur de prévision ou un choc de marché ; seul l'espace des valeurs possibles devient plus riche.

3.2 Variable aléatoire : transformer une issue en nombre

Une **variable aléatoire** X est une fonction qui associe un nombre à chaque issue. Cette définition peut sembler formelle ; son intérêt est concret : elle nous permet d'utiliser l'algèbre et l'analyse pour raisonner sur l'incertain.

Une variable peut être **discrète**, lorsqu'elle prend des valeurs séparées, ou **continue**, lorsqu'elle peut prendre une infinité de valeurs dans un intervalle.

EXEMPLE – Gain discret

Supposons qu'un jeu donne $X = -2$ avec probabilité 0,08, $X = -1$ avec probabilité 0,17, $X = 0$ avec probabilité 0,50, $X = 1$ avec probabilité 0,17 et $X = 2$ avec probabilité 0,08. La somme des probabilités vaut 1. La figure suivante représente la loi de X .




FIGURE 4 – Une loi discrète associe à chaque valeur possible une probabilité.

3.3 Espérance : le centre probabiliste, pas une promesse

Pour une variable discrète prenant les valeurs $x_1, \dots, x_m$ avec probabilités $p_1, \dots, p_m$, l'**espérance** est

$$\mathbb{E}[X] = \sum_{i=1}^m x_i p_i.$$

Elle est une moyenne pondérée par les probabilités. Elle ne dit pas quelle valeur sera observée au prochain tirage.

EXEMPLE – Calcul complet

Avec la loi précédente,

$$\mathbb{E}[X] = (-2)(0,08) + (-1)(0,17) + 0(0,50) + 1(0,17) + 2(0,08) = 0.$$

Le gain moyen théorique vaut zéro, alors que la plupart des réalisations individuelles ne sont pas égales à zéro.

Pour une variable continue de densité $f_X(x)$, la somme est remplacée par une intégrale :

$$\mathbb{E}[X] = \int_{-\infty}^{+\infty} x f_X(x) dx.$$

Nous utiliserons surtout l'interprétation : $\mathbb{E}[X]$ est le centre de gravité probabiliste de la distribution.

3.4 Variance et écart-type : quantifier la dispersion

Deux variables peuvent avoir la même espérance et des risques très différents. La **variance** mesure l'écart quadratique moyen au centre :

$$\text{Var}(X) = \mathbb{E}[(X - \mu)^2], \quad \mu = \mathbb{E}[X].$$

Une identité utile est

$$\text{Var}(X) = \mathbb{E}[X^2] - \mathbb{E}[X]^2.$$

L'**écart-type** est

$$\sigma_X = \sqrt{\text{Var}(X)}.$$

Son avantage est d'être exprimé dans la même unité que X .

DÉRIVATION – Pourquoi mettre les écarts au carré ?

Si l'on calculait simplement $\mathbb{E}[X - \mu]$, on obtiendrait toujours zéro : les écarts positifs et négatifs se compensent. Le carré rend tous les écarts positifs et pénalise davantage les écarts extrêmes. La racine carrée finale ramène l'unité au niveau original.

3.5 Covariance : deux variables bougent-elles ensemble ?

Pour deux variables X et Y ,

$$\text{Cov}(X, Y) = \mathbb{E}[(X - \mu_X)(Y - \mu_Y)].$$

Le produit des écarts explique le signe :

- si X et Y sont souvent simultanément au-dessus ou simultanément au-dessous de leur moyenne, les produits sont souvent positifs et la covariance tend à être positive ;
- si l'un est souvent au-dessus lorsque l'autre est au-dessous, elle tend à être négative ;
- si aucune relation linéaire systématique n'apparaît, elle peut être proche de zéro.

La covariance dépend des unités. Multiplier X par 100 multiplie aussi la covariance par 100. Pour comparer des relations entre variables d'échelles différentes, on normalise.

3.6 Corrélation : covariance sans unité

La corrélation de Pearson est

$$\text{Corr}(X, Y) = \rho_{XY} = \frac{\text{Cov}(X, Y)}{\sigma_X \sigma_Y}, \quad -1 \leq \rho_{XY} \leq 1.$$

Le dénominateur retire l'effet des unités. La valeur $+1$ signifie une relation linéaire positive parfaite, -1 une relation linéaire négative parfaite, et 0 l'absence de relation *linéaire* détectable.

Corrélation : sens et intensité d'une dépendance linéaire




FIGURE 5 – La corrélation résume le sens et l'intensité d'une dépendance linéaire, pas toute dépendance possible.

ATTENTION – Corrélation nulle n'implique pas indépendance

La corrélation ne mesure qu'une relation linéaire. Par exemple, si X est symétrique autour de zéro et $Y = X^2$, on peut avoir $\text{Corr}(X, Y) = 0$ alors que Y est entièrement déterminé par X . L'indépendance est une propriété beaucoup plus forte.

3.7 Indépendance : connaître l'une ne change pas la loi de l'autre

Intuitivement, X et Y sont indépendantes si l'information sur X ne modifie pas les probabilités relatives à Y . Pour des événements A et B , l'indépendance s'écrit

$$P(A \cap B) = P(A)P(B).$$

Sous des conditions usuelles, l'indépendance implique une covariance nulle lorsque les moments existent. L'inverse est faux en général.

Cette distinction deviendra cruciale : un **bruit blanc faible** est non autocorrélé, mais n'est pas nécessairement indépendant.

3.8 Fonction de répartition : accumuler les probabilités

La **fonction de répartition** d'une variable X est

$$F_X(x) = P(X \leq x).$$

Elle répond à une question très concrète : « quelle proportion de la probabilité se trouve à gauche de x ? ». Pour une variable continue de densité f_X ,

$$F_X(x) = \int_{-\infty}^x f_X(u) du.$$

L'aire totale sous la densité vaut 1.

3.9 Quantile : poser la question à l'envers

Un quantile cherche une valeur à partir d'une probabilité. Le quantile d'ordre p est une valeur q_p telle que

$$P(X \leq q_p) = p.$$

Par exemple, le quantile 0,95 est un seuil sous lequel se trouvent 95% des valeurs selon la distribution considérée.

EXEMPLE – Quantile et classement

Si le 95e centile d'une distribution de temps d'attente vaut 12 minutes, cela signifie qu'environ 95% des temps sont inférieurs ou égaux à 12 minutes et 5% supérieurs. Un quantile n'est donc pas une moyenne : c'est un seuil de classement probabiliste.

3.10 La loi normale : pourquoi la courbe en cloche apparaît partout

Une variable normale de moyenne μ et variance σ^2 est notée

$$X \sim \mathcal{N}(\mu, \sigma^2).$$

Sa densité est

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp \left[-\frac{(x - \mu)^2}{2\sigma^2} \right].$$

La forme en cloche vient du terme exponentiel : les valeurs proches de μ sont les plus denses, et la densité décroît lorsque l'on s'éloigne du centre.

ATTENTION – Une densité n'est pas une probabilité en un point

Pour une variable continue, $P(X = x) = 0$ pour tout point isolé. Les probabilités correspondent à des **aires sur des intervalles**, par exemple $P(a \leq X \leq b)$.

3.11 Standardisation : compter les écarts-types

Si

$$X \sim \mathcal{N}(\mu, \sigma^2),$$

on définit

$$Z = \frac{X - \mu}{\sigma}.$$

Alors

$$Z \sim \mathcal{N}(0, 1).$$

La variable Z indique combien d'écarts-types séparent X de sa moyenne. Une valeur $Z = 2$ signifie « deux écarts-types au-dessus du centre ».

3.12 D'où vient exactement le nombre 1,96 ?

Soit $Z \sim \mathcal{N}(0, 1)$ et Φ sa fonction de répartition. Le quantile d'ordre 0,975 vaut approximativement

$$\Phi^{-1}(0,975) = 1,959964 \dots \approx 1,96.$$

Par symétrie,

$$\Phi(-1,96) \approx 0,025.$$

Donc

$$P(-1,96 \leq Z \leq 1,96) = 0,975 - 0,025 \approx 0,95.$$




FIGURE 6 – Le nombre 1,96 est le quantile normal qui laisse environ 2,5% dans chacune des deux queues et 95% au centre.

À RETENIR – 1,96 n'est pas une constante universelle de la statistique

Le nombre 1,96 est approprié lorsque la statistique standardisée suit exactement ou approximativement une loi normale centrée réduite et que l'on souhaite un intervalle bilatéral central de 95%. Pour 90%, on utilise environ 1,645 ; pour 99%, environ 2,576. D'autres lois ou petits

échantillons peuvent conduire à d'autres quantiles.

3.13 Population, échantillon, estimateur : pourquoi les nombres calculés fluctuent

Une **population** désigne le mécanisme probabiliste ou l'ensemble conceptuel dont proviennent les données. Un **échantillon** est la collection finie effectivement observée. Un paramètre comme μ appartient au mécanisme théorique ; un estimateur comme

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$$

est une variable aléatoire avant observation, car sa valeur dépend de l'échantillon obtenu.

Si l'on répète l'expérience, on obtient une autre moyenne. La distribution de ces moyennes est appelée **distribution d'échantillonnage** de l'estimateur.

3.14 Erreur-type : la variabilité d'un estimateur

Supposons $X_1, \dots, X_n$ indépendantes, de même moyenne μ et même variance σ^2 . Alors

$$\text{Var}(\bar{X}_n) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(X_i) = \frac{\sigma^2}{n}.$$

Donc

$$\text{SE}(\bar{X}_n) = \sqrt{\text{Var}(\bar{X}_n)} = \frac{\sigma}{\sqrt{n}}.$$

Le symbole SE vient de *standard error*, erreur-type.

INTUITION – Pourquoi apparaît si souvent $1/\sqrt{n}$?

Doubler la taille de l'échantillon ne divise pas l'incertitude par deux. Pour diviser l'erreur-type par deux, il faut environ multiplier n par quatre. Cette loi en racine carrée réapparaîtra dans les bandes approximatives de l'ACF.

3.15 Le Théorème Central Limite : la normale émerge des moyennes

Sous des conditions classiques, si les X_i sont indépendantes et identiquement distribuées, de moyenne μ et variance finie σ^2 , alors

$$\frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \xrightarrow{d} \mathcal{N}(0, 1).$$

Équivalamment,

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} \mathcal{N}(0, \sigma^2).$$

FONDATION – Lire chaque morceau de la formule

$\bar{X}_n - \mu$ est l'erreur commise par la moyenne d'échantillon. Elle devient plus petite lorsque n augmente. Le facteur $\sqrt{n}$ la remet à une échelle non dégénérée. Le symbole $\xrightarrow{d}$ signifie convergence en distribution : la forme de la distribution de cette quantité standardisée se rapproche de la loi normale.

ATTENTION – Le TCL ne dit pas que les données deviennent normales

Même si les observations sont uniformes, asymétriques ou discrètes, c'est la **distribution de certaines sommes ou moyennes standardisées** qui devient approximativement normale. Les observations individuelles gardent leur distribution d'origine.

Nous pouvons maintenant vérifier cette idée numériquement. On simule des variables uniformes, donc très loin d'une cloche, puis on observe les moyennes de groupes de tailles croissantes.




FIGURE 7 – Le TCL en action : lorsque la taille des groupes augmente, la distribution des moyennes se rapproche d'une forme normale.

POINT DE VUE INGÉNIEUR – Ce que Python vérifie, et non ce qu'il « prouve »

La simulation illustre la théorie sur un cas choisi. Elle ne remplace pas le théorème. Sa valeur pédagogique est de rendre visible un objet abstrait : la distribution d'échantillonnage.

3.16 Intervalle de confiance et intervalle de prévision : ne pas les confondre

Un **intervalle de confiance** concerne l'incertitude sur un paramètre inconnu. Un **intervalle de prévision** concerne l'incertitude sur une future observation. Même lorsqu'ils utilisent tous deux un quantile comme 1,96, ils ne répondent pas à la même question.

Lorsque, asymptotiquement,

$$\frac{\hat{\theta} - \theta}{SE(\hat{\theta})} \approx \mathcal{N}(0, 1),$$

on obtient un intervalle approximatif à 95% :

$$\hat{\theta} \pm 1,96 SE(\hat{\theta}).$$

Nous retrouverons exactement cette logique pour comprendre les bandes d'ACF.

3.17 Probabilité, test, niveau α et p-value

Avant d'aborder ADF, KPSS ou Ljung–Box, nous devons séparer quatre idées.

- Une **hypothèse nulle** H_0 est la situation de référence que le test met à l'épreuve.
- Le **niveau** α est un seuil choisi à l'avance, souvent 5%.
- Une **statistique de test** résume l'écart entre les données et ce qui serait attendu sous H_0 .
- La **p-value** mesure, sous H_0 , à quel point une statistique au moins aussi extrême que celle observée serait surprenante.

ATTENTION – Une p-value n'est pas $P(H_0 \mid \text{données})$

Une p-value de 0,03 ne signifie pas « il y a 3% de chances que H_0 soit vraie ». Elle signifie que, si H_0 était vraie et si les hypothèses du test étaient satisfaites, obtenir un résultat au moins aussi extrême serait relativement rare selon la distribution de référence.

À RETENIR – Ce que nous avons construit

Nous disposons maintenant des briques nécessaires pour la suite : moyenne, variance, covariance, corrélation, indépendance, distribution, fonction de répartition, quantile, loi normale, erreur-type, TCL, hypothèse nulle et p-value. Nous pouvons donc parler d'une série temporelle sans cacher des notions probabilistes sous les formules.

4 Du hasard au temps : processus, retards et stationnarité

4.1 Une série temporelle n'est pas un tableau ordinaire

Dans un tableau classique, l'ordre des lignes peut souvent être mélangé sans changer le problème. Dans une série temporelle, permuter les observations détruit une partie de l'information : le passé précède le présent, et le présent précède le futur.

Notons une suite observée

$$X_1, X_2, \dots, X_t, \dots$$

où l'indice t représente le temps. Au moment t , les observations futures $X_{t+1}, X_{t+2}, \dots$ ne sont pas encore disponibles. Cette contrainte simple sera à la base de toute validation honnête.

4.2 Processus stochastique et réalisation

Un **processus stochastique** est une famille de variables aléatoires indexées par le temps :

$$\{X_t\}_{t \in \mathcal{T}}.$$

Chaque X_t représente ce qui pourrait être observé au temps t avant que l'observation n'ait lieu. La suite numérique réellement observée est une **réalisation** ou **trajectoire** du processus.

INTUITION – Une seule trajectoire parmi de nombreuses possibles

Une simulation de marche aléatoire produit une courbe. Si l'on change les chocs aléatoires, on obtient une autre courbe. Le processus est la règle probabiliste qui engendre toutes les courbes possibles ; notre dataset n'en contient généralement qu'une seule.

Cette distinction explique pourquoi l'inférence est difficile : nous voulons comprendre une loi temporelle à partir d'une trajectoire finie.

4.3 Le retard ou lag

Le **retard d'ordre k** de X_t est X_{t-k} . Pour $k = 1$, il s'agit de la valeur précédente ; pour $k = 2$, de celle observée deux périodes plus tôt.

EXEMPLE – Une table de retards

Supposons

$$X_1 = 10, \quad X_2 = 12, \quad X_3 = 11, \quad X_4 = 14.$$

Au temps $t = 4$,

$$X_t = 14, \quad X_{t-1} = 11, \quad X_{t-2} = 12.$$

Construire une variable retardée ne signifie rien de plus mystérieux que réaligner la série avec son propre passé.




FIGURE 8 – Une série et son premier retard aligné sur le temps courant. La figure vient après la définition du lag.

4.4 Information passée et innovation

Un modèle temporel cherche souvent à séparer deux composantes :

$$\text{valeur actuelle} = \text{partie prévisible depuis le passé} + \text{information nouvelle.}$$

L'information nouvelle est appelée **innovation** et notée souvent ε_t .

Dans un modèle idéalement spécifié, ε_t représente ce que le passé disponible ne permettait pas de prévoir à l'instant précédent.

ATTENTION – Innovation, erreur et résidu ne sont pas strictement synonymes

L'innovation ε_t appartient au modèle théorique. Le **résidu** $\hat{\varepsilon}_t$ est son approximation calculée après estimation sur des données. L'**erreur de prévision** compare une valeur future réalisée à une prévision produite antérieurement. Les trois objets peuvent être proches en pratique, mais ils répondent à des rôles différents.

4.5 Conditionnel et inconditionnel

La distinction entre une quantité **inconditionnelle** et une quantité **conditionnelle au passé** est fondamentale.

L'espérance inconditionnelle $\mathbb{E}[X_t]$ décrit le niveau moyen du processus sans préciser l'information déjà connue. L'espérance conditionnelle

$$\mathbb{E}[X_{t+1} \mid X_t, X_{t-1}, \dots]$$

répond à une autre question : « compte tenu de ce que je sais aujourd'hui, quelle est ma meilleure moyenne probabiliste pour demain ? ».

Nous utiliserons cette idée lorsque nous parlerons de prévision.

4.6 Pourquoi la stationnarité est-elle importante ?

Pour apprendre une structure à partir du passé, il faut qu'au moins une partie du mécanisme soit stable. Si la moyenne, la variance ou les dépendances changent constamment de manière non modélisée, les statistiques calculées hier peuvent perdre leur sens demain.

La stationnarité n'affirme pas que la série est immobile. Elle affirme que certaines propriétés probabilistes sont invariantes dans le temps.

4.7 Stationnarité stricte

Un processus est **strictement stationnaire** si, pour tout entier m , tout choix de dates $t_1, \dots, t_m$ et tout décalage h , les vecteurs

$$(X_{t_1}, \dots, X_{t_m}) \quad \text{et} \quad (X_{t_1+h}, \dots, X_{t_m+h})$$

ont la même loi jointe.

Cette définition dit que déplacer l'origine du calendrier ne change aucune distribution finie du processus. Elle est très forte et souvent difficile à vérifier directement.

4.8 Stationnarité faible ou de second ordre

En pratique, on utilise très souvent la **stationnarité faible**. Elle impose trois conditions :

$$\mathbb{E}[X_t] = \mu \quad \text{indépendant de } t,$$

$$\text{Var}(X_t) = \sigma^2 < \infty \quad \text{indépendant de } t,$$

et

$$\text{Cov}(X_t, X_{t-k}) = \gamma(k),$$

c'est-à-dire que la covariance dépend seulement du retard k , pas de la date absolue t .

FONDATION – Pourquoi « de second ordre » ?

L'espérance est un moment d'ordre 1. La variance et la covariance utilisent des produits quadratiques et sont des moments d'ordre 2. La stationnarité faible stabilise essentiellement ces deux premiers niveaux d'information.

4.9 Quatre séries qui peuvent sembler proches à l'œil mais ne le sont pas

Considérons quatre mécanismes :

1. un processus fluctuant autour d'une moyenne constante ;
2. un processus stationnaire autour d'une tendance déterministe ;
3. une marche aléatoire dont les chocs s'accumulent ;
4. un processus dont la moyenne reste proche de zéro mais dont la variance change brutalement.




FIGURE 9 – Quatre mécanismes différents : stabilité complète de second ordre, tendance, racine unitaire et rupture de variance.

4.10 Tendance déterministe et stationnarité autour d'une tendance

Une série peut s'écrire

$$X_t = a + bt + u_t,$$

où u_t est stationnaire. Le niveau X_t n'a pas une moyenne constante :

$$\mathbb{E}[X_t] = a + bt.$$

Mais après retrait de la tendance $a + bt$, le résidu u_t peut être stationnaire.

C'est très différent d'une marche aléatoire : dans une série à tendance déterministe, un choc transitoire peut s'éteindre autour d'une trajectoire prévisible ; dans une marche aléatoire, les chocs modifient durablement le niveau.

4.11 Rupture de variance

Même si $\mathbb{E}[X_t] = 0$ pour tout t , une série n'est pas stationnaire au second ordre si

$$\text{Var}(X_t)$$

change systématiquement avec le temps. Ce cas prépare le chapitre suivant : en finance, la variance peut évoluer sans que la moyenne des rendements présente une structure forte.

ATTENTION – « Visuellement stable » ne suffit pas

Une trajectoire courte peut masquer une non-stationnarité ; inversement, une série stationnaire peut connaître de grandes excursions. La stationnarité est une propriété probabiliste, pas un simple jugement graphique.

4.12 Un minimum de vocabulaire financier pour les exemples

Nous n'avons besoin ici que de trois objets.

DÉFINITION – Prix, rendement simple, rendement logarithmique

Si $P_t > 0$ désigne le prix d'un actif au temps t , le rendement simple est

$$r_t = \frac{P_t - P_{t-1}}{P_{t-1}},$$

et le rendement logarithmique est

$$g_t = \log P_t - \log P_{t-1} = \log \left(\frac{P_t}{P_{t-1}} \right).$$

Pour de petites variations, $g_t \approx r_t$.

Le niveau P_t peut être très persistant et non stationnaire, tandis que les rendements r_t ou g_t sont souvent plus proches d'une stationnarité en moyenne. Ce sont des tendances empiriques fréquentes, pas des lois universelles.

EXEMPLE – Prix et rendement

Si un prix passe de 100 à 102, le rendement simple vaut

$$\frac{102 - 100}{100} = 0,02 = 2\%.$$

Le rendement logarithmique vaut

$$\log(102) - \log(100) \approx 0,0198 = 1,98\%.$$

Le chapitre ne suppose aucune autre connaissance financière.

À RETENIR – Avant de modéliser

Toujours demander : quelle variable observe-t-on ? Son niveau est-il naturellement susceptible de dériver ? Sa moyenne est-elle stable ? Sa variance est-elle stable ? Une transformation — rendement, logarithme, différence, retrait d'une tendance — a-t-elle une justification ?

5 Bruit blanc, autocovariance et ACF : mesurer la mémoire sans magie

5.1 Le bruit blanc : une référence de « non-mémoire linéaire »

Un **bruit blanc faible** $\{\varepsilon_t\}$ vérifie

$$\mathbb{E}[\varepsilon_t] = 0, \quad \text{Var}(\varepsilon_t) = \sigma_\varepsilon^2 < \infty, \quad \text{Cov}(\varepsilon_t, \varepsilon_{t-k}) = 0 \quad \text{pour } k \neq 0.$$

Le terme « blanc » vient d'une analogie avec le bruit blanc en traitement du signal : aucune fréquence particulière ne porte une structure systématique dominante.

ATTENTION – Trois notions à ne jamais confondre

bruit blanc faible $\neq$ suite indépendante $\neq$ bruit blanc gaussien.

Le bruit blanc faible impose surtout une absence de dépendance *linéaire* mesurée par la covariance. Une suite iid impose une indépendance et une loi identique dans le temps. Un bruit blanc gaussien ajoute une loi normale ; dans un cadre conjointement gaussien, non-corrélation et indépendance coïncident, ce qui est un cas particulier très commode.

5.2 Pourquoi un bruit blanc n'a pas besoin d'être normal

Prenons deux suites : l'une faite de tirages normaux, l'autre de tirages uniformes centrés, tous indépendants. Les deux peuvent avoir moyenne zéro, variance constante et autocovariance nulle. Elles sont toutes deux des bruits blancs, bien que leurs histogrammes soient très différents.

“Bruit blanc” décrit la mémoire, pas nécessairement la forme de la loi




FIGURE 10 – Deux bruits blancs peuvent avoir la même absence de mémoire linéaire mais des distributions marginales très différentes.

5.3 La marche aléatoire : intégrer un bruit blanc

Une marche aléatoire simple est

$$X_t = X_{t-1} + \varepsilon_t.$$

En remontant jusqu'à l'origine,

$$X_t = X_0 + \sum_{j=1}^t \varepsilon_j.$$

Si les innovations sont indépendantes, de variance σ_ε^2 , alors

$$\text{Var}(X_t) = t\sigma_\varepsilon^2.$$

La variance du niveau augmente avec t : le processus n'est pas stationnaire.

EXEMPLE – Un choc permanent

Si $X_0 = 100$ et que $\varepsilon_1 = 5$, puis que tous les chocs suivants valent zéro, alors $X_1 = 105$ et $X_t = 105$ pour tout $t \geq 1$. Le choc de 5 n'est jamais oublié. Nous comparerons bientôt cette mémoire permanente à l'oubli géométrique d'un AR(1).

5.4 Autocovariance : appliquer la covariance à une série et son passé

Pour un processus stationnaire faible, l'autocovariance au retard k est

$$\gamma(k) = \text{Cov}(X_t, X_{t-k}).$$

Parce que le processus est stationnaire, $\gamma(k)$ ne dépend pas de t . Elle répond à la question : « les écarts à la moyenne observés aujourd'hui et k périodes auparavant ont-ils tendance à avoir le même signe et la même intensité ? »

Au retard zéro,

$$\gamma(0) = \text{Cov}(X_t, X_t) = \text{Var}(X_t) = \sigma_X^2.$$

Cette identité est fondamentale pour normaliser l'autocovariance.

5.5 Autocorrélation théorique : une mesure sans unité

La fonction d'autocorrélation est

$$\rho(k) = \frac{\gamma(k)}{\gamma(0)} = \frac{\text{Cov}(X_t, X_{t-k})}{\text{Var}(X_t)}.$$

Ainsi

$$\rho(0) = 1, \quad -1 \leq \rho(k) \leq 1.$$

EXEMPLE – Lecture de trois valeurs

Si $\rho(1) = 0,8$, une valeur au-dessus de sa moyenne tend à être suivie d'une valeur encore au-dessus de sa moyenne. Si $\rho(1) = -0,6$, les écarts tendent à alterner de signe. Si $\rho(1) \approx 0$, on ne détecte pas de relation linéaire forte au lag 1 ; cela ne prouve pas l'indépendance.

5.6 ACF théorique et ACF empirique : propriété du modèle versus estimation

La quantité $\rho(k)$ appartient au processus théorique et est inconnue. Avec un échantillon $x_1, \dots, x_n$, on calcule une estimation. Une définition courante est

$$\hat{\rho}(k) = \frac{\sum_{t=k+1}^n (x_t - \bar{x})(x_{t-k} - \bar{x})}{\sum_{t=1}^n (x_t - \bar{x})^2}.$$

FONDATION – Lire la formule comme une procédure

Pour un retard k :

1. on aligne chaque x_t avec x_{t-k} ;
2. on centre les deux valeurs par la moyenne $\bar{x}$;
3. on multiplie les écarts alignés ;
4. on additionne ces produits ;
5. on normalise par la somme des carrés des écarts.

La formule n'est donc qu'une corrélation entre la série et une copie décalée d'elle-même.

5.7 Calcul manuel d'une autocorrélation

Prenons la petite série

$$x = (2, 4, 3, 5, 4, 6).$$

Sa moyenne vaut

$$\bar{x} = \frac{2 + 4 + 3 + 5 + 4 + 6}{6} = 4.$$

Pour $k = 1$, les couples alignés sont

$$(4, 2), (3, 4), (5, 3), (4, 5), (6, 4).$$

Le numérateur devient

$$(4-4)(2-4) + (3-4)(4-4) + (5-4)(3-4) + (4-4)(5-4) + (6-4)(4-4) = -1.$$

Le dénominateur est

$$(2-4)^2 + (4-4)^2 + (3-4)^2 + (5-4)^2 + (4-4)^2 + (6-4)^2 = 10.$$

Donc, avec cette convention,

$$\hat{\rho}(1) = -0,1.$$

L'échantillon est minuscule : le but n'est pas d'inférer une structure, mais de rendre la mécanique transparente.

5.8 Pourquoi l'ACF d'un bruit blanc n'est-elle jamais exactement zéro ?

Même si la vraie autocorrélation d'un bruit blanc satisfait

$$\rho(k) = 0 \quad (k \neq 0),$$

l'estimation $\hat{\rho}(k)$ est calculée sur un échantillon fini. Les produits aléatoires positifs et négatifs ne se compensent jamais parfaitement. Une ACF empirique contient donc de petits pics fortuits.

La question devient statistique : quelle amplitude de $\hat{\rho}(k)$ est compatible avec de simples fluctuations d'échantillonnage ?

5.9 Pourquoi l'erreur-type est approximativement $1/\sqrt{n}$ sous bruit blanc ?

Sous un bruit blanc suffisamment régulier, pour un lag fixe $k > 0$, le numérateur de l'autocovariance empirique ressemble à une somme d'environ n produits

$$\varepsilon_t \varepsilon_{t-k}.$$

Sous indépendance ou sous des conditions asymptotiques appropriées, ces produits ont moyenne nulle et une variance de l'ordre de σ^4 . La somme a donc une variance de l'ordre de $n\sigma^4$. Après division par un dénominateur de l'ordre de $n\sigma^2$, l'échelle de fluctuation devient de l'ordre

$$\frac{\sqrt{n\sigma^4}}{n\sigma^2} = \frac{1}{\sqrt{n}}.$$

Ce raisonnement d'échelle ne remplace pas la démonstration asymptotique, mais explique pourquoi la racine de n apparaît naturellement.

Une approximation classique sous bruit blanc est

$$\hat{\rho}(k) \stackrel{approx}{\sim} \mathcal{N}\left(0, \frac{1}{n}\right), \quad k > 0.$$

Ainsi

$$\text{SE}(\hat{\rho}(k)) \approx \frac{1}{\sqrt{n}}.$$

5.10 Enfin, la bande $\pm 1,96/\sqrt{n}$

Nous avons déjà expliqué le quantile 1,96. Si

$$Z_k = \frac{\hat{\rho}(k) - 0}{1/\sqrt{n}}$$

est approximativement normal standard, alors

$$P(-1,96 \leq Z_k \leq 1,96) \approx 0,95.$$

En revenant à $\hat{\rho}(k)$,

$$P\left(-\frac{1,96}{\sqrt{n}} \leq \hat{\rho}(k) \leq \frac{1,96}{\sqrt{n}}\right) \approx 0,95.$$

À RETENIR – La bande est maintenant une conséquence

$$\text{bande approximative 95\% sous bruit blanc : } \pm \frac{1,96}{\sqrt{n}}.$$

Elle résulte de deux éléments déjà construits : l'erreur-type approximative $1/\sqrt{n}$ et le quantile normal bilatéral 1,96.

Nous pouvons maintenant regarder une ACF de bruit blanc sans utiliser un objet non expliqué.




FIGURE 11 – ACF empirique d'un bruit blanc. Les barres ne sont pas exactement nulles ; les lignes pointillées matérialisent la bande asymptotique approximative.

5.11 Expérience de Monte Carlo : voir la distribution d'échantillonnage de l'ACF

Une simulation de 10 000 bruits blancs de taille $n = 200$ permet de calculer 10 000 valeurs de $\hat{\rho}(1)$. Leur histogramme se rapproche d'une loi normale centrée en zéro, avec un écart-type proche de $1/\sqrt{200}$.




FIGURE 12 – Distribution empirique de $\hat{\rho}(1)$ sur 10 000 bruits blancs. C’est cette distribution d’échantillonnage qui justifie l’usage d’une bande approximative.

5.12 La formule de Bartlett : ce que l’on peut dire précisément

Pour un bruit blanc, la variance asymptotique simplifiée des autocorrélations empiriques non nulles est approximativement $1/n$. Pour un processus autocorrélé plus général, les résultats de Bartlett conduisent à des expressions où la variance dépend des autocorrélations du processus lui-même (Bartlett, 1946 ; Brockwell et Davis, 2016).

ATTENTION – Ne pas appeler toute bande ACF « la formule complète de Bartlett »

La règle $\pm 1,96/\sqrt{n}$ est une référence pédagogique et asymptotique particulièrement naturelle sous bruit blanc. Des logiciels peuvent construire des intervalles selon des conventions différentes, et les hypothèses changent lorsque la série n’est pas un bruit blanc, lorsque la variance n’est pas stable ou lorsque l’on estime des paramètres avant de calculer les résidus.

5.13 Multiplicité : pourquoi un pic sur vingt peut apparaître par hasard

Une bande à 95% concerne approximativement un lag pris isolément. Si l’on examine 20 lags, on effectue implicitement de nombreuses comparaisons. Même sous bruit blanc, il n’est donc pas surprenant qu’une barre isolée franchisse parfois la bande.

Si, de manière simplifiée, 20 événements étaient indépendants et chacun restait dans sa bande avec probabilité 0,95, la probabilité que les 20 restent tous dedans serait

$$0,95^{20} \approx 0,358.$$

Les lags ne sont pas indépendants de cette manière exacte, mais le calcul donne l’intuition : **un dépassement isolé n’est pas automatiquement une découverte.**

5.14 Ce que l’ACF peut et ne peut pas dire

L’ACF est utile pour :

- visualiser une dépendance linéaire selon le retard ;
- comparer des structures théoriques AR, MA et ARMA ;

- inspecter des résidus ;
- suggérer des modèles candidats.

Elle ne suffit pas à :

- prouver une causalité ;
- détecter toutes les dépendances non linéaires ;
- garantir une prévisibilité économiquement exploitable ;
- transformer automatiquement tout pic en paramètre de modèle.

À RETENIR – La bonne question

Une ACF n'est pas une collection de barres à « lire » mécaniquement. Chaque barre est un estimateur soumis au hasard d'échantillonnage. La bonne question est : quelle structure globale, compatible avec la taille de l'échantillon et les hypothèses du processus, apparaît au-delà des fluctuations fortuites ?

6 Le modèle autorégressif : comprendre la persistance de l'intérieur

6.1 Pourquoi introduire un modèle AR ?

L'ACF nous permet de constater qu'une série peut conserver une mémoire linéaire. Il faut maintenant un mécanisme capable de générer cette mémoire. L'idée autorégressive est la plus directe : une partie de la valeur présente provient de la valeur passée.

Le modèle AR(1) est

$$X_t = c + \phi X_{t-1} + \varepsilon_t,$$

où :

- c est une constante ;
- ϕ est le coefficient autorégressif ;
- ε_t est l'innovation nouvelle au temps t .

INTUITION – Mémoire et nouveauté

Le terme ϕX_{t-1} transporte une partie du passé dans le présent ; ε_t apporte ce qui vient d'arriver et n'était pas contenu dans ce passé. Le coefficient ϕ ne mesure pas la taille des chocs ; il mesure la manière dont le système conserve ou inverse leur influence.

6.2 Dérouler l'équation : la meilleure façon de voir la mémoire

Partons de

$$X_t = c + \phi X_{t-1} + \varepsilon_t.$$

À la date précédente,

$$X_{t-1} = c + \phi X_{t-2} + \varepsilon_{t-1}.$$

En remplaçant X_{t-1} dans la première équation,

$$X_t = c + \phi(c + \phi X_{t-2} + \varepsilon_{t-1}) + \varepsilon_t,$$

d'où

$$X_t = c(1 + \phi) + \phi^2 X_{t-2} + \phi \varepsilon_{t-1} + \varepsilon_t.$$

En répétant k fois,

$$X_t = c \sum_{j=0}^{k-1} \phi^j + \phi^k X_{t-k} + \sum_{j=0}^{k-1} \phi^j \varepsilon_{t-j}.$$

Cette identité contient presque toute la théorie de l'AR(1).

6.3 La suite géométrique et l'oubli du passé lointain

Pour $\phi \neq 1$,

$$\sum_{j=0}^{k-1} \phi^j = \frac{1 - \phi^k}{1 - \phi}.$$

Si

$$|\phi| < 1,$$

alors

$$\phi^k \longrightarrow 0 \quad \text{lorsque } k \rightarrow \infty.$$

Deux conséquences apparaissent :

1. la contribution de la condition initiale X_{t-k} disparaît ;
2. la somme des effets d'innovations anciennes converge.

À RETENIR – Sens dynamique de $|\phi| < 1$

La condition $|\phi| < 1$ n'est pas d'abord une règle à mémoriser. Elle signifie que le système **oublie progressivement le passé lointain**. C'est le mécanisme qui permet à un équilibre probabiliste stationnaire d'exister.

6.4 Propagation d'un choc

Supposons qu'une innovation supplémentaire d'amplitude 1 arrive au temps t . Son effet direct est 1 à t , puis

$$\phi, \phi^2, \phi^3, \dots$$

aux horizons successifs.

EXEMPLE – $\phi = 0,8$

Un choc de +10 contribue environ

$$10, \quad 8, \quad 6,4, \quad 5,12, \dots$$

aux périodes successives. Le choc ne disparaît pas immédiatement, mais son influence décroît géométriquement.




FIGURE 13 – Survie d'un même choc pour plusieurs valeurs de ϕ . Les régimes stationnaire, oscillant, unitaire et explosif deviennent visibles.

6.5 Les régimes de ϕ

$\phi = 0$. Le modèle devient

$$X_t = c + \varepsilon_t.$$

Il n'y a plus de mémoire autorégressive.

$0 < \phi < 1$. Les écarts persistent dans le même sens puis s'atténuent.

$-1 < \phi < 0$. La magnitude s'atténue mais le signe alterne. La série revient vers son centre en oscillant.

$\phi = 1$. La mémoire ne décroît plus :

$$X_t = X_{t-1} + c + \varepsilon_t.$$

C'est une marche aléatoire avec dérive si $c \neq 0$.

$\phi = -1$. Les effets alternent sans décroître. Cette frontière est elle aussi une racine unitaire au sens du module.

$|\phi| > 1$. Les effets des conditions initiales et des chocs sont amplifiés géométriquement ; la dynamique est explosive.




FIGURE 14 – Trois AR(1) construits avec exactement les mêmes innovations : la différence visible provient uniquement de la mémoire imposée par ϕ .

6.6 Espérance inconditionnelle d'un AR(1) stationnaire

Supposons $|\phi| < 1$, $\mathbb{E}[\varepsilon_t] = 0$, et une moyenne stationnaire

$$\mathbb{E}[X_t] = \mathbb{E}[X_{t-1}] = \mu.$$

Prenons l'espérance de

$$X_t = c + \phi X_{t-1} + \varepsilon_t.$$

Alors

$$\mu = c + \phi\mu.$$

Donc

$$\mu(1 - \phi) = c$$

et

$$\boxed{\mu = \frac{c}{1 - \phi}}.$$

DÉRIVATION – La même formule par la somme géométrique

Lorsque $|\phi| < 1$, le développement précédent donne à long terme

$$X_t \approx c \sum_{j=0}^{\infty} \phi^j + \sum_{j=0}^{\infty} \phi^j \varepsilon_{t-j}.$$

Comme

$$\sum_{j=0}^{\infty} \phi^j = \frac{1}{1 - \phi}$$

et que les innovations ont moyenne nulle,

$$\mathbb{E}[X_t] = \frac{c}{1 - \phi}.$$

Les deux chemins conduisent au même résultat.

6.7 Pourquoi $\phi = 1$ détruit l'espérance stationnaire

La formule $c/(1 - \phi)$ ne doit pas être « évaluée » naïvement à $\phi = 1$: elle a été obtenue sous une hypothèse de stationnarité qui n'est plus valable.

Pour

$$X_t = X_{t-1} + c + \varepsilon_t,$$

on obtient

$$X_t = X_0 + ct + \sum_{j=1}^t \varepsilon_j,$$

donc

$$\mathbb{E}[X_t] = X_0 + ct.$$

Si $c \neq 0$, la moyenne se déplace linéairement dans le temps. Même si $c = 0$, la variance continue de croître avec t .

6.8 Variance inconditionnelle : dérivation complète

Écrivons le processus autour de sa moyenne :

$$Y_t = X_t - \mu.$$

Comme $\mu = c + \phi\mu$,

$$Y_t = \phi Y_{t-1} + \varepsilon_t.$$

Supposons que l'innovation soit non corrélée au passé, donc

$$\text{Cov}(Y_{t-1}, \varepsilon_t) = 0.$$

Alors

$$\text{Var}(Y_t) = \text{Var}(\phi Y_{t-1} + \varepsilon_t) = \phi^2 \text{Var}(Y_{t-1}) + \sigma_\varepsilon^2.$$

Sous stationnarité,

$$\text{Var}(Y_t) = \text{Var}(Y_{t-1}) = \sigma_X^2.$$

Donc

$$\sigma_X^2 = \phi^2 \sigma_X^2 + \sigma_\varepsilon^2,$$

puis

$$\sigma_X^2(1 - \phi^2) = \sigma_\varepsilon^2,$$

et finalement

$$\boxed{\text{Var}(X_t) = \frac{\sigma_\varepsilon^2}{1 - \phi^2}.$$

L'écart-type est

$$\boxed{\sigma_X = \frac{\sigma_\varepsilon}{\sqrt{1 - \phi^2}}.$$

6.9 La mémoire amplifie le risque inconditionnel

Le facteur

$$\frac{1}{1 - \phi^2}$$

mesure combien la variance des innovations est amplifiée par leur persistance dans le système.

EXEMPLE – Trois cas

Si $\sigma_\varepsilon^2 = 1$:

- $\phi = 0$ donne $\text{Var}(X) = 1$;
- $\phi = 0,5$ donne $1/(1 - 0,25) = 1,333 \dots$;

— $\phi = 0,99$ donne $1/(1 - 0,9801) \approx 50,25$.

Une forte persistance permet aux chocs successifs de s'accumuler durablement.




FIGURE 15 – Le facteur de variance explose lorsque $|\phi|$ se rapproche de 1.

6.10 Variance de la marche aléatoire et règle en racine du temps

Pour $\phi = 1$ et $c = 0$,

$$X_t = X_0 + \sum_{j=1}^t \varepsilon_j.$$

Si les innovations sont indépendantes,

$$\text{Var}(X_t) = t\sigma_\varepsilon^2,$$

donc

$$\text{sd}(X_t) = \sqrt{t} \sigma_\varepsilon.$$

Cette règle en racine du temps est souvent utilisée comme approximation en finance, mais elle repose sur des hypothèses fortes : innovations indépendantes, variance constante et absence d'autocorrélation pertinente. CH03 montrera pourquoi la volatilité variable peut la fragiliser.

6.11 ACF théorique de l'AR(1)

Partons de

$$Y_t = \phi Y_{t-1} + \varepsilon_t.$$

Multiplions par Y_{t-k} et prenons l'espérance. Pour $k \geq 1$, l'innovation courante est non corrélée au passé, donc

$$\gamma(k) = \phi \gamma(k-1).$$

Par récurrence,

$$\gamma(k) = \phi^k \gamma(0).$$

En divisant par $\gamma(0)$,

$$\boxed{\rho(k) = \phi^k.}$$

La décroissance de l'ACF n'est donc pas une règle empirique arbitraire : elle est la signature algébrique de la propagation géométrique de la mémoire.

6.12 Demi-vie d'un choc

La demi-vie $h_{1/2}$ est l'horizon auquel l'amplitude absolue du choc est divisée par deux :

$$|\phi|^{h_{1/2}} = \frac{1}{2}.$$

En prenant le logarithme,

$$h_{1/2} \log |\phi| = \log(1/2),$$

d'où

$$h_{1/2} = \frac{\log(1/2)}{\log |\phi|}.$$

Cette formule s'applique directement lorsque $0 < |\phi| < 1$; si $\phi < 0$, le signe oscille mais l'enveloppe absolue décroît selon $|\phi|^k$.




FIGURE 16 – La demi-vie devient très longue lorsque ϕ s'approche de 1 : la proximité de la frontière compte énormément.

6.13 Du AR(1) au AR(p)

Un modèle autorégressif d'ordre p est

$$X_t = c + \phi_1 X_{t-1} + \cdots + \phi_p X_{t-p} + \varepsilon_t.$$

Chaque coefficient agit conditionnellement aux autres retards. Pour $p > 1$, une condition simple comme $|\phi_i| < 1$ pour chaque coefficient n'est pas suffisante. Il faut analyser la dynamique globale créée par leur combinaison.

6.14 L'opérateur de retard : une notation qui compresse les décalages

Définissons l'opérateur L par

$$LX_t = X_{t-1}.$$

Alors

$$L^2 X_t = L(LX_t) = X_{t-2},$$

et plus généralement

$$L^k X_t = X_{t-k}.$$

Ce n'est pas un nombre ordinaire : L est une règle qui agit sur une série.

Avec cette notation,

$$X_t - \phi_1 X_{t-1} - \dots - \phi_p X_{t-p} = (1 - \phi_1 L - \dots - \phi_p L^p) X_t.$$

On définit le polynôme autorégressif

$$\Phi(L) = 1 - \phi_1 L - \dots - \phi_p L^p.$$

Le modèle devient

$$\Phi(L)X_t = c + \varepsilon_t.$$

6.15 Pourquoi introduire une variable complexe z ?

Pour étudier un polynôme, on remplace l'opérateur L par une variable mathématique z et on cherche les solutions de

$$\Phi(z) = 0.$$

Pour un AR(1),

$$\Phi(z) = 1 - \phi z,$$

donc

$$z = \frac{1}{\phi}.$$

6.16 Nombre complexe et module : juste ce qu'il faut pour le cercle unité

Un nombre complexe s'écrit

$$z = a + ib,$$

où $i^2 = -1$. On le représente par le point (a, b) dans le plan. Son module est

$$|z| = \sqrt{a^2 + b^2}.$$

L'ensemble des points tels que

$$|z| = 1$$

forme le cercle de rayon 1 centré à l'origine : le **cercle unité**.

6.17 AR(1) : coefficients à l'intérieur, racine à l'extérieur

Nous savons que la stationnarité exige

$$|\phi| < 1.$$

Or

$$|z| = \frac{1}{|\phi|}.$$

Donc

$$|\phi| < 1 \iff |z| > 1.$$

Voilà l'origine de la formule apparemment paradoxale : le coefficient ϕ doit avoir un module inférieur à 1, alors que la racine z du polynôme doit avoir un module supérieur à 1.




FIGURE 17 – Le cercle unité permet de distinguer racines extérieures, racine sur la frontière et racines intérieures.

6.18 AR(p) : la condition générale sur les racines

Pour

$$\Phi(z) = 1 - \phi_1 z - \dots - \phi_p z^p,$$

la condition standard de causalité-stationnarité est que **toutes** les racines vérifient

$$|z_j| > 1.$$

Si une racine touche le cercle, $|z_j| = 1$, on rencontre une racine unitaire. Si une racine est à l'intérieur, la dynamique correspondante ne décroît pas de la manière requise pour une représentation causale stationnaire.




FIGURE 18 – Trois configurations AR(2) : le critère porte sur l'ensemble des racines, pas sur un coefficient pris isolément.

POINT DE VUE INGÉNIEUR – Ce que fait le logiciel

Les bibliothèques de séries temporelles peuvent calculer les racines du polynôme estimé et vérifier la stationnarité. Le logiciel automatise le calcul numérique ; il ne change pas le critère mathématique. Comprendre le cercle unité permet de savoir ce que signifie réellement un message comme « non-stationary starting autoregressive parameters ».

6.19 Ce qu'un AR ne garantit pas

Un AR stationnaire peut décrire une dépendance linéaire de moyenne, mais il ne garantit ni normalité, ni indépendance complète, ni variance conditionnelle constante, ni stabilité éternelle des paramètres. Une série peut avoir une moyenne AR prévisible tout en ayant une volatilité changeante ; ce sera précisément le sujet de CH03.

À RETENIR – Résumé AR

Le fil logique est maintenant complet :

$$\text{AR}(1) \rightarrow \phi^k \rightarrow \text{oubli} \rightarrow \mu \rightarrow \text{Var} \rightarrow \rho(k) \rightarrow \text{demi-vie} \rightarrow L \rightarrow \Phi(z) \rightarrow \text{racines.}$$

La condition de stationnarité n'est plus une recette : elle relie dynamique, moments, mémoire et géométrie du polynôme.

7 MA, PACF et ARMA : mémoire des chocs, mémoire des valeurs

7.1 Pourquoi un modèle MA après l'AR ?

L'AR suppose que le passé agit par les anciennes valeurs de la série. Il existe une autre forme de mémoire : un choc passé peut continuer à influencer la valeur actuelle, même si l'on ne réinjecte pas directement X_{t-1} .

Le modèle moyenne mobile d'ordre 1, ou MA(1), est

$$X_t = \mu + \varepsilon_t + \theta \varepsilon_{t-1}.$$

Le nom « moyenne mobile » est historique et peut prêter à confusion : il ne s'agit pas de la moyenne glissante descriptive d'un prix. Il s'agit d'une combinaison linéaire d'innovations présentes et passées.

7.2 Lire un MA(1) terme par terme

Au temps t , deux chocs interviennent :

- ε_t , choc nouveau, avec coefficient 1 ;
- ε_{t-1} , choc d'hier, avec coefficient θ .

Le choc ε_{t-2} n'apparaît plus directement.

EXEMPLE – Un choc unitaire

Supposons $\mu = 0$ et $\theta = 0,65$. Si un choc de valeur 1 survient à la date 0 et que les autres innovations valent zéro, son effet vaut 1 immédiatement, puis 0,65 une période plus tard, puis zéro directement à partir de la deuxième période.




FIGURE 19 – Dans un MA(1), la contribution directe d'un choc est finie : présente aujourd'hui, pondérée demain, puis absente.

7.3 Espérance et variance d'un MA(1)

Si $\mathbb{E}[\varepsilon_t] = 0$, alors

$$\mathbb{E}[X_t] = \mu.$$

Si les innovations sont non corrélées dans le temps et de variance σ_ε^2 ,

$$\text{Var}(X_t) = \text{Var}(\varepsilon_t + \theta\varepsilon_{t-1}) = (1 + \theta^2)\sigma_\varepsilon^2.$$

Le terme croisé disparaît parce que

$$\text{Cov}(\varepsilon_t, \varepsilon_{t-1}) = 0.$$

7.4 ACF théorique du MA(1)

Calculons l'autocovariance au lag 1 :

$$\gamma(1) = \text{Cov}(X_t, X_{t-1}).$$

En retirant la moyenne,

$$X_t - \mu = \varepsilon_t + \theta\varepsilon_{t-1},$$

$$X_{t-1} - \mu = \varepsilon_{t-1} + \theta\varepsilon_{t-2}.$$

Le seul terme partagé dans les deux expressions est ε_{t-1} . On obtient

$$\gamma(1) = \theta \sigma_\varepsilon^2.$$

Comme

$$\gamma(0) = (1 + \theta^2) \sigma_\varepsilon^2,$$

$$\rho(1) = \frac{\theta}{1 + \theta^2}.$$

Pour $k \geq 2$, aucun choc n'est commun aux deux valeurs, donc

$$\rho(k) = 0 \quad (k \geq 2).$$

À RETENIR – La « coupure » de l'ACF a une cause mécanique

L'ACF théorique d'un MA(1) devient nulle après le lag 1 parce qu'au-delà d'une période les deux observations ne partagent plus aucune innovation commune. Pour un MA(q), l'ACF théorique s'annule après le lag q .

7.5 MA(q) : mémoire directe de longueur q

Le modèle général est

$$X_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q}.$$

Il reste stationnaire au second ordre dès lors que les innovations sont un bruit blanc de variance finie : c'est une combinaison finie de chocs stationnaires. Le problème principal du côté MA n'est donc pas la stationnarité, mais l'**invertibilité**.

7.6 Pourquoi l'invertibilité existe-t-elle ?

Le modèle contient des innovations ε_t que nous n'observons pas directement. Pour estimer ou interpréter le modèle, nous voulons pouvoir reconstruire ces innovations à partir des observations présentes et passées de X d'une manière stable et unique.

Prenons, pour simplifier, $\mu = 0$:

$$X_t = \varepsilon_t + \theta \varepsilon_{t-1}.$$

Isolons ε_t :

$$\varepsilon_t = X_t - \theta \varepsilon_{t-1}.$$

Mais

$$\varepsilon_{t-1} = X_{t-1} - \theta \varepsilon_{t-2}.$$

Donc

$$\varepsilon_t = X_t - \theta X_{t-1} + \theta^2 \varepsilon_{t-2}.$$

En poursuivant,

$$\varepsilon_t = X_t - \theta X_{t-1} + \theta^2 X_{t-2} - \theta^3 X_{t-3} + \cdots.$$

Cette série ne peut fournir une représentation stable que si les puissances de θ décroissent :

$$|\theta| < 1.$$




FIGURE 20 – Les puissances $|\theta|^k$ décroissent lorsque $|\theta| < 1$ et ne décroissent plus lorsque le module dépasse 1.

INTUITION – Invertibilité = retrouver les chocs sans explosion

La stationnarité AR demande que le passé lointain cesse d'influencer fortement X_t . L'invertibilité MA demande que la reconstruction d'un choc à partir des observations ne nécessite pas des coefficients qui explosent avec l'âge des données.

7.7 Polynôme MA et racines

Définissons

$$\Theta(L) = 1 + \theta_1 L + \dots + \theta_q L^q.$$

Alors

$$X_t - \mu = \Theta(L)\varepsilon_t.$$

Une condition standard d'invertibilité est que les racines de

$$\Theta(z) = 0$$

soient elles aussi à l'extérieur du cercle unité. Pour un MA(1), avec la convention $1 + \theta z$, la racine est

$$z = -\frac{1}{\theta},$$

et $|z| > 1$ équivaut à $|\theta| < 1$.

7.8 Pourquoi l'identifiabilité a besoin de l'invertibilité

Sans la convention d'invertibilité, plusieurs paramétrisations MA peuvent produire les mêmes autocovariances observables. Pour un MA(1), la corrélation

$$\rho(1) = \frac{\theta}{1 + \theta^2}$$

reste inchangée lorsqu'on remplace θ par $1/\theta$:

$$\frac{1/\theta}{1 + 1/\theta^2} = \frac{\theta}{1 + \theta^2}.$$

L'invertibilité choisit une représentation canonique, généralement celle avec $|\theta| < 1$.

7.9 Pourquoi l'ACF seule ne sépare pas toujours tout ?

Pour un AR, l'ACF décroît progressivement ; pour un MA, elle s'annule théoriquement après quelques lags. Mais dans un échantillon fini, les barres ne sont jamais exactement conformes au dessin théorique. Nous avons besoin d'une deuxième vue : la PACF.

7.10 Corrélation partielle : enlever les chemins intermédiaires

Supposons que X_t soit lié à X_{t-1} et que X_{t-1} soit lié à X_{t-2} . Alors X_t et X_{t-2} peuvent être corrélés simplement parce que l'information transite par X_{t-1} :

$$X_{t-2} \longrightarrow X_{t-1} \longrightarrow X_t.$$

L'ACF au lag 2 mesure la relation totale. La **corrélation partielle** au lag 2 cherche ce qui reste entre X_t et X_{t-2} après avoir contrôlé linéairement X_{t-1} .

7.11 Construction par régression au lag 2

Une manière de comprendre la PACF consiste à estimer

$$X_t = a + \beta_1 X_{t-1} + \beta_2 X_{t-2} + u_t.$$

Le coefficient associé à X_{t-2} , après contrôle de X_{t-1} , exprime l'idée de contribution directe du lag 2. Les définitions exactes de PACF reposent sur cette logique de projection linéaire.

Plus généralement, la PACF au lag k mesure l'association entre X_t et X_{t-k} après retrait de l'effet linéaire des lags $1, \dots, k-1$.

EXEMPLE – AR(1)

Dans un AR(1),

$$X_t = \phi X_{t-1} + \varepsilon_t.$$

Le lag 2 influence X_t via X_{t-1} . Une fois X_{t-1} contrôlé, X_{t-2} n'apporte plus de relation linéaire directe. La PACF théorique est donc coupée après le lag 1.

7.12 Signatures théoriques ACF/PACF

Dans des modèles idéalisés :

- AR(p) : ACF décroissante, PACF théoriquement nulle après p ;
- MA(q) : ACF théoriquement nulle après q , PACF décroissante ;
- ARMA(p, q) : ACF et PACF décroissent généralement toutes deux.




FIGURE 21 – Signatures ACF/PACF sur des simulations idéalisées. Elles servent à raisonner sur des candidats, pas à reconnaître mécaniquement un modèle.

ATTENTION – Une « coupure » empirique est floue

Dans un échantillon fini, aucune barre ne connaît le modèle théorique. Le bruit d'échantillonnage, une racine proche de 1, une saisonnalité, une variance changeante ou une mauvaise transformation peuvent brouiller les signatures. ACF/PACF sont des outils d'identification, pas des oracles.

7.13 ARMA : combiner mémoire des valeurs et mémoire des chocs

Un ARMA(p, q) stationnaire-inversible s'écrit

$$X_t = c + \phi_1 X_{t-1} + \dots + \phi_p X_{t-p} + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}.$$

Avec les polynômes

$$\Phi(L) = 1 - \phi_1 L - \dots - \phi_p L^p,$$

$$\Theta(L) = 1 + \theta_1 L + \dots + \theta_q L^q,$$

on écrit

$$\Phi(L)(X_t - \mu) = \Theta(L)\varepsilon_t.$$

INTUITION – Deux mécanismes complémentaires

La partie AR dit : « la valeur passée du système se propage ». La partie MA dit : « certains chocs récents continuent à agir explicitement ». ARMA autorise les deux mécanismes simultanément.

7.14 Réponse impulsionnelle d'un ARMA

Même lorsqu'un MA n'a qu'une mémoire directe finie, la présence d'une partie AR peut réinjecter l'effet du choc et produire une réponse qui décroît sur de nombreux horizons. Une représentation causale stationnaire-inversible permet d'écrire

$$X_t - \mu = \sum_{j=0}^{\infty} \psi_j \varepsilon_{t-j},$$

avec des coefficients ψ_j qui décroissent suffisamment vite.

Cette écriture est utile parce qu'elle dit finalement combien chaque innovation passée contribue à X_t .

7.15 Pourquoi ne pas choisir un ARMA énorme ?

Ajouter des paramètres peut améliorer l'ajustement sur l'échantillon, mais :

- augmente l'incertitude d'estimation ;
- crée des compensations difficiles à interpréter ;
- augmente le risque de sur-ajustement ;
- peut rendre les racines proches de frontières instables ;
- n'améliore pas nécessairement la prévision future.

La parcimonie sera donc un principe explicite dans Box–Jenkins et dans AIC/BIC.

À RETENIR – La logique AR/MA/PACF

AR explique une mémoire qui se transmet par les valeurs ; MA explique une mémoire finie des chocs ; la PACF aide à séparer influence directe et influence transmise ; ARMA combine les deux. Chaque signature ACF/PACF doit être reliée au mécanisme qui la produit.

8 Racine unitaire, différenciation et tests de stationnarité

8.1 Pourquoi une racine unitaire est-elle un cas si particulier ?

Pour un AR(1),

$$X_t = \phi X_{t-1} + \varepsilon_t,$$

le polynôme autorégressif est

$$\Phi(z) = 1 - \phi z.$$

Sa racine est

$$z = \frac{1}{\phi}.$$

Lorsque $\phi = 1$, la racine vaut exactement

$$z = 1,$$

donc elle se trouve sur le cercle unité. C'est l'origine de l'expression **racine unitaire**.

Le modèle devient

$$X_t = X_{t-1} + \varepsilon_t,$$

soit une marche aléatoire.

8.2 Différencier : soustraire deux observations successives

On définit la première différence par

$$\Delta X_t = X_t - X_{t-1}.$$

Avec l'opérateur de retard,

$$\Delta X_t = (1 - L)X_t.$$

Pour une marche aléatoire,

$$X_t - X_{t-1} = \varepsilon_t,$$

donc

$$\Delta X_t = \varepsilon_t.$$

La série non stationnaire en niveau devient alors un bruit blanc stationnaire après une différence.

Différencier retire l'accumulation d'une racine unitaire




FIGURE 22 – Une marche aléatoire en niveau devient son innovation après première différence.

INTUITION – Racine unitaire et différenciation sont la même histoire algébrique

Le facteur qui produit la racine unitaire est $(1 - L)$. Différencier consiste précisément à appliquer $(1 - L)$ à la série. C'est pourquoi racine unitaire, différenciation et composante « I » d'ARIMA ne sont pas trois recettes séparées.

8.3 Ordre d'intégration $I(d)$

Une série est dite intégrée d'ordre d , notée $I(d)$, si elle devient stationnaire après d différenciations appropriées et pas moins.

- $I(0)$: série déjà stationnaire ;
- $I(1)$: une différence suffit ;
- $I(2)$: deux différences sont nécessaires.

Cette notation décrit le nombre de racines unitaires de type $(1 - L)$ que l'on doit retirer dans ce cadre simple.

8.4 Différence première, croissance et rendement

Lorsque X_t est un niveau, la différence

$$X_t - X_{t-1}$$

mesure un changement absolu. Pour un prix positif P_t , le rendement logarithmique

$$\Delta \log P_t = \log P_t - \log P_{t-1}$$

mesure approximativement un changement relatif. Les deux opérations sont des différences, mais sur des variables différentes ; elles ne doivent pas être confondues.

8.5 Sur-différenciation : trop transformer peut dégrader la série

Si une série est déjà stationnaire et qu'on la différencie malgré tout, on ne la rend pas « plus stationnaire ». On modifie sa dynamique.

Pour un bruit blanc $X_t = \varepsilon_t$,

$$\Delta X_t = \varepsilon_t - \varepsilon_{t-1},$$

qui est un MA(1) avec coefficient -1 , précisément sur une frontière d'invertibilité. La différenciation inutile peut donc introduire une autocorrélation négative artificielle et augmenter la variance des variations.




FIGURE 23 – Différencier une série déjà stationnaire peut créer une dynamique artificielle et augmenter le bruit.

ATTENTION – Le nombre d n'est pas « plus grand = mieux »

Le choix de d doit être justifié par la structure de la série. Une transformation excessive peut détériorer la prévision, rendre l'interprétation difficile et créer des racines MA proches de la non-invertibilité.

8.6 Dickey–Fuller : dériver le test à partir de l'AR(1)

Partons de

$$X_t = \rho X_{t-1} + \varepsilon_t.$$

Une racine unitaire correspond à

$$\rho = 1.$$

Soustrayons X_{t-1} des deux côtés :

$$X_t - X_{t-1} = (\rho - 1)X_{t-1} + \varepsilon_t.$$

Donc

$$\Delta X_t = \gamma X_{t-1} + \varepsilon_t, \quad \gamma = \rho - 1.$$

Ainsi

$$\rho = 1 \iff \gamma = 0.$$




FIGURE 24 – Le test Dickey–Fuller reformule la question « $\rho = 1$? » en « $\gamma = 0$? ».

À RETENIR – Hypothèse nulle de Dickey–Fuller

Dans cette formulation,

$$H_0 : \gamma = 0$$

signifie qu’une racine unitaire est présente. L’alternative stationnaire correspond à $\gamma < 0$ dans le cas classique unilatéral.

8.7 Pourquoi un test t ordinaire ne suffit pas ?

Sous $H_0 : \rho = 1$, le régresseur X_{t-1} est lui-même non stationnaire. La statistique t habituelle ne suit donc pas la loi de Student standard. Dickey et Fuller ont établi des distributions limites particulières et des valeurs critiques spécifiques (Dickey et Fuller, 1979).

C’est pour cette raison qu’une sortie ADF fournit des valeurs critiques « Dickey–Fuller » et non simplement les quantiles t d’une régression ordinaire.

8.8 Constante, tendance ou rien : la spécification change la question

Trois formes simplifiées apparaissent souvent :

$$\Delta X_t = \gamma X_{t-1} + u_t,$$

$$\Delta X_t = \alpha + \gamma X_{t-1} + u_t,$$

$$\Delta X_t = \alpha + \beta t + \gamma X_{t-1} + u_t.$$

Elles correspondent respectivement à une régression sans terme déterministe, avec constante, ou avec constante et tendance.

ATTENTION – On ne « teste pas la stationnarité » sans préciser le cadre

Une série stationnaire autour d’une tendance peut sembler non stationnaire si l’on utilise un test qui n’autorise pas cette tendance. Le terme déterministe fait partie de l’hypothèse statistique.

8.9 ADF : pourquoi ajouter des retards de différences ?

Si les erreurs du modèle Dickey–Fuller sont autocorrélées, la distribution de la statistique est perturbée. Le test ADF, pour *Augmented Dickey–Fuller*, ajoute des retards de la variable différenciée :

$$\Delta X_t = \alpha + \beta t + \gamma X_{t-1} + \sum_{i=1}^p \delta_i \Delta X_{t-i} + u_t.$$

Les termes ΔX_{t-i} absorbent une partie de la dynamique de court terme afin que u_t soit plus proche d'un bruit blanc.

Le paramètre testé reste γ :

$$H_0 : \gamma = 0.$$

8.10 Choisir le nombre de retards de l'ADF

Trop peu de retards laisse de l'autocorrélation résiduelle ; trop de retards consomme des degrés de liberté et réduit la puissance. Les logiciels utilisent souvent AIC, BIC ou des règles séquentielles, mais ce choix doit être documenté.

8.11 Lire une sortie ADF sans réciter une règle

Une sortie typique contient :

- une **statistique ADF** ;
- une **p-value** ;
- le nombre de retards utilisés ;
- le nombre d'observations effectives ;
- des **valeurs critiques** à 1%, 5% et 10%.

LECTURE D'UNE SORTIE – Exemple conceptuel

Supposons : statistique ADF = -4,1, valeur critique 5% = -2,9, p-value = 0,002. La statistique est plus négative que le seuil 5% et la p-value est petite : les données apportent un argument contre la racine unitaire dans la spécification utilisée. Cela ne prouve ni stationnarité éternelle, ni absence de rupture, ni pertinence économique.

8.12 Phillips–Perron : même nullité, correction différente

Le test Phillips–Perron (PP) garde l'hypothèse nulle de racine unitaire mais traite l'autocorrélation et l'hétéroscédasticité des erreurs par une correction non paramétrique de la statistique plutôt qu'en ajoutant explicitement les mêmes retards que l'ADF (Phillips et Perron, 1988).

L'ADF et PP posent donc une question proche, avec des stratégies différentes pour gérer la dépendance de court terme.

8.13 KPSS : inverser l'hypothèse nulle

Le test KPSS prend comme référence une série stationnaire autour d'un niveau ou d'une tendance, selon la spécification (Kwiatkowski et al., 1992).

Schématiquement :

H_0 : stationnarité spécifiée, H_1 : non-stationnarité de type racine unitaire.

Un petit p-value conduit donc ici à rejeter la stationnarité, contrairement à l'ADF où un petit p-value conduit à rejeter la racine unitaire.

8.14 Pourquoi combiner ADF/PP et KPSS ?

Les tests ont une puissance limitée, surtout lorsque la racine est proche de 1 ou l'échantillon court. Les hypothèses nulles opposées créent une grille de lecture utile :

Résultat	Lecture possible	Réaction raisonnable
ADF rejette, KPSS ne rejette pas	cohérent avec stationnarité	poursuivre diagnostics
ADF ne rejette pas, KPSS rejette	cohérent avec racine unitaire	envisager différence / autre transformation
ADF ne rejette pas, KPSS ne rejette pas	zone d'incertitude / faible puissance	graphique, spécification, échantillon, robustesse
ADF rejette, KPSS rejette	conflit possible : rupture, mauvaise spécification, dynamique complexe	ne pas conclure mécaniquement

8.15 Près de la racine unitaire : le cas difficile

Si $\phi = 0,98$, le processus est mathématiquement stationnaire, mais sa mémoire est très longue. Sur un échantillon modeste, il peut ressembler à une marche aléatoire. Les tests peuvent manquer de puissance pour distinguer 0,98 de 1.

Cette difficulté n'est pas un défaut du logiciel ; elle reflète une proximité réelle entre deux mécanismes sur des horizons finis.

8.16 Ruptures structurelles : une autre source de confusion

Une série stationnaire par morceaux peut comporter un changement brutal de moyenne. Un test de racine unitaire standard peut alors interpréter cette persistance comme de la non-stationnarité. À l'inverse, une série avec changement de régime peut violer l'hypothèse de paramètres constants sans être une marche aléatoire.

POINT DE VUE INGÉNIEUR – Les tests complètent le graphique, ils ne le remplacent pas

Une procédure solide combine : visualisation du niveau et des différences, connaissance du mécanisme, ACF/PACF, choix raisonné des termes déterministes, plusieurs tests lorsque c'est pertinent, inspection des ruptures et validation hors échantillon.

8.17 De la différenciation à ARIMA

Une fois une série rendue stationnaire par d différences, on peut modéliser la série transformée avec un ARMA. C'est exactement l'idée d'ARIMA :

ARIMA = ARMA appliqué après intégration/différenciation appropriée.

La prochaine section réunira ces briques dans une notation unique.

9 Saisonnalité et SARIMA : quand le temps possède un calendrier

9.1 Pourquoi la saisonnalité mérite une section entière

Une dépendance temporelle peut provenir d'une mémoire locale — hier influence aujourd'hui — mais aussi d'une position répétée dans un calendrier : lundi après lundi, janvier après janvier, ouverture de séance après ouverture de séance. La saisonnalité n'est donc ni une décoration ni un cas marginal : c'est une forme structurée de dépendance temporelle.

ATTENTION – Saisonnalité et GARCH ne répondent pas à la même question

La saisonnalité de la moyenne ou du niveau appartient naturellement à l'analyse de CH02. ARCH/GARCH, étudiés au chapitre suivant, décrivent principalement une dynamique de variance conditionnelle. Une volatilité intraday périodique peut exister, mais elle doit être distinguée du clustering stochastique que GARCH cherche à modéliser.

9.2 Période s : compter la distance entre positions comparables

Si un motif revient tous les s pas, alors s est la période saisonnière. Avec des données mensuelles et un cycle annuel, $s = 12$. Avec des données trimestrielles, $s = 4$. Avec des données ouvrées présentant un effet hebdomadaire, on peut avoir $s \approx 5$.

EXEMPLE – Une série de période 5

Considérons

10, 14, 20, 16, 12, 10, 14, 20, 16, 12, ...

Les observations X_t et X_{t-5} occupent la même position dans le motif. Le retard saisonnier naturel est donc 5.




FIGURE 25 – La périodicité crée des correspondances privilégiées entre t et $t - s$, puis $t - 2s$, etc.

9.3 Saisonnalité déterministe et saisonnalité stochastique

Deux mécanismes différents peuvent produire un motif saisonnier.

Une **saisonnalité déterministe** peut être décrite par une fonction périodique :

$$S_t = A \sin\left(\frac{2\pi t}{s}\right) + B \cos\left(\frac{2\pi t}{s}\right).$$

La forme est alors liée directement à la position dans le cycle.

Une **saisonnalité stochastique** peut prendre la forme d'une dépendance autorégressive saisonnière :

$$X_t = \Phi X_{t-s} + \varepsilon_t.$$

Ici, ce n'est pas une courbe périodique fixe qui se répète : la valeur à la même position du cycle précédent transmet une partie de son information au présent.

INTUITION – Mémoire locale versus mémoire saisonnière

Dans un AR(1), le canal de mémoire est $t - 1 \rightarrow t$. Dans un AR saisonnier d'ordre 1, il devient $t - s \rightarrow t$. Les deux sont des mémoires, mais elles ne suivent pas la même distance temporelle.

9.4 Ce que l'ACF doit montrer, et pourquoi

Si X_t ressemble à X_{t-s} , alors la corrélation au lag s peut être forte. Une structure saisonnière peut donc produire des pics dans l'ACF autour de

$$s, 2s, 3s, \dots$$

Mais un pic saisonnier ne prouve pas à lui seul un modèle SARIMA particulier : tendance, combinaison de périodicités, calendrier irrégulier ou ruptures peuvent aussi affecter le corrélogramme.

9.5 Pourquoi la différenciation ordinaire peut échouer

La différence ordinaire

$$\Delta X_t = X_t - X_{t-1}$$

compare deux instants voisins. Elle est adaptée à une tendance locale ou à une racine unitaire non saisonnière. Mais si le problème est « janvier ressemble à janvier précédent », comparer janvier à décembre n'enlève pas nécessairement cette structure.

C'est exactement pour cela que l'on introduit la différence saisonnière.

9.6 Différenciation saisonnière : comparer une position à elle-même un cycle plus tôt

On définit

$$\Delta_s X_t = X_t - X_{t-s}.$$

Avec l'opérateur de retard L ,

$$\Delta_s X_t = (1 - L^s) X_t.$$

EXEMPLE – Calcul manuel

Si les ventes de janvier 2025 valent 120 et celles de janvier 2024 valent 100, alors

$$\Delta_{12} X_{\text{janvier 2025}} = 120 - 100 = 20.$$

Cette différence mesure le changement entre deux positions saisonnières comparables, pas entre deux mois consécutifs.




FIGURE 26 – La différence ordinaire et la différence saisonnière retirent des structures différentes.

9.7 Racines saisonnières : la géométrie revient

Le facteur saisonnier

$$1 - L^s$$

possède plusieurs racines complexes sur le cercle unité. Pour $s = 4$,

$$1 - z^4 = 0$$

a pour solutions $1, -1, i, -i$. La non-stationnarité saisonnière peut donc être liée à des racines unitaires placées à plusieurs angles du cercle, et pas seulement à $z = 1$.

À RETENIR – Une idée unifie beaucoup de choses

La différenciation ordinaire applique le facteur $(1 - L)$. La différenciation saisonnière applique $(1 - L^s)$. Toutes deux cherchent à neutraliser une structure persistante liée à une racine unitaire, mais pas au même rythme temporel.

9.8 SARIMA : étendre ARIMA sans changer sa logique

Un modèle saisonnier s'écrit

$$SARIMA(p, d, q) \times (P, D, Q)_s.$$

Les paramètres (p, d, q) décrivent la dynamique ordinaire ; (P, D, Q) la dynamique saisonnière ; s indique la période.

Une écriture compacte est

$$\Phi(L) \Phi_s(L^s) (1-L)^d (1-L^s)^D X_t = \Theta(L) \Theta_s(L^s) \varepsilon_t.$$

Cette formule ne doit pas être lue comme un bloc. Chaque morceau a un sens :

- $\Phi(L)$: mémoire AR non saisonnière ;
- $\Phi_s(L^s)$: mémoire AR entre positions saisonnières ;
- $(1-L)^d$: différenciation ordinaire ;
- $(1-L^s)^D$: différenciation saisonnière ;
- $\Theta(L)$: mémoire MA non saisonnière ;
- $\Theta_s(L^s)$: mémoire MA saisonnière.

9.9 Un exemple canonique : le modèle “airline”

Le modèle

$$ARIMA(0, 1, 1) \times (0, 1, 1)_{12}$$

est célèbre pour des séries mensuelles avec tendance stochastique et saisonnalité annuelle. Il signifie : une différence ordinaire, une différence saisonnière annuelle, un MA non saisonnier et un MA saisonnier.

ATTENTION – Ne jamais choisir ce modèle parce qu’il est célèbre

Le modèle airline est un exemple pédagogique. Une série réelle doit être diagnostiquée : structure, période, transformations, résidus et validation hors échantillon. Copier $(0, 1, 1) \times (0, 1, 1)_{12}$ sans diagnostic est exactement le contraire de la démarche de ce cours.

9.10 Saisonnalité multiplicative et logarithme

Si l’amplitude des oscillations augmente avec le niveau, une saisonnalité additive peut être inadéquate. Un logarithme peut stabiliser l’échelle et transformer une relation multiplicative en relation additive approximative. Cette étape doit être motivée par la géométrie de la série, pas appliquée automatiquement.

9.11 Fourier : une autre façon de coder un calendrier régulier

Une saisonnalité lisse peut être décrite par des couples sinus/cosinus :

$$\sin\left(\frac{2\pi kt}{s}\right), \quad \cos\left(\frac{2\pi kt}{s}\right),$$

pour plusieurs harmoniques k . Cette représentation peut être particulièrement utile lorsque s est grand, ou lorsque l’on souhaite intégrer la saisonnalité comme variables explicatives plutôt que par une structure SARIMA complète.




FIGURE 27 – Une harmonique fondamentale peut être enrichie pour représenter des formes périodiques moins sinusoïdales.

9.12 Calendrier financier : saisonnalité réelle, mais prudence maximale

En finance, on peut rencontrer des effets jour-de-semaine, fin de mois, ouverture/clôture, volume intraday ou volatilité intraday. Ils ne sont ni universels ni éternels : coûts de transaction, changements de microstructure et adaptation des acteurs peuvent les atténuer.




FIGURE 28 – Exemple conceptuel d'une volatilité intraday en U : structure périodique déterministe et clustering GARCH ne doivent pas être confondus.

POINT DE VUE INGÉNIEUR – Prétraiter avant GARCH

Si une volatilité présente une structure intraday très régulière, on peut d'abord estimer/retirer cette composante saisonnière, puis étudier la dépendance stochastique restante. Sinon un modèle GARCH peut attribuer à sa persistance une partie de ce qui relève simplement de l'heure de la journée.

9.13 Sur-différenciation saisonnière

Comme pour la différenciation ordinaire, appliquer trop de différences peut détériorer la série. On ne choisit donc pas $D = 1$ simplement parce qu'une saisonnalité existe visuellement : on examine si la structure saisonnière est déterministe, stochastique, stable, et si la transformation améliore réellement la stationnarité et la prévision.

9.14 La séquence de diagnostic que nous retiendrons

Pour une série potentiellement saisonnière :

1. identifier la fréquence des données et les calendriers plausibles ;
2. visualiser la série et les positions dans le cycle ;
3. examiner ACF/PACF aux lags ordinaires et saisonniers ;
4. distinguer tendance, saisonnalité déterministe et saisonnalité stochastique ;
5. tester une transformation d'échelle si nécessaire ;
6. comparer différence ordinaire et saisonnière ;
7. ajuster des candidats parcimonieux ;
8. diagnostiquer les résidus ;
9. évaluer hors échantillon avec une séparation temporelle.

À RETENIR – Ce que la saisonnalité nous a appris

La dépendance temporelle n'est pas seulement une mémoire de proximité. Le calendrier peut créer une mémoire à distance régulière. ARIMA modélise la dynamique ordinaire ; SARIMA l'étend explicitement aux structures périodiques. Cette compréhension doit être acquise avant de passer à ARCH/GARCH.

10 ARIMA, estimation et sélection : de la structure au modèle ajusté

10.1 Déchiffrer ARIMA(p, d, q)

ARIMA signifie *Autoregressive Integrated Moving Average*. La notation ARIMA(p, d, q) regroupe trois choix :

- p : nombre de retards autorégressifs ;
- d : nombre de différenciations appliquées ;
- q : nombre de retards d'innovations dans la partie MA.

Si

$$W_t = (1 - L)^d X_t,$$

et si W_t suit un ARMA(p, q), alors X_t suit un ARIMA(p, d, q).

Avec

$$\Phi(L) = 1 - \phi_1 L - \dots - \phi_p L^p$$

et

$$\Theta(L) = 1 + \theta_1 L + \dots + \theta_q L^q,$$

une écriture compacte est

$$\Phi(L)(1-L)^d X_t = c + \Theta(L)\varepsilon_t.$$

10.2 Lire quelques modèles sans jargon

- ARIMA(1,0,0) : un AR(1) ;
- ARIMA(0,0,1) : un MA(1) ;
- ARIMA(1,0,1) : un ARMA(1,1) ;
- ARIMA(0,1,0) : une série dont la première différence est un bruit blanc ;
- ARIMA(1,1,1) : la première différence suit un ARMA(1,1).

ATTENTION – La lettre « I » ne signifie pas qu'ARIMA rend toute série modélisable

Une différence peut retirer une racine unitaire, mais elle ne corrige pas automatiquement une saisonnalité, une rupture, une variance conditionnelle changeante, une non-linéarité ou une mauvaise qualité des données.

10.3 Dérive dans un modèle intégré

Considérons

$$\Delta X_t = \delta + \varepsilon_t.$$

Alors

$$X_t = X_0 + \delta t + \sum_{j=1}^t \varepsilon_j.$$

Le terme δ devient une dérive moyenne du niveau. Une constante dans l'équation différenciée n'a donc pas la même interprétation qu'une constante dans un AR stationnaire en niveau.

10.4 Que signifie « estimer un modèle » ?

Jusqu'ici, nous avons supposé les paramètres connus. Dans les données réelles, ϕ , θ , c et σ_ε^2 sont inconnus. **Estimer** signifie choisir des valeurs à partir de l'échantillon observé selon un critère mathématique.

Pour un AR simple, les moindres carrés peuvent être interprétés comme la recherche des paramètres qui minimisent

$$\sum_t \hat{\varepsilon}_t^2.$$

Pour ARMA/ARIMA, le maximum de vraisemblance est très courant.

10.5 Vraisemblance : rendre les données observées plausibles

Supposons un modèle paramétré par ϑ . La vraisemblance est

$$L(\vartheta) = p(\text{données observées} \mid \vartheta).$$

Pour des données continues, il s'agit rigoureusement d'une densité jointe évaluée aux observations. On cherche

$$\hat{\vartheta} = \arg \max_{\vartheta} L(\vartheta).$$

Comme les produits de nombreuses densités deviennent numériquement très petits, on travaille avec la log-vraisemblance :

$$\ell(\vartheta) = \log L(\vartheta),$$

et

$$\arg \max L = \arg \max \ell.$$




FIGURE 29 – Exemple simple : la valeur du paramètre qui maximise la log-vraisemblance rend les données observées les plus compatibles avec le modèle choisi.

10.6 Exemple élémentaire : estimer une moyenne normale

Si $Y_i \sim \mathcal{N}(\mu, \sigma^2)$ avec σ connu, la log-vraisemblance, à constante près, vaut

$$\ell(\mu) = -\frac{1}{2\sigma^2} \sum_{i=1}^n (y_i - \mu)^2.$$

Maximiser ℓ revient à minimiser la somme des carrés, ce qui donne

$$\hat{\mu} = \bar{y}.$$

Cet exemple montre que maximum de vraisemblance et moindres carrés ne sont pas deux mondes sans lien.

10.7 Pourquoi ARMA est plus difficile à estimer qu'un AR simple ?

Dans un MA ou un ARMA, les innovations passées sont latentes : elles ne sont pas directement observées. Leur valeur dépend des paramètres candidats. La vraisemblance doit donc tenir compte d'un état initial, d'une récursion ou d'une représentation d'espace d'état.

Les bibliothèques modernes utilisent des méthodes numériques robustes et souvent une représentation d'espace d'état avec filtre de Kalman. L'étudiant n'a pas besoin de dériver ici le filtre complet, mais doit savoir que la commande d'estimation réalise une optimisation non triviale, soumise aux contraintes de stationnarité et d'invertibilité.

10.8 Erreur-type des paramètres

Un estimateur $\hat{\phi}$ change si l'on observe un autre échantillon. Son erreur-type mesure cette variabilité d'échantillonnage. Une sortie logicielle peut fournir

$$\hat{\phi}, \quad \text{SE}(\hat{\phi}), \quad z \text{ ou } t, \quad p\text{-value}, \quad \text{intervalle de confiance}.$$


La présence d'un coefficient estimé ne signifie donc pas que sa valeur est connue sans incertitude.

10.9 Box–Jenkins : une boucle plutôt qu’une recette

La démarche Box–Jenkins (Box et al., 2015) peut être résumée en six étapes :

1. définir correctement la variable et la fréquence ;
2. diagnostiquer stationnarité, tendances, ruptures et besoin de transformation ;
3. proposer quelques ordres (p, d, q) parcimonieux ;
4. estimer les paramètres ;
5. diagnostiquer les résidus ;
6. prévoir sur des données futures et évaluer.

Box-Jenkins : un cycle raisonné, pas une commande automatique



Un mauvais diagnostic renvoie vers les étapes précédentes

FIGURE 30 – Box–Jenkins est une boucle de raisonnement : un échec de diagnostic oblige à revenir en arrière.

10.10 Identifier d avant p et q

La partie ARMA suppose une série stationnaire. Il est donc logique de traiter d’abord la non-stationnarité de niveau :

- inspection graphique ;
- analyse des différences ;
- ADF/PP/KPSS avec spécification justifiée ;
- préférence pour le plus petit d suffisant.

Une fois d choisi, ACF/PACF de la série transformée peuvent aider à proposer p et q .

10.11 Pourquoi la parcimonie est-elle une qualité ?

Avec peu de données, un modèle trop riche peut apprendre des particularités accidentelles. Un paramètre supplémentaire :

- améliore souvent l’ajustement in-sample ;
- augmente pourtant l’incertitude globale ;
- peut créer des racines proches de frontières ;
- complique le diagnostic ;
- peut détériorer la prévision hors échantillon.

Le but n'est donc pas de trouver « le plus gros modèle qui converge ».

10.12 AIC : ajustement plus pénalité

Le critère d'Akaike est

$$AIC = -2\ell(\hat{\vartheta}) + 2k,$$

où k est le nombre de paramètres estimés.

Le premier terme récompense l'ajustement : une meilleure log-vraisemblance rend -2ℓ plus petit. Le second pénalise la complexité.

INTUITION – Pourquoi -2ℓ ?

Le facteur -2 est une convention théorique commode issue de la théorie de vraisemblance et de l'approximation de l'information de Kullback–Leibler. Pour l'usage pratique ici, retenons : plus -2ℓ est petit, meilleur est l'ajustement ; ajouter des paramètres doit compenser la pénalité $2k$.

10.13 BIC : une pénalité qui croît avec n

Le critère de Schwarz est

$$BIC = -2\ell(\hat{\vartheta}) + k \log n.$$

Lorsque n est grand, $\log n$ dépasse souvent 2 ; BIC pénalise alors plus fortement les modèles riches.




FIGURE 31 – Illustration conceptuelle : ajustement, AIC et BIC ne privilégient pas nécessairement la même complexité.

10.14 AIC/BIC ne sont pas des métriques de prévision future

AIC et BIC sont calculés à partir des données d'estimation. Ils ne voient pas le futur. Deux modèles peuvent être classés par AIC d'une manière et par MAE future d'une autre.

ATTENTION – Interdit : sélectionner sur le test final

On peut utiliser AIC/BIC sur l'entraînement pour générer des candidats, puis utiliser une validation temporelle pour choisir une architecture. Le test final ne doit pas être rouvert à chaque fois qu'un résultat déplaît, sinon il devient implicitement une donnée d'entraînement.

10.15 Convergence numérique, optimum local et diagnostics d'estimation

Une estimation est une optimisation. Il faut vérifier :

- si l'algorithme a convergé ;
- si les paramètres respectent les contraintes choisies ;
- si les erreurs-types sont raisonnables ;
- si la matrice de covariance n'est pas pathologique ;
- si les racines sont compatibles avec stationnarité/invertibilité ;
- si le modèle n'est pas inutilement redondant.

Un message de convergence n'est pas un détail technique à supprimer : il peut être le signe que le modèle choisi ne correspond pas bien aux données ou que les paramètres sont mal identifiés.

10.16 Ce que l'on demande à un modèle estimé avant de prévoir

Un modèle candidat n'est acceptable que si :

1. sa transformation est justifiée ;
2. ses paramètres sont estimables et interprétables ;
3. ses racines sont cohérentes avec les conditions voulues ;
4. ses résidus ne conservent pas une mémoire linéaire évidente ;
5. sa performance future est comparée à des baselines.

À RETENIR – L'estimation ne termine pas le travail

Un modèle avec une belle table de coefficients peut être inadéquat. L'étape suivante est de regarder ce qu'il a laissé derrière lui : les résidus.

11 Résidus, prévision et validation temporelle : vérifier avant de croire

11.1 Résidu : ce que le modèle n'a pas expliqué

Après estimation, une valeur ajustée $\hat{X}_t$ est la partie du signal que le modèle reconstruit avec les informations qu'il utilise. Le résidu est

$$\hat{\varepsilon}_t = X_t - \hat{X}_t.$$

Si le modèle a correctement capturé la dépendance linéaire visée, les résidus ne doivent plus montrer une structure temporelle évidente exploitable par le même type de modèle.

ATTENTION – Résidu petit ne signifie pas modèle bon

Un modèle très flexible peut produire de petits résidus in-sample simplement parce qu'il sur-ajuste. Le diagnostic doit porter sur la structure des résidus et sur la performance future, pas seulement sur leur amplitude moyenne dans l'échantillon d'entraînement.

11.2 Que signifie « les résidus ressemblent à un bruit blanc » ?

On vérifie notamment :

- une moyenne résiduelle proche de zéro ;
- une ACF résiduelle sans structure systématique ;
- l'absence de motifs temporels visibles ;
- une distribution compatible avec les hypothèses utilisées si celles-ci sont importantes pour les intervalles ;
- une variance suffisamment stable pour la tâche, ou au moins une reconnaissance explicite de son instabilité.




FIGURE 32 – Une série de résidus et son ACF : le diagnostic cherche ce que la dynamique moyenne n'a pas absorbé.

11.3 Pourquoi une ACF résiduelle ne suffit pas à elle seule ?

Inspecter 20 ou 30 lags séparément reproduit le problème de multiplicité déjà rencontré. Nous voulons aussi une statistique globale qui demande : « prises ensemble jusqu'au lag h , les autocorrélations résiduelles sont-elles compatibles avec zéro ? »

C'est l'idée du test de Ljung–Box (Ljung et Box, 1978).

11.4 La statistique de Ljung–Box, terme par terme

Soit $\hat{\rho}_k$ l'autocorrélation des résidus au lag k . La statistique est

$$Q(h) = n(n+2) \sum_{k=1}^h \frac{\hat{\rho}_k^2}{n-k}.$$

Chaque composante a un rôle :

- $\hat{\rho}_k^2$ rend positives les autocorrélations positives ou négatives et mesure leur amplitude ;

- la somme agrège plusieurs lags ;
- $n - k$ corrige le fait qu'il existe moins de couples disponibles aux grands retards ;
- le facteur $n(n + 2)$ produit une correction de petit échantillon par rapport à une forme de type Box–Pierce.

Sous H_0 , schématiquement,

$$H_0 : \rho_1 = \dots = \rho_h = 0.$$

Pour un modèle sans paramètres estimés ou sous des approximations usuelles, $Q(h)$ est comparé à une loi du χ^2 . Pour des résidus d'un ARMA estimé, on ajuste souvent les degrés de liberté en tenant compte de $p + q$.




FIGURE 33 – Ljung–Box cumule l'information de plusieurs autocorrélations résiduelles au lieu de juger une barre isolée.

LECTURE D'UNE SORTIE – Une grande p-value ne prouve pas l'indépendance

Si la p-value Ljung–Box vaut 0,42, on ne rejette pas l'hypothèse d'absence d'autocorrélation globale jusqu'aux lags testés. Cela signifie que le test ne trouve pas assez d'évidence contre H_0 ; cela ne démontre ni indépendance, ni normalité, ni absence de dépendance non linéaire.

11.5 Prévoir, c'est calculer une distribution conditionnelle

Une prévision ponctuelle au temps t pour l'horizon h peut être notée

$$\hat{X}_{t+h|t}.$$

La notation « $| t$ » rappelle que seules les informations disponibles jusqu'au temps t peuvent être utilisées.

Conceptuellement, la meilleure prévision quadratique est l'espérance conditionnelle :

$$\hat{X}_{t+h|t} = \mathbb{E}[X_{t+h} | \mathcal{F}_t],$$

où $\mathcal{F}_t$ désigne l'information disponible à t .

11.6 Prévision AR(1) à un pas

Pour

$$X_t - \mu = \phi(X_{t-1} - \mu) + \varepsilon_t,$$

au temps t , X_t est connu et ε_{t+1} a une espérance conditionnelle nulle. Donc

$$\hat{X}_{t+1|t} = \mu + \phi(X_t - \mu).$$

À deux pas,

$$\hat{X}_{t+2|t} = \mu + \phi^2(X_t - \mu).$$

Plus généralement,

$$\boxed{\hat{X}_{t+h|t} = \mu + \phi^h(X_t - \mu).}$$

Pour $|\phi| < 1$, la prévision moyenne converge vers μ .

11.7 Erreur de prévision et variance à un horizon donné

Définissons l'erreur future

$$e_{t+h|t} = X_{t+h} - \hat{X}_{t+h|t}.$$

Pour un AR(1),

$$e_{t+h|t} = \varepsilon_{t+h} + \phi\varepsilon_{t+h-1} + \dots + \phi^{h-1}\varepsilon_{t+1}.$$

Si les innovations sont non corrélées, de variance σ_ε^2 ,

$$\text{Var}(e_{t+h|t}) = \sigma_\varepsilon^2 \sum_{j=0}^{h-1} \phi^{2j} = \sigma_\varepsilon^2 \frac{1 - \phi^{2h}}{1 - \phi^2}.$$

Lorsque $h \rightarrow \infty$ et $|\phi| < 1$,

$$\text{Var}(e_{t+h|t}) \rightarrow \frac{\sigma_\varepsilon^2}{1 - \phi^2},$$

qui est la variance inconditionnelle du processus. À très long terme, l'observation actuelle n'apporte plus d'avantage sur l'incertitude de fond.

11.8 Intervalle de prévision : le retour de 1,96

Si l'erreur de prévision est approximativement normale, un intervalle conditionnel approximatif à 95% est

$$\hat{X}_{t+h|t} \pm 1,96\sqrt{\text{Var}(e_{t+h|t})}.$$

Le nombre 1,96 n'a rien de nouveau : il est exactement le quantile normal étudié au début du chapitre. Ce qui change ici est l'erreur-type utilisée : elle est celle de la **prévision future**, pas celle d'un coefficient ou d'une ACF.




FIGURE 34 – Dans un AR(1), la prévision moyenne revient vers le centre tandis que l'incertitude augmente jusqu'à la variance inconditionnelle.

ATTENTION – Intervalle de prévision conditionnel au modèle

Si les innovations ont des queues épaisses, si la variance varie dans le temps, si les paramètres changent ou si le modèle est mal spécifié, la couverture réelle peut être très différente de 95%. Un intervalle calculé n'est pas une garantie contractuelle sur le futur.

11.9 Prévision à origine fixe et walk-forward

Deux protocoles doivent être distingués.

Origine fixe. On entraîne une fois jusqu'à une date T , puis on prévoit plusieurs horizons futurs sans réestimer avec les nouvelles observations du test.

Walk-forward. On avance dans le temps. À chaque étape, on réestime éventuellement le modèle avec les données réellement disponibles, puis on prévoit le bloc suivant.




FIGURE 35 – Origine fixe et walk-forward respectent tous deux l'ordre du temps, mais répondent à des scénarios opérationnels différents.

11.10 Pourquoi un split aléatoire est généralement faux en séries temporelles

Si l'on mélange aléatoirement les dates, une observation future peut se retrouver dans l'entraînement alors qu'une observation passée est dans le test. Le modèle apprend alors indirectement un futur qui n'aurait pas été disponible en situation réelle.

La règle de base est :

tout ce qui sert à décider à t doit être calculé avec l'information disponible au plus tard à t .

11.11 Fuite temporelle : les formes les plus fréquentes

Une fuite peut apparaître si l'on :

- standardise toute la série avec une moyenne calculée aussi sur le futur ;
- choisit p, d, q après avoir regardé le test ;
- impute une valeur manquante avec une méthode utilisant des observations futures ;
- calcule un indicateur centré utilisant $t + 1$ pour produire le signal à t ;
- choisit la meilleure transformation après avoir comparé ses performances sur le test final.

11.12 Baselines : pourquoi une méthode sophistiquée doit battre quelque chose de simple

Une baseline est une règle élémentaire utilisée comme référence. Pour un niveau temporel, deux baselines fréquentes sont :

Persistence.

$$\hat{X}_{t+1|t} = X_t.$$

La meilleure prévision de demain est simplement aujourd'hui.

Drift. Si l'on observe une tendance moyenne entre le début et la fin de l'entraînement, on extrapole cette pente.

Un ARIMA qui ne fait pas mieux qu'une règle de persistance ou de drift n'est pas forcément inutile scientifiquement, mais sa valeur prédictive additionnelle doit être questionnée.




FIGURE 36 – Exemple synthétique : comparer la trajectoire future réelle à la persistance, au drift et à ARIMA.

11.13 MAE : erreur absolue moyenne

Pour des observations futures y_i et des prévisions $\hat{y}_i$,

$$MAE = \frac{1}{m} \sum_{i=1}^m |y_i - \hat{y}_i|.$$

La MAE mesure l'erreur absolue moyenne dans l'unité de la variable.

EXEMPLE – Calcul à la main

Si les erreurs valent 1, -2, 0, 3, alors

$$MAE = \frac{|1| + |-2| + 0 + |3|}{4} = \frac{6}{4} = 1,5.$$

11.14 RMSE : pénaliser davantage les grandes erreurs

$$RMSE = \sqrt{\frac{1}{m} \sum_{i=1}^m (y_i - \hat{y}_i)^2}.$$

Le carré rend les grandes erreurs plus coûteuses.

Avec les mêmes erreurs,

$$RMSE = \sqrt{\frac{1^2 + (-2)^2 + 0^2 + 3^2}{4}} = \sqrt{3,5} \approx 1,87.$$




FIGURE 37 – Deux modèles peuvent avoir des profils d’erreur différents ; MAE et RMSE ne pondèrent pas les grands écarts de la même manière.

11.15 Pourquoi la meilleure métrique dépend de la décision

Une erreur de 10 unités peut être dix fois plus grave qu’une erreur de 1, ou beaucoup plus grave selon le problème. MAE et RMSE sont des résumés mathématiques, pas des fonctions universelles de coût économique.

En trading, une faible RMSE sur le niveau d’un prix ne garantit pas un signal profitable. La direction, le timing, les coûts, la taille de position et la gestion du risque interviennent. CH02 reste volontairement centré sur la qualité de la prévision temporelle.

11.16 Comparer sans réutiliser le test

Un protocole propre distingue au minimum :

- **train** : estimation des paramètres ;
- **validation** : choix des hyperparamètres, transformations, ordres ;
- **test** : évaluation finale d’une règle gelée.

Lorsque les données sont rares, des schémas walk-forward permettent de répéter des évaluations temporelles sans mélanger le futur au passé.

11.17 Pourquoi une bonne moyenne ne suffit pas si la variance change

Un ARIMA classique peut capturer correctement la moyenne conditionnelle tout en laissant des résidus dont l'amplitude alterne entre périodes calmes et périodes turbulentes. Dans ce cas, l'ACF des résidus peut être faible mais l'ACF des résidus au carré rester élevée.

C'est la transition naturelle vers CH03 : modéliser la **variance conditionnelle** avec ARCH/GARCH.

À RETENIR – Ce que signifie une prévision défendable

Une prévision n'est défendable que si sa variable a été définie, son modèle diagnostiqué, son information temporelle respectée, son incertitude explicitée et sa performance comparée sur un futur non utilisé pour la construire.

12 Exemple guidé intégral, exercices et synthèse

12.1 Un diagnostic complet sans sauter d'étape

Considérons une série synthétique Y_t observée quotidiennement. Elle est construite pour ressembler à un niveau économique ou financier : elle évolue, dérive et contient une dépendance temporelle dans ses variations. Nous ne supposons pas que le lecteur sait « reconnaître » un ARIMA. Nous suivrons les questions dans l'ordre.

Étape 1 — Que représente la variable ?

La colonne `arima_level` du dataset du chapitre est un **niveau synthétique**. Ce n'est ni un rendement réel, ni le prix d'un actif réel. Son unité est arbitraire. Cette précision est nécessaire : le sens d'une différence, d'un logarithme ou d'une erreur dépend de la variable modélisée.

Étape 2 — Le niveau semble-t-il stable ?

On trace d'abord Y_t . Une trajectoire qui dérive ne prouve pas une racine unitaire, mais elle rend plausible l'idée que la moyenne du niveau n'est pas constante. On ne calcule pas encore ADF « parce que c'est la commande standard » ; on formule d'abord l'hypothèse à tester.

Étape 3 — Comparer niveau et première différence

On calcule

$$\Delta Y_t = Y_t - Y_{t-1}.$$

Si le niveau accumule les variations, la différence peut être beaucoup plus stable. On compare les deux séries, leur moyenne, leur variance et leurs ACF.

Étape 4 — Tester le niveau et la différence

Pour le niveau, on utilise ADF avec une spécification déterministe justifiée. Une absence de rejet de la racine unitaire, combinée à un KPSS qui rejette la stationnarité, renforce l'hypothèse d'une série $I(1)$. Pour la différence, on attend le diagnostic inverse.

ATTENTION – Aucun test isolé ne décide de la transformation

Le choix $d = 1$ est justifié par un faisceau : mécanisme, graphique, stabilité de la différence, ACF, ADF/PP/KPSS, et contrôle que la différenciation n'est pas excessive.

Étape 5 — Examiner ACF/PACF de la série stationnaire

Supposons que ΔY_t soit stationnaire. On examine son ACF et sa PACF. Une décroissance dans les deux peut suggérer un ARMA plutôt qu'un AR ou MA pur. On génère alors quelques candidats parcimonieux, par exemple

$$ARIMA(1, 1, 0), \quad ARIMA(0, 1, 1), \quad ARIMA(1, 1, 1), \quad ARIMA(2, 1, 1).$$

Ce sont des candidats à comparer, pas quatre vérités possibles.

Étape 6 — Estimer sur le train uniquement

On choisit une date de coupure. Toutes les opérations d'estimation, y compris la sélection des ordres et la calibration des transformations, utilisent uniquement les données antérieures à cette date.

Étape 7 — Comparer AIC/BIC et diagnostiquer les résidus

Un petit AIC ne suffit pas. Pour chaque candidat, on contrôle : convergence, racines, paramètres, ACF résiduelle, Ljung-Box et éventuellement la stabilité de la variance.

Étape 8 — Construire une vraie prévision future

On gèle un modèle principal à partir du train/validation. On produit ensuite une prévision sur le test futur et on calcule MAE et RMSE.

Étape 9 — Comparer aux baselines

La persistance et le drift sont calculés avec la même information que le modèle. Si ARIMA ne les domine pas, ce résultat doit être conservé et interprété, pas masqué.

Étape 10 — Lire l'échec comme information

Si ARIMA ne gagne pas nettement, plusieurs explications sont possibles :

- la moyenne de la série est peu prévisible ;
- la dynamique change hors échantillon ;
- la baseline est déjà très forte ;
- l'incertitude d'estimation annule le gain théorique ;
- la structure intéressante se situe dans la variance plutôt que dans la moyenne.

Une méthode pédagogique sérieuse ne transforme pas toute expérience en succès.

12.2 Exemple numérique miniature : AR(1) de bout en bout

Prenons

$$X_t = 2 + 0,5X_{t-1} + \varepsilon_t, \quad \text{Var}(\varepsilon_t) = 4.$$

Moyenne.

$$\mu = \frac{2}{1 - 0,5} = 4.$$

Variance.

$$\text{Var}(X_t) = \frac{4}{1 - 0,5^2} = \frac{4}{0,75} = 5,333 \dots$$

Donc

$$\sigma_X \approx 2,309.$$

ACF.

$$\rho(1) = 0,5, \quad \rho(2) = 0,25, \quad \rho(3) = 0,125.$$

Demi-vie.

$$h_{1/2} = \frac{\log(0,5)}{\log(0,5)} = 1.$$

Un choc est divisé par deux à chaque période.

Prévision. Si $X_t = 8$,

$$\hat{X}_{t+1|t} = 4 + 0,5(8 - 4) = 6.$$

À deux pas,

$$\hat{X}_{t+2|t} = 4 + 0,5^2(8 - 4) = 5.$$

À long terme, la prévision revient vers 4.

Variance d'erreur à deux pas.

$$\text{Var}(e_{t+2|t}) = 4(1 + 0,5^2) = 5.$$

Donc l'écart-type vaut $\sqrt{5} \approx 2,236$ et un intervalle normal approximatif à 95% est

$$5 \pm 1,96 \times 2,236,$$

soit environ

$$[0,62; 9,38].$$

Chaque nombre utilisé dans ce calcul a maintenant été défini et dérivé dans le chapitre.

12.3 Exemple numérique miniature : bande ACF

Avec $n = 400$ observations de bruit blanc,

$$\text{SE}(\hat{\rho}(k)) \approx \frac{1}{\sqrt{400}} = 0,05.$$

La bande bilatérale approximative à 95% est

$$\pm 1,96 \times 0,05 = \pm 0,098.$$

Une barre à 0,07 n'est donc pas remarquable isolément ; une barre à 0,15 dépasse cette référence ponctuelle. Mais si 30 lags sont inspectés, on tient compte de la multiplicité et de la structure d'ensemble.

12.4 Exemple numérique miniature : ADF

Supposons qu'une régression ADF renvoie

$$\hat{\gamma} = -0,21,$$

avec statistique ADF $-3,7$, valeur critique 5% $-2,9$ et p-value $0,004$.

Le raisonnement est :

1. $H_0 : \gamma = 0$ représente la racine unitaire ;
2. une statistique très négative est défavorable à H_0 ;
3. $-3,7 < -2,9$ et $0,004 < 0,05$;
4. on rejette H_0 au niveau 5% dans cette spécification ;
5. on n'en déduit pas que la série est stationnaire « pour toujours » : on complète par diagnostics et robustesse.

12.5 Laboratoires numériques associés

Le chapitre est accompagné de deux notebooks.

NB01 — Fondations, ACF et AR(1). Loi normale, 1,96, TCL, bruit blanc gaussien/non gaussien, distribution d'échantillonnage de l'ACF, propagation d'un choc, variance AR(1), demi-vie, racines et cercle unité.

NB02 — Stationnarité, tests et ARIMA. Différenciation, sur-différenciation, ADF/KPSS, identification ACF/PACF, estimation ARIMA, AIC/BIC, Ljung–Box, prévisions, baselines, fixed-origin et walk-forward.

POINT DE VUE INGÉNIEUR – Règle de lecture des notebooks

Chaque expérience numérique vient après la théorie correspondante. Le notebook n'introduit pas un objet mathématique inédit : il permet de calculer, visualiser et tester un mécanisme déjà compris.

12.6 Exercices de compréhension conceptuelle

1. Expliquez avec vos mots la différence entre une variable aléatoire et une réalisation observée.
2. Pourquoi une densité normale élevée autour de zéro ne signifie-t-elle pas $P(Z = 0) > 0$?
3. Dérivez le fait que $P(-1,96 \leq Z \leq 1,96) \approx 0,95$ à partir de $\Phi(1,96) \approx 0,975$.
4. Pourquoi la largeur d'un intervalle basé sur une erreur-type en $1/\sqrt{n}$ ne diminue-t-elle pas de moitié lorsque l'on double n ?
5. Donnez un exemple d'absence de corrélation sans indépendance.
6. Expliquez pourquoi un bruit blanc uniforme peut être un bruit blanc au même titre qu'un bruit blanc gaussien.
7. Pourquoi l'ACF empirique d'un vrai bruit blanc contient-elle malgré tout des barres non nulles ?
8. Que signifie réellement la condition $|\phi| < 1$ en termes de mémoire d'un choc ?
9. Pourquoi $\phi = -0,8$ produit-il un retour oscillant ?

10. Pourquoi la formule $\mu = c/(1 - \phi)$ ne doit-elle pas être appliquée à $\phi = 1$ comme une simple substitution numérique ?
11. Expliquez pourquoi $\text{Var}(X_t) = \sigma_\varepsilon^2/(1 - \phi^2)$ augmente lorsque $|\phi|$ augmente.
12. Pourquoi le coefficient AR peut être « dans » le cercle unité alors que la racine du polynôme doit être « dehors » ?
13. Expliquez l'invertibilité MA sans utiliser le mot « invertibilité » dans votre première phrase.
14. Pourquoi l'ACF d'un MA(1) se coupe-t-elle après le lag 1 ?
15. Quelle différence conceptuelle sépare ACF et PACF ?
16. Pourquoi différencier une marche aléatoire produit-il son innovation ?
17. Pourquoi sur-différencier peut-il créer une dynamique MA artificielle ?
18. Montrez algébriquement que tester $\rho = 1$ dans un AR(1) revient à tester $\gamma = 0$ dans une régression sur ΔX_t .
19. Pourquoi ADF et KPSS peuvent-ils être complémentaires ?
20. Expliquez pourquoi le plus petit AIC ne garantit pas la plus petite MAE future.
21. Pourquoi une grande p-value Ljung–Box ne prouve-t-elle pas l'indépendance des résidus ?
22. Expliquez pourquoi un intervalle de prévision s'élargit généralement avec l'horizon.
23. Donnez trois exemples de fuite temporelle.

12.7 Exercices de calcul

1. Pour $X_t = 1 + 0,75X_{t-1} + \varepsilon_t$, avec $\text{Var}(\varepsilon_t) = 9$, calculez μ , $\text{Var}(X_t)$, $\rho(1)$, $\rho(4)$ et la demi-vie.
2. Pour un échantillon de taille $n = 625$, calculez la bande ACF approximative 95% sous bruit blanc.
3. Pour un MA(1) avec $\theta = 0,5$, calculez $\text{Var}(X_t)/\sigma_\varepsilon^2$ et $\rho(1)$.
4. Montrez que les valeurs $\theta = 2$ et $\theta = 1/2$ produisent la même $\rho(1)$ dans un MA(1). Laquelle retient-on sous convention d'invertibilité ?
5. Pour un AR(1) avec $\phi = 0,9$ et $X_t - \mu = 10$, calculez la prévision de l'écart à la moyenne aux horizons 1, 2, 5 et 10.
6. Si les erreurs de quatre prévisions sont $-1, 2, 2, -5$, calculez MAE et RMSE.

12.8 Exercices d'analyse et de diagnostic

1. Une série a une ACF très élevée et décroissante lentement, ADF ne rejette pas et KPSS rejette. Proposez une suite de diagnostics sans décider immédiatement qu'il faut ARIMA(5,1,5).
2. Une série stationnaire autour d'une tendance est testée avec ADF sans tendance. Expliquez pourquoi la spécification peut conduire à une conclusion trompeuse.
3. Un ARIMA(2,1,2) a un AIC plus faible qu'un ARIMA(1,1,1), mais Ljung–Box est satisfaisant pour les deux et le modèle complexe a des coefficients très incertains. Discutez le choix.
4. Les résidus ont une ACF proche de zéro mais leur amplitude arrive en grappes. Quelle partie du modèle semble correctement traitée et quelle partie reste à modéliser ?

5. Un modèle bat la persistance in-sample mais perd contre elle sur le test futur. Pourquoi ce résultat est-il plus informatif qu'un très bon ajustement d'entraînement ?

12.9 Checklist « zéro boîte noire » avant de quitter CH02

Le lecteur doit pouvoir expliquer, sans logiciel :

- | | |
|---|---------------------------------|
| — variable aléatoire et réalisation ; | — polynôme AR et cercle unité ; |
| — espérance et variance ; | — MA et invertibilité ; |
| — covariance et corrélation ; | — PACF ; |
| — indépendance et non-corrélation ; | — ARMA ; |
| — densité, CDF et quantile ; | — racine unitaire ; |
| — normale standard et 1,96 ; | — différence et $I(d)$; |
| — erreur-type et TCL ; | — ADF, PP, KPSS ; |
| — processus stochastique ; | — ARIMA(p, d, q) ; |
| — lag et innovation ; | — vraisemblance ; |
| — stationnarité stricte/faible ; | — AIC/BIC ; |
| — bruit blanc ; | — résidus ; |
| — marche aléatoire ; | — Ljung–Box ; |
| — ACF théorique/empirique ; | — prévision conditionnelle ; |
| — $1/\sqrt{n}$ et bandes ACF ; | — intervalle de prévision ; |
| — AR(1), ϕ^k , moyenne, variance ; | — MAE/RMSE ; |
| — demi-vie ; | — baseline ; |
| — opérateur L ; | — split temporel et fuite. |

12.10 Synthèse : une seule histoire, pas trente notions séparées

Le chapitre peut être résumé par une chaîne logique.

Une série temporelle est une réalisation d'un processus aléatoire. Si ses propriétés de second ordre sont stables, l'autocovariance et l'autocorrélation ont un sens durable. L'ACF empirique fluctue parce qu'elle est un estimateur ; sous bruit blanc, son erreur-type est approximativement $1/\sqrt{n}$, d'où les bandes utilisant le quantile normal 1,96.

Un AR transporte le passé par les valeurs ; un MA transporte les chocs ; ARMA combine les deux. La stabilité AR se comprend par l'oubli géométrique et par les racines du polynôme hors du cercle unité. L'invertibilité MA garantit une reconstruction stable et identifiable des innovations.

Une racine unitaire empêche l'oubli et produit une accumulation de chocs. La différenciation applique le facteur $(1 - L)$ correspondant. ADF, PP et KPSS aident à distinguer stationnarité et non-stationnarité, à condition de respecter leurs hypothèses et leur spécification.

ARIMA modélise ensuite la dynamique stationnaire après différenciation. Estimer n'est que le début : il faut diagnostiquer les résidus, comparer des modèles parcimonieux, quantifier l'incertitude, tester hors échantillon, affronter des baselines et protéger le protocole contre les fuites temporelles.

À RETENIR – La phrase à conserver

Comprendre une série temporelle, ce n'est pas appliquer ARIMA ; c'est construire une chaîne de raisons qui explique pourquoi la variable, la transformation, le modèle, le test, la prévision et l'évaluation sont cohérents entre eux.

12.11 Transition vers CH03

Même lorsque les résidus d'un modèle de moyenne sont peu autocorrélés, leurs carrés peuvent rester fortement autocorrélés. Cela signifie que la moyenne est peut-être difficile à prévoir, alors que l'**intensité des fluctuations** possède une mémoire.

Le chapitre suivant partira exactement de cette observation pour construire ARCH, GARCH et les modèles de volatilité conditionnelle — sans revenir sur les fondations probabilistes et temporelles maintenant établies.

Références essentielles

- [1] Akaike, H. (1974). A New Look at the Statistical Model Identification. *IEEE Transactions on Automatic Control*, 19(6), 716–723.
- [2] Bartlett, M. S. (1946). On the Theoretical Specification and Sampling Properties of Autocorrelated Time-Series. *Supplement to the Journal of the Royal Statistical Society*, 8, 27–41.
- [3] Box, G. E. P., Jenkins, G. M., Reinsel, G. C. et Ljung, G. M. (2015). *Time Series Analysis : Forecasting and Control*, 5e éd., Wiley.
- [4] Brockwell, P. J. et Davis, R. A. (2016). *Introduction to Time Series and Forecasting*, 3e éd., Springer.
- [5] Dickey, D. A. et Fuller, W. A. (1979). Distribution of the Estimators for Autoregressive Time Series with a Unit Root. *JASA*, 74, 427–431.
- [6] Hamilton, J. D. (1994). *Time Series Analysis*. Princeton University Press.
- [7] Hyndman, R. J. et Athanasopoulos, G. (2021). *Forecasting : Principles and Practice*, 3e éd., OTexts.
- [8] Kwiatkowski, D., Phillips, P. C. B., Schmidt, P. et Shin, Y. (1992). Testing the Null Hypothesis of Stationarity against the Alternative of a Unit Root. *Journal of Econometrics*, 54, 159–178.
- [9] Ljung, G. M. et Box, G. E. P. (1978). On a Measure of Lack of Fit in Time Series Models. *Biometrika*, 65(2), 297–303.
- [10] Phillips, P. C. B. et Perron, P. (1988). Testing for a Unit Root in Time Series Regression. *Biometrika*, 75(2), 335–346.
- [11] Schwarz, G. (1978). Estimating the Dimension of a Model. *The Annals of Statistics*, 6(2), 461–464.