
TRADING INTELLIGENT

Économétrie financière, Machine Learning, Time Series, Deep Learning
et Reinforcement Learning pour la décision de marché

CHAPITRE 3

Comprendre et prévoir le risque

Volatilité conditionnelle, ARCH, GARCH et extensions

Question directrice : comment modéliser un marché dont le rendement moyen paraît difficile à prévoir, alors que l'intensité de ses fluctuations varie de façon persistante et contient une information exploitable sur le risque futur ?

Tawfik Masrour

Version 2.1 – octobre 2026

Comment utiliser ce chapitre

Le chapitre précédent a montré qu'une série temporelle peut conserver une mémoire dans sa moyenne et que cette mémoire peut être modélisée par des processus AR, MA, ARMA ou ARIMA. Mais les séries financières présentent souvent un phénomène différent : leur rendement peut être faiblement autocorrélé tandis que son amplitude reste fortement structurée dans le temps.

Nous allons donc déplacer la question. Il ne s'agit plus seulement de prévoir *où* se situera la prochaine observation, mais aussi de quantifier *l'incertitude* qui entoure cette observation. Cette transition conduit naturellement aux modèles ARCH et GARCH, puis aux extensions asymétriques et aux mesures de risque conditionnel.

À RETENIR – Principe de travail

Une série peut être presque imprévisible dans sa direction et pourtant très prévisible dans son niveau de risque. En finance, cette distinction entre **moyenne conditionnelle** et **variance conditionnelle** est fondamentale : elle sépare la prévision du rendement de la prévision de l'amplitude des fluctuations.

Table des matières

3	Comprendre et prévoir le risque	1
3.1	De la prévision du rendement à la prévision de son incertitude	1
3.2	Conventions d'unités : le premier piège à éliminer	2
3.3	Volatilité : plusieurs notions à distinguer	3
3.4	Faits stylisés des rendements financiers	4
3.4.1	Faible autocorrélation linéaire des rendements	4
3.4.2	Autocorrélation de l'amplitude	4
3.4.3	Queues épaisses	5
3.4.4	Asymétrie des chocs	5
3.5	Hétéroscédasticité : quand la variance n'est pas constante	5
3.6	ARCH : laisser les chocs récents expliquer le risque futur	6
3.6.1	ARCH d'ordre général	7
3.7	Détecter des effets ARCH	7
3.7.1	Inspection des résidus au carré et de leur ACF	7
3.7.2	Test ARCH-LM	7
3.8	GARCH : donner une mémoire propre à la variance	7
3.9	Stationnarité de la variance et niveau de long terme	9
3.9.1	Demi-vie d'un choc	9
3.9.2	Persistance extrême, IGARCH et changement de régime	10
3.10	Estimation : apprendre les paramètres à partir des rendements	10
3.10.1	Vraisemblance gaussienne et quasi-maximum de vraisemblance	11
3.10.2	Initialisation, convergence et discipline numérique	11
3.10.3	Ajuster n'est pas encore prévoir	11
3.11	Diagnostiquer un GARCH : les résidus standardisés	12
3.12	Loi normale ou Student-t ?	13
3.13	Pourquoi un GARCH symétrique peut être insuffisant	14
3.13.1	GJR-GARCH / Threshold GARCH	14
3.13.2	EGARCH	15
3.14	Prévoir la volatilité	16
3.14.1	Volatilité quotidienne, horizon cumulé et annualisation	17
3.15	Du modèle de volatilité à la Value-at-Risk	17

3.16 Expected Shortfall : regarder au-delà du seuil	18
3.17 Backtester une mesure de risque	19
3.18 Évaluer une prévision de volatilité quand la vraie volatilité est invisible	21
3.19 De GARCH au portefeuille : ce que le modèle change concrètement	22
3.20 Workflow pratique de modélisation	23
3.21 Laboratoire du chapitre	24
3.22 Limites des modèles ARCH/GARCH	25
3.22.1 Ruptures structurelles	25
3.22.2 Mémoire longue	25
3.22.3 Volatilité stochastique	25
3.22.4 Données à haute fréquence	25
3.22.5 Multivarié	25
3.23 Exercices	25
3.24 Lexique local FR-EN	26
3.25 Synthèse	27
3.26 Vers le chapitre suivant	27

Comprendre et prévoir le risque

Volatilité conditionnelle, ARCH, GARCH et extensions

QUESTION DIRECTRICE – Pourquoi les périodes agitées ont-elles tendance à rester agitées ?

Sur de nombreux marchés, la direction du prochain rendement est difficile à anticiper. Pourtant, après un épisode de forte turbulence, les fluctuations importantes ont tendance à se prolonger quelque temps. À l'inverse, les périodes calmes ont elles aussi tendance à se regrouper dans le temps. Ce phénomène de *clustering de volatilité* révèle une mémoire de l'*amplitude* que les modèles de volatilité conditionnelle cherchent précisément à représenter.

3.1 De la prévision du rendement à la prévision de son incertitude

Considérons un rendement r_t . Une écriture générale sépare sa moyenne conditionnelle et son innovation :

$$r_t = \mu_t + \varepsilon_t,$$

où $\mu_t = \mathbb{E}(r_t \mid \mathcal{F}_{t-1})$ représente la moyenne conditionnelle compte tenu de l'information disponible au temps $t - 1$, et ε_t la partie non anticipée.

Au chapitre précédent, l'essentiel de notre attention portait sur μ_t . Nous allons maintenant étudier la variance conditionnelle de l'innovation :

$$\sigma_t^2 = \text{Var}(\varepsilon_t \mid \mathcal{F}_{t-1}).$$

Une représentation très utile est

$$\varepsilon_t = \sigma_t z_t,$$

où z_t est une innovation standardisée de moyenne nulle et de variance unitaire. Toute la dynamique du risque est alors portée par σ_t .




FIGURE 3.1 – Les rendements peuvent fluctuer autour d’une moyenne proche de zéro tandis que leur amplitude se regroupe en périodes calmes et agitées.

INTUITION – Direction et amplitude sont deux problèmes différents

Supposons que demain le rendement puisse être positif ou négatif avec presque autant de chances dans les deux sens. Il reste pourtant essentiel de savoir si un mouvement typique vaut plutôt 0,5% ou 3%. Pour une décision de trading, un levier, une taille de position ou une mesure de risque, ces deux situations n’ont rien d’équivalent.

3.2 Conventions d’unités : le premier piège à éliminer

Avant toute équation, fixons une convention. Un rendement peut être stocké en **décimal** ou exprimé en **pourcentage**. Les deux écritures décrivent la même réalité, mais les paramètres d’un modèle de variance ne prennent pas les mêmes valeurs numériques.

	Décimal	Pourcentage
Rendement de 1,5%	0,015	1,5
Variance correspondante si $\sigma = 1,5\%$	0,000225	2,25
Écart-type	0,015	1,5

Dans ce chapitre, les équations sont indépendantes de l’unité choisie, mais les exemples numériques indiquent explicitement l’échelle utilisée. Les notebooks lisent les rendements du dataset en décimal puis les multiplient parfois par 100 pour estimer les modèles en unités de pourcentage, ce qui améliore la lisibilité numérique.

ATTENTION – Ne jamais mélanger décimaux et pourcentages

Un ω estimé sur des rendements en pourcentage n'est pas directement comparable à un ω estimé sur des rendements en décimal. En revanche, les coefficients sans dimension tels que α , β et la persistance $\alpha + \beta$ restent comparables si la spécification est identique.

EXEMPLE – Un calcul d'échelle très simple

Un rendement de -2% vaut $-0,02$ en décimal. Son carré vaut $0,0004$ en décimal mais 4 en unités de pourcentage. Le mécanisme ARCH est le même dans les deux cas ; seule l'échelle de ω et de la variance change.

3.3 Volatilité : plusieurs notions à distinguer

Le mot *volatilité* est utilisé dans plusieurs sens. Pour éviter toute ambiguïté, nous distinguerons quatre objets.

DÉFINITION – Volatilité inconditionnelle

La volatilité inconditionnelle est l'écart-type global d'un processus lorsque celui-ci possède une variance stable à long terme :

$$\sigma = \sqrt{\text{Var}(r_t)}.$$

Elle résume un niveau moyen de dispersion sur l'ensemble de la distribution.

DÉFINITION – Volatilité conditionnelle

La volatilité conditionnelle au temps t est

$$\sigma_t = \sqrt{\text{Var}(r_t | \mathcal{F}_{t-1})}.$$

Elle dépend de l'information connue avant l'observation de r_t et peut donc varier dans le temps.

DÉFINITION – Volatilité réalisée et proxys ex post

Dans un sens strict, la **volatilité réalisée** est une mesure ex post construite à partir de rendements intrajournaliers, typiquement à partir de la somme de leurs carrés sur une journée, puis de sa racine carrée pour revenir à l'unité d'une volatilité. À fréquence quotidienne, r_t^2 , $|r_t|$ ou une variance glissante sont plutôt des **proxys** de volatilité : utiles, mais plus bruités et à ne pas confondre avec une mesure réalisée haute fréquence.

DÉFINITION – Volatilité implicite

La volatilité implicite est extraite des prix d'options à partir d'un modèle de valorisation. Elle reflète une information de marché orientée vers le futur, mais dépend du modèle et de la structure des options utilisées. Elle ne sera qu'évoquée ici.




FIGURE 3.2 – La variance inconditionnelle décrit un niveau de long terme ; la variance conditionnelle réagit à l'information récente puis peut revenir progressivement vers ce niveau.

EXEMPLE – Une même série, deux lectures

Imaginons un actif dont l'écart-type quotidien de long terme est proche de 1%. Après une annonce majeure, la volatilité conditionnelle peut momentanément atteindre 3%. Dire simplement « la volatilité vaut 1% » masquerait alors précisément l'information qui intéresse le trader : le risque de demain est aujourd'hui bien supérieur à son niveau habituel.

3.4 Faits stylisés des rendements financiers

Les modèles ARCH/GARCH ont été développés pour représenter plusieurs propriétés empiriques fréquemment observées dans les rendements financiers [1, 2, 5].

3.4.1 Faible autocorrélation linéaire des rendements

À des fréquences usuelles, l'autocorrélation des rendements peut être faible. Cela limite la capacité d'un simple modèle linéaire de moyenne à produire des prévisions directionnelles stables.

3.4.2 Autocorrélation de l'amplitude

En revanche, les transformations $|r_t|$ ou r_t^2 peuvent conserver une autocorrélation positive sur de nombreux retards. Une observation importante en amplitude rend donc plus probable une nouvelle période agitée, sans prédire son signe.




FIGURE 3.3 – Une ACF faible des rendements peut coexister avec une ACF persistante des rendements au carré.

EXEMPLE – Pourquoi regarder les carrés ?

Considérons la suite $+3\%, -3\%, +3\%, -3\%$. Les signes alternent, de sorte que la dépendance linéaire du rendement peut être faible ou négative. En revanche, les carrés valent tous 9 en unités de pourcentage au carré : l'amplitude est manifestement persistante.

3.4.3 Queues épaisses

Les rendements financiers présentent souvent davantage d'observations extrêmes qu'une loi normale de même variance. Une partie de cet effet disparaît lorsque la volatilité conditionnelle est correctement modélisée, mais pas nécessairement toute la kurtosis (aplatissement).

3.4.4 Asymétrie des chocs

Pour de nombreux actifs, un choc négatif est suivi d'une hausse de volatilité plus forte qu'un choc positif de même amplitude. Ce phénomène est souvent appelé *leverage effect* ou effet d'asymétrie, même si les mécanismes économiques précis peuvent varier selon l'actif.

3.5 Hétéroscédasticité : quand la variance n'est pas constante

Le terme **hétéroscédasticité** signifie simplement que la variance n'est pas constante. Dans un modèle classique à variance constante,

$$\varepsilon_t \sim (0, \sigma^2),$$

la même variance σ^2 s'applique à toutes les dates.

Dans un modèle de volatilité conditionnelle,

$$\varepsilon_t \mid \mathcal{F}_{t-1} \sim (0, \sigma_t^2),$$

et σ_t^2 dépend du passé.

RAPPEL JUSTE À TEMPS – Variance et écart-type

Si une variable aléatoire X a pour variance $\text{Var}(X) = \sigma^2$, alors son écart-type est σ . Les modèles ARCH/GARCH sont généralement écrits sur la **variance** conditionnelle parce que les carrés des innovations y entrent naturellement. Lorsqu'on parle de volatilité, on revient souvent à $\sigma_t = \sqrt{\sigma_t^2}$ pour retrouver l'unité du rendement.

3.6 ARCH : laisser les chocs récents expliquer le risque futur

Le modèle ARCH, pour *Autoregressive Conditional Heteroskedasticity*, a été introduit par Engle [1]. Dans sa forme ARCH(1),

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2,$$

avec typiquement $\omega > 0$ et $\alpha \geq 0$.

La logique est immédiate : un grand choc hier, positif ou négatif, implique une variance conditionnelle plus élevée aujourd'hui.




FIGURE 3.4 – Dans un ARCH(1) symétrique, la variance future dépend du carré du choc précédent : son amplitude compte, pas son signe.

EXEMPLE – Calcul ARCH(1) à la main

Prenons

$$\omega = 0,20, \quad \alpha = 0,50.$$

Si le choc précédent vaut $\varepsilon_{t-1} = 1$, alors

$$\sigma_t^2 = 0,20 + 0,50 \times 1^2 = 0,70.$$

Si le choc vaut 2, alors

$$\sigma_t^2 = 0,20 + 0,50 \times 4 = 2,20.$$

Doubler l'amplitude du choc multiplie son carré par quatre. Le modèle traduit ainsi fortement les épisodes extrêmes dans la variance suivante.

3.6.1 ARCH d'ordre général

La généralisation à q retards est

$$\sigma_t^2 = \omega + \sum_{i=1}^q \alpha_i \varepsilon_{t-i}^2.$$

Une longue mémoire de volatilité peut alors nécessiter de nombreux coefficients α_i . C'est précisément l'une des motivations du modèle GARCH.

3.7 Détecter des effets ARCH

Avant de construire un modèle de variance conditionnelle, on recherche une structure dans les carrés des résidus d'un modèle de moyenne.

3.7.1 Inspection des résidus au carré et de leur ACF

Une ACF persistante des résidus au carré suggère que l'amplitude des erreurs n'est pas indépendante dans le temps.

3.7.2 Test ARCH-LM

Le test ARCH-LM, pour *Lagrange Multiplier test for ARCH effects*, consiste à expliquer les carrés des résidus par leurs propres retards. Schématiquement,

$$\hat{\varepsilon}_t^2 = c + \beta_1 \hat{\varepsilon}_{t-1}^2 + \dots + \beta_q \hat{\varepsilon}_{t-q}^2 + u_t.$$

L'hypothèse nulle correspond à l'absence d'effet ARCH jusqu'à l'ordre considéré.

ATTENTION – Tester les résidus, pas n'importe quelle série brute

Si la moyenne conditionnelle est mal spécifiée, les résidus peuvent conserver une structure qui sera ensuite attribuée à tort à la variance. La bonne démarche consiste à modéliser suffisamment la moyenne, puis à examiner les propriétés des innovations restantes.

3.8 GARCH : donner une mémoire propre à la variance

Bollerslev [2] généralise ARCH en permettant à la variance conditionnelle passée de contribuer directement à la variance actuelle. Le GARCH(1,1) s'écrit

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2.$$

Les trois termes jouent des rôles distincts :

- ω crée un niveau de base ;
- α mesure la sensibilité immédiate aux nouvelles, via ε_{t-1}^2 ;
- β mesure la persistance de la variance passée.

EXEMPLE – Lire trois paramétrages

- α élevé, β modéré : la volatilité réagit fortement aux nouvelles, mais l'effet s'efface relativement vite ;
- α faible, β élevé : la réaction immédiate est plus douce, mais l'état de volatilité possède une forte inertie ;
- $\alpha + \beta$ proche de 1 : les chocs de variance se dissipent lentement.

EXEMPLE – Prédiction GARCH à un pas, terme par terme

Supposons que les rendements soient exprimés en pourcentage et que

$$\omega = 0,04, \quad \alpha = 0,08, \quad \beta = 0,88,$$

avec un choc précédent $\varepsilon_t = -1,5$ et une variance courante $\sigma_t^2 = 1,20$. Alors

$$\sigma_{t+1}^2 = 0,04 + 0,08(1,5)^2 + 0,88(1,20) = 0,04 + 0,18 + 1,056 = 1,276.$$

La volatilité prévue vaut donc

$$\sigma_{t+1} \approx \sqrt{1,276} \approx 1,13\%.$$

Le calcul montre concrètement le rôle des trois composantes : niveau de base, nouvelle information et mémoire de la variance.




FIGURE 3.5 – Une prédiction GARCH à un pas est la somme d'un niveau de base, de l'impact du dernier choc et de la mémoire de la variance précédente.




FIGURE 3.6 – Un même choc produit des trajectoires très différentes selon la persistance $\alpha + \beta$.

3.9 Stationnarité de la variance et niveau de long terme

Sous une formulation GARCH(1,1) standard, une condition classique de variance inconditionnelle finie est

$$\alpha + \beta < 1.$$

En prenant les espérances de l'équation de variance dans un régime stationnaire,

$$\mathbb{E}(\sigma_t^2) = \omega + (\alpha + \beta)\mathbb{E}(\sigma_t^2),$$

d'où

$$\bar{\sigma}^2 = \frac{\omega}{1 - \alpha - \beta}.$$

EXEMPLE – Calcul d'une volatilité de long terme

Prenons $\omega = 0,04$, $\alpha = 0,08$ et $\beta = 0,88$ dans des unités de rendement exprimé en pourcentage. Alors

$$\alpha + \beta = 0,96$$

et

$$\bar{\sigma}^2 = \frac{0,04}{1 - 0,96} = 1.$$

La volatilité de long terme vaut donc $\sqrt{1} = 1\%$ par période.

3.9.1 Demi-vie d'un choc

Lorsque la dynamique est approximativement gouvernée par la persistance $p = \alpha + \beta$, la demi-vie d'un choc peut être interprétée par

$$h_{1/2} = \frac{\log(0,5)}{\log(p)}.$$

Elle indique le nombre de périodes nécessaires pour que l'écart au niveau de long terme soit réduit de moitié.




FIGURE 3.7 – Une persistance proche de 1 peut transformer une petite variation de coefficient en une très longue mémoire du risque.

POINT DE VUE INGÉNIEUR – Pourquoi la persistance compte pour le trading

Une stratégie qui dimensionne ses positions en fonction de la volatilité réagira très différemment selon que le risque revient à la normale en trois jours ou en trente jours. La persistance influence donc directement le leverage, le sizing, les limites de risque et la vitesse d'adaptation du système.

3.9.2 Persistance extrême, IGARCH et changement de régime

Lorsque $\alpha + \beta$ est très proche de 1, deux lectures sont possibles. La première est qu'un choc de volatilité se dissipe réellement très lentement. La seconde est que le modèle stationnaire tente d'absorber des **ruptures de régime** qu'il ne représente pas explicitement. Il ne faut donc pas interpréter mécaniquement une persistance de 0,998 comme une loi structurelle du marché.

Le cas limite $\alpha + \beta = 1$ est souvent associé à la famille **IGARCH**. La variance inconditionnelle finie de la forme $\omega/(1 - \alpha - \beta)$ n'existe alors plus. Ce cas mérite une analyse spécifique et ne doit pas être confondu avec un GARCH stationnaire ordinaire.

ATTENTION – Une grande persistance n'est pas une preuve de mémoire infinie

Avant de conclure, il faut examiner les ruptures, la période d'estimation, les diagnostics résiduels et la stabilité des paramètres sur plusieurs sous-échantillons.

3.10 Estimation : apprendre les paramètres à partir des rendements

Supposons

$$z_t \sim \mathcal{N}(0, 1), \quad \varepsilon_t = \sigma_t z_t.$$

Conditionnellement à $\mathcal{F}_{t-1}$,

$$\varepsilon_t \sim \mathcal{N}(0, \sigma_t^2).$$

La contribution de l'observation t à la log-vraisemblance gaussienne est, à une constante près,

$$\ell_t = -\frac{1}{2} \left(\log \sigma_t^2 + \frac{\varepsilon_t^2}{\sigma_t^2} \right).$$

L'estimation par maximum de vraisemblance choisit les paramètres qui rendent les observations les plus plausibles sous le modèle.

RAPPEL JUSTE À TEMPS – Maximum de vraisemblance

Le maximum de vraisemblance ne cherche pas à minimiser directement l'erreur de prévision du rendement. Il choisit les paramètres qui maximisent la densité conditionnelle attribuée aux observations réellement vues. Dans GARCH, la vraisemblance dépend récursivement de toute la trajectoire de variance.

Des contraintes sont nécessaires pour préserver une variance positive et, selon la spécification, assurer l'existence d'un moment inconditionnel fini.

3.10.1 Vraisemblance gaussienne et quasi-maximum de vraisemblance

Dans la pratique, on peut estimer un GARCH avec une vraisemblance gaussienne même lorsque les innovations ne sont pas parfaitement normales. Sous certaines conditions de régularité et si la dynamique de variance est correctement spécifiée, cette démarche est interprétée comme un **quasi-maximum de vraisemblance** (QMLE). Pour l'inférence, on utilise souvent des erreurs standards robustes à la non-normalité. L'idée importante pour ce chapitre est la suivante : l'hypothèse de distribution utilisée pour estimer la dynamique de variance et l'hypothèse utilisée pour décrire les queues ne doivent pas être confondues.

Une Student-t peut améliorer la description des queues, mais une bonne distribution ne compense pas une mauvaise dynamique de variance. Réciproquement, un GARCH bien calibré peut encore laisser des queues épaisses dans les résidus standardisés.

3.10.2 Initialisation, convergence et discipline numérique

L'estimation GARCH est récursive. Il faut initialiser la première variance, imposer des contraintes admissibles et vérifier la convergence réelle de l'optimiseur. Une sortie numérique, à elle seule, ne constitue pas une preuve statistique crédible.

POINT DE VUE INGÉNIEUR – Trois contrôles minimaux après optimisation

Toujours vérifier : **(1)** le statut de convergence, **(2)** l'admissibilité des paramètres, **(3)** la stabilité du résultat lorsque l'on change raisonnablement l'initialisation. Les notebooks du chapitre affichent explicitement le statut de l'optimiseur.

3.10.3 Ajuster n'est pas encore prévoir

Un modèle peut très bien expliquer l'échantillon sur lequel il a été estimé et échouer sur le futur. Pour évaluer une prévision de risque, on doit respecter l'ordre temporel :

entraînement → validation éventuelle → test futur intact.




FIGURE 3.8 – La validation d’un modèle de volatilité doit préserver l’ordre du temps : le futur ne doit intervenir ni dans l’estimation ni dans le choix final du modèle.

Dans un backtest one-step-ahead réaliste, la variance de demain peut être mise à jour avec le rendement observé aujourd’hui, mais aucun rendement futur ne doit être utilisé avant sa date.

3.11 Diagnostiquer un GARCH : les résidus standardisés

Après estimation, on construit

$$z_t = \frac{\hat{\varepsilon}_t}{\hat{\sigma}_t}.$$

Si le modèle de variance a capté l’essentiel de la dépendance de volatilité, les z_t devraient être beaucoup plus proches d’une série homoscédastique que les résidus bruts.

On examine notamment :

- l’ACF de z_t pour détecter une structure résiduelle de moyenne ;
- l’ACF de z_t^2 pour détecter une volatilité encore non expliquée ;
- des tests de Ljung–Box sur z_t et z_t^2 ;
- la distribution de z_t pour vérifier l’hypothèse normale ou envisager une loi à queues épaisses.

EXEMPLE – Lire deux tests de Ljung–Box sans recette mécanique

Supposons qu’à 20 retards on obtienne $p = 0,42$ pour z_t mais $p = 0,03$ pour z_t^2 . La moyenne résiduelle ne montre alors pas d’autocorrélation linéaire évidente, mais la variance conserve une structure exploitable : le modèle de volatilité reste insuffisant. Si les deux p-values sont élevées, le diagnostic est plus rassurant, sans pour autant prouver que la distribution est normale ni que le modèle est optimal hors échantillon.




FIGURE 3.9 – La standardisation divise les innovations par la volatilité conditionnelle estimée ; elle permet d’isoler ce que le modèle n’a pas expliqué.

ATTENTION – Un bon ajustement de variance ne garantit pas une loi normale

Même si l’ACF des carrés standardisés devient faible, la distribution des z_t peut encore présenter de l’asymétrie ou des queues épaisses. La dynamique de variance et la forme de la distribution conditionnelle sont deux choix distincts.

Symptôme après estimation	Lecture possible	Action raisonnable
ACF de z_t significative	moyenne mal spécifiée	revoir ARMA/ARIMA ou les variables de moyenne
ACF de z_t^2 significative	variance mal spécifiée	revoir ordre GARCH, asymétrie ou régime
Queues épaisses de z_t	distribution conditionnelle trop fine	tester Student-t ou autre loi adaptée
Dépassements VaR regroupés	adaptation du risque trop lente	revoir dynamique, rupture ou validation

3.12 Loi normale ou Student-t ?

La loi normale est souvent un point de départ commode. Mais elle attribue relativement peu de probabilité aux événements très éloignés de la moyenne. Une loi Student-t avec peu de degrés de liberté possède des queues plus épaisses.

Pour utiliser une Student-t comme innovation de variance unitaire, on la standardise. Si $T \sim t_\nu$ avec $\nu > 2$, alors

$$Z = \frac{T}{\sqrt{\nu/(\nu - 2)}}$$

a une variance égale à 1.




FIGURE 3.10 – À variance comparable, une Student-t attribue davantage de probabilité aux observations extrêmes qu’une loi normale.

EXEMPLE – Pourquoi cela change le risque

Deux modèles peuvent produire exactement la même prévision de volatilité $\sigma_{t+1} = 2\%$. Si l’un suppose une loi normale et l’autre une Student-t à queues épaisses, leurs quantiles extrêmes seront différents. La même volatilité ne conduit donc pas nécessairement à la même VaR.

Le paramètre ν contrôle l’épaisseur des queues. Lorsque ν est faible, les événements extrêmes reçoivent davantage de probabilité. Lorsque ν devient grand, la Student-t se rapproche progressivement d’une loi normale. Pour disposer d’une variance finie, il faut $\nu > 2$; pour disposer en plus d’un quatrième moment fini, et donc d’une kurtosis théorique finie, il faut $\nu > 4$.

ATTENTION – Student-t ne signifie pas « crise garantie »

Une loi à queues épaisses modifie les probabilités conditionnelles d’événements extrêmes. Elle ne prédit pas la date d’une crise. Elle décrit mieux la forme possible des innovations après prise en compte de la volatilité conditionnelle.

3.13 Pourquoi un GARCH symétrique peut être insuffisant

Dans un GARCH standard, $+2\%$ et -2% ont exactement le même impact sur la variance future car ils possèdent le même carré. Cette symétrie peut être trop restrictive.

3.13.1 GJR-GARCH / Threshold GARCH

Une forme courante de GJR-GARCH [4] est

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \gamma I_{t-1}^- \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2,$$

où

$$I_{t-1}^- = \begin{cases} 1, & \varepsilon_{t-1} < 0, \\ 0, & \varepsilon_{t-1} \geq 0. \end{cases}$$

Pour un choc positif, l'effet instantané est essentiellement gouverné par α . Pour un choc négatif, il devient $\alpha + \gamma$.




FIGURE 3.11 – La courbe d'impact des nouvelles illustre comment un modèle asymétrique peut réagir davantage aux chocs négatifs.

EXEMPLE – Même amplitude, conséquence différente

Si $\alpha = 0,05$ et $\gamma = 0,10$, un choc positif de carré égal à 4 contribue pour $0,05 \times 4 = 0,20$. Le même choc négatif contribue pour

$$(0,05 + 0,10) \times 4 = 0,60.$$

Le signe est donc devenu informatif pour la variance.

Sous une distribution symétrique où la probabilité d'un choc négatif vaut approximativement $1/2$, une condition courante de variance inconditionnelle finie pour cette écriture du GJR-GARCH est

$$\alpha + \beta + \frac{\gamma}{2} < 1.$$

Cette formule dépend de la convention et de la distribution ; elle doit donc être reliée à l'équation exacte du modèle utilisé.

3.13.2 EGARCH

Le modèle EGARCH, pour *Exponential GARCH*, a été proposé par Nelson [3]. Une écriture usuelle est

$$\log \sigma_t^2 = \omega + \beta \log \sigma_{t-1}^2 + \alpha (|z_{t-1}| - \mathbb{E}|z|) + \gamma z_{t-1}.$$

La modélisation du logarithme de la variance garantit sa positivité sans imposer exactement les mêmes contraintes de non-négativité sur les coefficients. Le terme signé γz_{t-1} permet de représenter l'asymétrie.

ATTENTION – Les signes dépendent de la convention

Selon les logiciels et les articles, l'écriture d'EGARCH ou de TGARCH peut varier. Il faut toujours lire l'équation exacte avant d'interpréter le signe d'un coefficient. Un nom de modèle ne suffit pas à déterminer la convention utilisée.

3.14 Prévoir la volatilité

Une fois le modèle estimé au temps T , on cherche

$$\mathbb{E}_T(\sigma_{T+h}^2),$$

la variance conditionnelle prévue à l'horizon h .

Pour un GARCH(1,1), après la prévision à un pas, les innovations futures ont une espérance quadratique égale à leur variance conditionnelle. La prévision multi-horizon converge alors vers la variance de long terme lorsque $\alpha + \beta < 1$.

Si $p = \alpha + \beta$ et $\bar{\sigma}^2 = \omega/(1 - p)$, on peut écrire pour $h \geq 1$ une relation de type

$$\hat{\sigma}_{T+h|T}^2 = \bar{\sigma}^2 + p^{h-1} (\hat{\sigma}_{T+1|T}^2 - \bar{\sigma}^2).$$




FIGURE 3.12 – La prévision multi-horizon d'un GARCH stationnaire converge progressivement vers son niveau de variance de long terme.

POINT DE VUE INGÉNIEUR – Une prévision de volatilité doit préciser son horizon

Dire « la volatilité prévue vaut 2% » est incomplet. S'agit-il de la volatilité quotidienne de demain, d'une volatilité annualisée, d'un horizon de dix jours ou d'une moyenne sur le mois ? Une mesure de risque n'a de sens qu'avec une unité et un horizon explicites.

3.14.1 Volatilité quotidienne, horizon cumulé et annualisation

La règle familière $\sigma_h \approx \sqrt{h} \sigma$ suppose un cadre où les variances quotidiennes sont suffisamment stables et où les covariances entre rendements sont négligeables. Dans un modèle GARCH, la variance prévue change précisément avec l'horizon.

Si l'on cherche la variance d'un rendement cumulé sur H jours et que les covariances conditionnelles des rendements sont négligeables, une approximation cohérente consiste à sommer les variances prévues :

$$\text{Var}_T \left(\sum_{h=1}^H r_{T+h} \right) \approx \sum_{h=1}^H \hat{\sigma}_{T+h|T}^2.$$

La volatilité de l'horizon est alors la racine carrée de cette somme.

ATTENTION – Ne pas annualiser mécaniquement une prévision dynamique

Multiplier une volatilité quotidienne par $\sqrt{252}$ est utile comme convention descriptive lorsque le niveau quotidien est supposé représentatif. Pour un horizon de risque conditionnel précis, il est préférable d'agréger les variances prévues selon la dynamique du modèle.

3.15 Du modèle de volatilité à la Value-at-Risk

La **Value-at-Risk**, abrégée VaR, répond à une question de quantile : quel seuil de perte ne devrait être dépassé qu'avec une petite probabilité donnée, sous le modèle choisi ?

Pour éviter les ambiguïtés de signe, définissons la perte

$$L_{t+1} = -r_{t+1}.$$

La VaR au niveau c est le quantile c de la distribution conditionnelle de L_{t+1} :

$$\text{VaR}_{c,t} = Q_c(L_{t+1} \mid \mathcal{F}_t).$$

Sous une hypothèse normale

$$r_{t+1} = \mu_{t+1} + \sigma_{t+1}Z, \quad Z \sim \mathcal{N}(0, 1),$$

posons $\alpha = 1 - c$ et $z_\alpha = \Phi^{-1}(\alpha) < 0$. Avec la convention $L = -r$,

$$\text{VaR}_{c,t} = -(\mu_{t+1} + \sigma_{t+1}z_\alpha).$$

Cette formule rend explicites les trois éléments nécessaires : une moyenne, une volatilité conditionnelle et un quantile de distribution.

EXEMPLE – VaR 99 % sur un rendement journalier

Supposons $\mu = 0$ et $\sigma = 2\%$. Le quantile gauche à 1% de la loi normale vaut environ $-2,326$. Le seuil de rendement est donc

$$-2,326 \times 2\% \approx -4,65\%.$$

Avec notre convention de perte positive, la VaR 99% vaut environ 4,65% du capital pour une période.




FIGURE 3.13 – Une VaR conditionnelle suit la volatilité estimée ; les observations au-delà du seuil constituent des dépassements.

3.16 Expected Shortfall : regarder au-delà du seuil

La VaR indique un seuil, mais ne dit pas ce qui se passe lorsque ce seuil est dépassé. L'**Expected Shortfall**, abrégé ES, répond à une question différente : quelle est la perte moyenne dans la queue la plus défavorable ?

Dans une présentation continue,

$$ES_{c,t} = \mathbb{E}[L_{t+1} \mid L_{t+1} \geq VaR_{c,t}, \mathcal{F}_t].$$

Sous normalité, avec $\alpha = 1 - c$ et $z_\alpha = \Phi^{-1}(\alpha)$,

$$ES_{c,t} = -\mu_{t+1} + \sigma_{t+1} \frac{\phi(z_\alpha)}{\alpha}.$$

Ainsi, pour une même distribution continue et un même niveau c , l'ES est plus sévère que la VaR car elle moyenne les pertes situées au-delà du seuil.

EXEMPLE – Du GARCH à la VaR et à l'ES en trois lignes

Supposons que le modèle fournisse pour demain $\mu = 0,02\%$ et $\sigma = 1,50\%$. Pour une VaR normale à 99%, $\alpha = 0,01$ et $z_\alpha \approx -2,326$:

$$VaR_{99\%} \approx -(0,02\% - 2,326 \times 1,50\%) \approx 3,47\%.$$

Comme $\phi(-2,326) \approx 0,02665$,

$$ES_{99\%} \approx -0,02\% + 1,50\% \times \frac{0,02665}{0,01} \approx 3,98\%.$$

La volatilité est donc l'entrée dynamique ; la loi choisie transforme cette volatilité en quantile puis en moyenne de queue.




FIGURE 3.14 – La VaR localise un seuil de queue ; l’Expected Shortfall décrit la sévérité moyenne au-delà de ce seuil.

INTUITION – Deux portefeuilles peuvent partager la même VaR et avoir des queues très différentes

Si deux distributions possèdent le même quantile à 99%, elles ont la même VaR 99%. Pourtant, dans l’une, les pertes au-delà du seuil peuvent rester proches de celui-ci ; dans l’autre, elles peuvent devenir beaucoup plus extrêmes. L’ES distingue ces situations parce qu’il regarde la queue entière.

La réglementation prudentielle moderne utilise notamment l’Expected Shortfall dans le cadre du risque de marché, mais notre objectif ici reste pédagogique : comprendre comment une distribution conditionnelle et une prévision de volatilité deviennent une mesure de risque [8].

3.17 Backtester une mesure de risque

Un modèle de risque n’est pas crédible simplement parce qu’il produit un nombre chaque jour. Il faut comparer ses prévisions aux pertes effectivement observées.

Pour une VaR à 99%, un premier contrôle consiste à examiner la fréquence des dépassements. Sur un très grand nombre d’observations et sous calibration correcte, cette fréquence devrait être proche de 1%.

Mais deux propriétés doivent être distinguées :

- **couverture** : le nombre total de dépassements est-il cohérent avec le niveau annoncé ?
- **indépendance** : les dépassements sont-ils dispersés dans le temps, plutôt que regroupés en *clusters* temporels ?

Une série de dépassements regroupés pendant une crise signale souvent que le modèle adapte insuffisamment vite son niveau de risque.

ATTENTION – Le taux de dépassement ne suffit pas

Une VaR 99% qui produit exactement 1% de dépassements peut encore être mal calibrée si tous ces dépassements surviennent dans une même période. La temporalité des erreurs de risque compte autant que leur nombre.

Définissons l'indicateur de dépassement

$$I_t = \mathbf{1}\{L_t > \text{VaR}_{c,t-1}\}.$$

Sous une VaR correctement calibrée au niveau c , on attend en première approximation

$$\mathbb{P}(I_t = 1) = 1 - c.$$

Le test de **couverture inconditionnelle de Kupiec** [9] compare la fréquence observée de dépassement à la fréquence théorique. Il ne vérifie cependant pas leur indépendance. Le **test d'indépendance de Christoffersen** [10] cible précisément la dimension temporelle : un modèle ne doit pas seulement produire le bon nombre d'exceptions, il doit aussi éviter qu'elles se regroupent systématiquement. La combinaison couverture + indépendance conduit au test de **couverture conditionnelle**.


La couverture seule ne suffit pas : l'indépendance des dépassements compte

FIGURE 3.15 – Deux modèles peuvent produire le même nombre de dépassements de VaR mais une qualité très différente : des exceptions regroupées signalent une dynamique de risque mal captée.

POINT DE VUE INGÉNIEUR – Validation minimale d'une VaR

Pour une première lecture : **(1)** taux de dépassement, **(2)** graphique des exceptions, **(3)** test de couverture, **(4)** test d'indépendance. Une validation industrielle exige ensuite davantage de stabilité, de scénarios et de gouvernance.

L'Expected Shortfall ne se valide pas par un simple « taux de dépassement » puisqu'elle décrit la *sévérité moyenne* au-delà d'un seuil. Son backtesting demande donc des outils spécifiques ; nous nous limitons ici à cette distinction conceptuelle.

3.18 Évaluer une prévision de volatilité quand la vraie volatilité est invisible

Dans des données réelles, σ_t^2 est latente : on n'observe pas directement « la vraie variance conditionnelle ». Cette difficulté distingue la prévision de volatilité de nombreux problèmes supervisés classiques.

Plusieurs proxys sont utilisés :

- r_t^2 , très bruité mais simple ;
- $|r_t|$;
- des estimations utilisant High, Low, Open et Close ;
- la volatilité réalisée construite à partir de données intrajournalières.

POINT DE VUE INGÉNIEUR – Le dataset pédagogique connaît la vérité, le marché réel non

Dans le jeu synthétique associé au chapitre, la colonne `true_sigma` contient la volatilité exacte du simulateur. Elle permet de vérifier pédagogiquement un estimateur. Dans une application réelle, une telle colonne n'existe pas : l'utiliser comme entrée d'un modèle prétendument réaliste créerait une fuite d'information conceptuelle.

Une fonction très utilisée pour comparer des prévisions de variance est la perte QLIKE. Si $\hat{v}_t > 0$ désigne la variance prévue et x_t un proxy positif de la variance réalisée, une écriture courante est

$$\text{QLIKE}_t = \frac{x_t}{\hat{v}_t} - \log\left(\frac{x_t}{\hat{v}_t}\right) - 1.$$

Elle vaut 0 lorsque le proxy et la prévision coïncident exactement et augmente lorsque leur rapport s'éloigne de 1. On rencontre aussi l'écriture $\log(\hat{v}_t) + x_t/\hat{v}_t$; pour un $x_t > 0$ donné, elle diffère de la forme ci-dessus d'un terme qui ne dépend pas de la prévision et conduit donc au même classement des modèles. Si le proxy peut être nul, l'implémentation numérique doit annoncer explicitement le petit plancher positif utilisé avant le logarithme. Son intérêt et ses propriétés en présence de proxys imparfaits sont discutés notamment par Patton [11].




FIGURE 3.16 – La volatilité conditionnelle vraie est latente. Un rendement au carré constitue un proxy très bruité; une mesure agrégée peut suivre la dynamique plus lisiblement sans devenir pour autant la « vérité ».

ATTENTION – Ne jamais sélectionner un modèle sur la colonne `true_sigma` d'un problème réel

Dans notre dataset synthétique, `true_sigma` permet de vérifier si la chaîne pédagogique fonctionne. Dans un marché réel, ce signal n'existe pas. Le notebook l'utilise donc uniquement comme *oracle d'évaluation*, après estimation et jamais comme entrée.

L'évaluation doit toujours rester cohérente avec l'objet latent que l'on tente d'estimer, le proxy disponible et l'usage final du modèle.

3.19 De GARCH au portefeuille : ce que le modèle change concrètement

Une prévision de volatilité peut intervenir dans de nombreuses décisions :

- ajustement de la taille de position ;
- volatility targeting ;
- allocation du risque entre plusieurs actifs ;
- calcul de VaR ou ES ;
- marges et limites de risque ;
- détection d'un changement de régime ;
- définition de récompenses ajustées du risque dans un futur agent RL.

EXEMPLE – Volatility targeting très simple

Supposons qu'une stratégie vise une volatilité de 10% annualisée. Si le modèle estime la volatilité de l'actif à 20%, une règle élémentaire peut réduire l'exposition à environ

$$\frac{10\%}{20\%} = 0,5.$$

Si la volatilité estimée tombe à 8%, la même règle donnerait 1,25. Dans un système réel, cette exposition serait ensuite bornée par des contraintes de levier, liquidité et risque.

Cette logique prépare directement le chapitre 8, où la sortie d'un modèle sera transformée en position et en portefeuille.

3.20 Workflow pratique de modélisation

La démarche suivante constitue une première discipline de travail :

Un modèle de volatilité crédible est un cycle de diagnostic, pas une simple commande logicielle



Revenir en arrière si les résidus standardisés, les carrés ou les dépassements conservent une structure inexpliquée.

FIGURE 3.17 – Chaîne de travail recommandée pour une modélisation de volatilité et de risque conditionnel.

1. construire une série de rendements propre et correctement datée ;
2. fixer l'unité : décimal ou pourcentage, et ne plus en changer silencieusement ;
3. spécifier suffisamment la moyenne conditionnelle ;
4. rechercher des effets ARCH dans les résidus ;
5. estimer un modèle simple, souvent GARCH(1,1) comme baseline ;
6. vérifier convergence, contraintes et stabilité numérique ;
7. diagnostiquer les résidus standardisés et leurs carrés ;
8. examiner les queues et l'asymétrie ;
9. comparer éventuellement Student-t, GJR-GARCH ou EGARCH ;
10. figer le choix avant d'ouvrir le futur de test ;
11. produire une prévision hors échantillon et préciser son horizon ;
12. traduire cette prévision en une mesure de risque ou une règle de sizing ;

13. backtester couverture, indépendance et stabilité du modèle.

À RETENIR – Checklist de qualité avant de croire un GARCH

Le modèle est seulement un candidat tant que l'on n'a pas répondu clairement à ces questions : **quelle unité ? quelle moyenne ? quelles contraintes ? l'optimiseur a-t-il convergé ? les résidus standardisés sont-ils propres ? les queues sont-elles plausibles ? la performance est-elle hors échantillon ? les dépassements de VaR sont-ils correctement calibrés et dispersés ?**

3.21 Laboratoire du chapitre

Deux notebooks accompagnent ce chapitre.

Notebook 1 – ARCH/GARCH et diagnostics

Le notebook CH03_NB01_ARCH_GARCH_Diagnostics_Tawfik_Masrour_STUDENT.ipynb permet de :

- visualiser le clustering de volatilité ;
- comparer l'ACF des rendements et de leurs carrés ;
- appliquer un test ARCH-LM ;
- estimer un GARCH(1,1) par maximum de vraisemblance ;
- calculer persistance, variance de long terme et demi-vie ;
- diagnostiquer les résidus standardisés.

Notebook 2 – Asymétrie, VaR et Expected Shortfall

Le notebook CH03_NB02_Asymmetry_VaR_ES_Tawfik_Masrour_STUDENT.ipynb permet de :

- comparer GARCH et GJR-GARCH ;
- examiner l'hypothèse normale face à une Student-t ;
- produire une prévision multi-horizon ;
- calculer VaR et ES conditionnelles ;
- backtester la VaR : taux de dépassement, couverture de Kupiec et indépendance de Christoffersen.

Le jeu de données associé porte l'identifiant stable **TI_CH03_VOL_RISK_V1** et le nom logique **TI_CH03_Vol_Risk_v1.csv**. Il est synthétique et déterministe, ce qui permet de connaître la volatilité latente vraie à des fins de vérification pédagogique.

3.22 Limites des modèles ARCH/GARCH

Les modèles étudiés sont puissants, mais ils ne constituent pas une description complète du risque financier.

3.22.1 Ruptures structurelles

Une forte persistance estimée peut parfois résulter d'un changement de régime non modélisé. Un même GARCH stationnaire peut alors « moyenner » plusieurs époques différentes.

3.22.2 Mémoire longue

Certaines séries de volatilité présentent une décroissance très lente des dépendances. Des extensions comme FIGARCH ou des modèles fractionnaires peuvent alors être étudiées, mais elles dépassent notre tronc commun.

3.22.3 Volatilité stochastique

Dans GARCH, la variance est une fonction déterministe du passé conditionnellement aux paramètres. Les modèles de volatilité stochastique introduisent au contraire un processus latent propre à la variance.

3.22.4 Données à haute fréquence

Avec des données intrajournalières, la volatilité réalisée et les modèles de microstructure apportent une information que le seul rendement quotidien ne peut pas contenir.

3.22.5 Multivarié

Pour un portefeuille, les volatilités individuelles ne suffisent pas : il faut aussi modéliser covariances et corrélations. Les familles multivariées GARCH et les modèles de corrélation dynamique constituent une extension naturelle.

ATTENTION – Complexité ne signifie pas automatiquement meilleure prévision

Une extension GARCH plus sophistiquée peut mieux ajuster l'échantillon historique tout en se dégradant hors échantillon. Comme pour ARIMA, la parcimonie, les diagnostics et l'évaluation chronologique priment sur le nombre de paramètres.

3.23 Exercices

Niveau A – Compréhension

1. Expliquer pourquoi une faible ACF des rendements n'implique pas l'absence de toute dépendance temporelle exploitable.
2. Distinguer volatilité inconditionnelle, conditionnelle, réalisée et implicite.

3. Pourquoi un GARCH standard est-il symétrique par rapport au signe du choc ?
4. Quelle différence conceptuelle sépare VaR et Expected Shortfall ?

Niveau B – Calcul

1. Pour un ARCH(1) avec $\omega = 0,1$ et $\alpha = 0,4$, calculer σ_t^2 après des chocs 0, 1 et -2 .
2. Pour un GARCH(1,1) avec $\omega = 0,02$, $\alpha = 0,08$ et $\beta = 0,90$, calculer la variance de long terme et la demi-vie approximative.
3. Avec $\omega = 0,04$, $\alpha = 0,08$, $\beta = 0,88$, $\varepsilon_t = -1,5$ et $\sigma_t^2 = 1,20$ en unités de pourcentage, calculer σ_{t+1}^2 puis σ_{t+1} .
4. Si $\sigma = 1,5\%$ et $\mu = 0$, approximer une VaR normale 99% avec $z_{0,01} \approx -2,326$, puis expliquer pourquoi l'ES doit être plus grande.

Niveau C – Raisonnement

1. Deux modèles ont le même AIC. L'un laisse une autocorrélation des carrés standardisés, l'autre non. Lequel est plus crédible pour la variance et pourquoi ?
2. Un modèle produit 1% de dépassements de VaR 99%, mais tous sont concentrés durant une crise de deux semaines. Pourquoi ce résultat reste-t-il préoccupant ?
3. Un GARCH estimé donne $\alpha + \beta = 0,998$. Donner deux interprétations possibles et deux précautions avant de conclure à une mémoire presque infinie.

Niveau D – Programmation / expérimentation

1. Simuler un GARCH(1,1) pour trois valeurs de persistance et comparer visuellement les trajectoires de variance.
2. Comparer VaR normale et VaR Student-t sur le dataset du chapitre.
3. Construire un mini-backtest de volatility targeting en bornant l'exposition entre 0 et 1,5.

3.24 Lexique local FR–EN

Français	Anglais / notation usuelle
volatilité conditionnelle	conditional volatility
variance conditionnelle	conditional variance
hétéroscédasticité conditionnelle autorégressive	Autoregressive Conditional Heteroskedasticity (ARCH)
hétéroscédasticité conditionnelle autorégressive généralisée	Generalized ARCH (GARCH)
effet de levier / asymétrie	leverage effect / asymmetry

innovation standardisée	standardized innovation
queues épaisses	heavy tails / fat tails
persistance	persistence
demi-vie d'un choc	shock half-life
variance de long terme	long-run variance
Value-at-Risk	VaR
Expected Shortfall / perte moyenne en queue	ES / conditional tail expectation selon convention
dépassement	exceedance / violation / breach
volatilité réalisée	realized volatility
quasi-maximum de vraisemblance	quasi-maximum likelihood (QMLE)
couverture inconditionnelle	unconditional coverage
indépendance des dépassements	independence of exceedances
perte QLIKE	QLIKE loss
prévision à un pas	one-step-ahead forecast
prévision multi-horizon	multi-step forecast

3.25 Synthèse

Nous pouvons maintenant distinguer deux formes de mémoire :

mémoire de la moyenne
 et mémoire de la variance

ARIMA s'intéressait principalement à la première. ARCH et GARCH construisent la seconde.

Le fil logique du chapitre est :

clustering de volatilité → effets ARCH → GARCH → persistance
 → diagnostics → asymétrie / queues → prévision → VaR / ES.

À RETENIR – Ce qu'il faut réellement savoir défendre

À la fin de ce chapitre, le lecteur doit être capable d'expliquer pourquoi une variance conditionnelle est nécessaire, d'interpréter les paramètres d'un GARCH(1,1), de distinguer persistance et réaction immédiate, de diagnostiquer les résidus standardisés, de justifier une extension asymétrique ou une loi Student-t et de transformer une prévision de volatilité en mesure de risque cohérente avec un horizon et une convention de perte.

3.26 Vers le chapitre suivant

Nous savons maintenant modéliser une série isolée sous deux angles : sa dynamique moyenne et sa dynamique de risque. Mais les marchés ne sont pas composés d'un seul actif. Deux prix peuvent évoluer ensemble sans que leur simple corrélation soit suffisante pour construire une relation stable.

La prochaine question devient donc :

comment distinguer une co-mouvement passager d'une relation inter-actifs suffisamment structurée pour être modélisée et, éventuellement, exploitée dans une stratégie de spread ?

Cette question nous conduira à la corrélation, à la régression entre actifs, à la stationnarité d'un spread et à la cointégration.

Références essentielles

- [1] R. F. Engle, “Autoregressive Conditional Heteroscedasticity with Estimates of the Variance of United Kingdom Inflation”, *Econometrica*, vol. 50, no. 4, pp. 987–1007, 1982.
- [2] T. Bollerslev, “Generalized Autoregressive Conditional Heteroskedasticity”, *Journal of Econometrics*, vol. 31, no. 3, pp. 307–327, 1986. [https://doi.org/10.1016/0304-4076\(86\)90063-1](https://doi.org/10.1016/0304-4076(86)90063-1)
- [3] D. B. Nelson, “Conditional Heteroskedasticity in Asset Returns : A New Approach”, *Econometrica*, vol. 59, no. 2, pp. 347–370, 1991. <https://doi.org/10.2307/2938260>
- [4] L. R. Glosten, R. Jagannathan et D. E. Runkle, “On the Relation between the Expected Value and the Volatility of the Nominal Excess Return on Stocks”, *The Journal of Finance*, vol. 48, no. 5, pp. 1779–1801, 1993. <https://doi.org/10.1111/j.1540-6261.1993.tb05128.x>
- [5] R. S. Tsay, *Analysis of Financial Time Series*, 3e éd., Wiley, 2010.
- [6] A. J. McNeil, R. Frey et P. Embrechts, *Quantitative Risk Management : Concepts, Techniques and Tools*, édition révisée, Princeton University Press, 2015.
- [7] C. Francq et J.-M. Zakoïan, *GARCH Models : Structure, Statistical Inference and Financial Applications*, Wiley, 2019.
- [8] Basel Committee on Banking Supervision, *Minimum capital requirements for market risk*, Bank for International Settlements. Cadre prudentiel utilisant notamment l’Expected Shortfall dans l’approche interne du risque de marché. <https://www.bis.org/bcbs/publ/d457.htm>
- [9] P. H. Kupiec, “Techniques for Verifying the Accuracy of Risk Measurement Models”, *The Journal of Derivatives*, vol. 3, no. 2, pp. 73–84, 1995.
- [10] P. F. Christoffersen, “Evaluating Interval Forecasts”, *International Economic Review*, vol. 39, no. 4, pp. 841–862, 1998.
- [11] A. J. Patton, “Volatility Forecast Comparison Using Imperfect Volatility Proxies”, *Journal of Econometrics*, vol. 160, no. 1, pp. 246–256, 2011. <https://doi.org/10.1016/j.jeconom.2010.03.034>